

CENTRO DE INVESTIGACIÓN Y DE ESTUDIOS AVANZADOS
DEL INSTITUTO POLITÉCNICO NACIONAL

Unidad Saltillo

Robótica y Manufactura Avanzada

“Estrategias de aprendizaje para asir y lanzar objetos rígidos a posiciones fijas con robots manipuladores”

T e s i s

Que presenta

José Fausto Gómez Cordero

Para obtener el grado de

Maestro en Ciencias

En

Robótica y Manufactura Avanzada

Directores de la Tesis

Dr. Gustavo Arechavaleta Servín
Dr. Keny Ordaz Hernández

Ramos Arizpe, Coahuila 2026

A mi familia.

Agradecimientos

A mi mamá, por estar siempre pendiente de mí y apoyarme en todo lo que necesité durante esta etapa. Gracias por ayudarme a resolver tantas cosas y por hacerme sentir acompañado aun en los momentos difíciles. Tu apoyo fue fundamental para llegar hasta aquí.

A mi papá, por el apoyo que me brindó durante mis estudios. A mi hermana y a mi novia, por acompañarme, escucharme y estar presentes a lo largo de este proceso.

Al Dr. Gustavo Arechavaleta Servín, por su disposición para ayudarme siempre que lo necesité, tanto en el desarrollo de la tesis como en otras situaciones que surgieron durante la maestría.

Al Dr. Keny Ordaz Hernández, por sus ideas y observaciones, que me ayudaron a identificar problemas, cuestionar mis decisiones y mejorar este trabajo.

Al Centro de Investigación y de Estudios Avanzados del Instituto Politécnico Nacional (Cinvestav), Unidad Saltillo, por la formación recibida y por las instalaciones y los equipos que hicieron posible el desarrollo de esta tesis.

A la Secretaría de Ciencia, Humanidades, Tecnología e Innovación (Secihti), por la beca otorgada para realizar mis estudios de maestría.

Resumen

Estrategias de aprendizaje para asir y lanzar objetos rígidos a posiciones fijas con robots manipuladores

El transporte de objetos suele resolverse mediante operaciones de *pick and place*, en las que el manipulador mantiene la pieza sujeta hasta alcanzar su destino. El lanzamiento permite extender esta capacidad hacia objetivos situados fuera del alcance directo del robot, aunque el resultado depende tanto de las condiciones de liberación como de la ubicación seleccionada de asimiento.

En este trabajo se desarrolla una estrategia de aprendizaje en dos etapas para asir y lanzar piezas rígidas hacia objetivos fijos. Debido a la apertura reducida del efector final, primero se entrena una red de asimiento con etiquetas densas generadas mediante un criterio geométrico en simulación. Posteriormente, la política se refina mediante lanzamientos simulados para favorecer los asimientos que producen mejores resultados en la tarea. La selección del asimiento se combina con un modelo balístico y un planificador de trayectorias para generar el movimiento de lanzamiento.

El entrenamiento se realiza completamente en simulación y los parámetros de la red permanecen fijos durante la transferencia al robot Sawyer.

En la evaluación física, el sistema asió correctamente el 97.56 % de las piezas conocidas durante el entrenamiento y el 96.15 % de las desconocidas. Una vez asida la pieza, el lanzamiento alcanzó el objetivo asignado en el 87.25 % y el 76.50 % de los casos, respectivamente, lo que corresponde a un éxito en la tarea completa del 85.12 % para las piezas conocidas y del 73.56 % para las desconocidas.

Estos resultados muestran que el sistema puede transferir la política aprendida en simulación al robot físico y realizar lanzamientos hacia objetivos situados fuera de su alcance directo.

Abstract

Learning Strategies for Grasping and Throwing Rigid Objects to Fixed Positions with Robotic Manipulators

Object transport is typically addressed through pick-and-place operations, in which the manipulator keeps the object grasped until it reaches its destination. Throwing extends this capability to targets located beyond the robot's direct reach, although the outcome depends on both the release conditions and the selected grasp location.

This thesis develops a two-stage learning strategy for grasping and throwing rigid objects toward fixed targets. Due to the limited opening of the end effector, a grasping network is first trained with dense labels generated through a geometric criterion in simulation. The policy is then refined through simulated throws to favor grasps that yield better task outcomes. Grasp selection is combined with a ballistic model and a trajectory planner to generate the throwing motion.

Training is performed entirely in simulation, and the network parameters remain fixed during transfer to the Sawyer robot.

In the physical evaluation, the system successfully grasped 97.56 % of the known objects and 96.15 % of the unseen ones. Once the object was grasped, the throw reached the assigned target in 87.25 % and 76.50 % of the cases, respectively, which corresponds to a full-task success rate of 85.12 % for seen objects and 73.56 % for unseen objects.

These results show that the system can transfer the policy learned in simulation to the physical robot and perform throws toward targets located beyond its direct reach.

Índice general

Resumen vii

Abstract ix

Lista de Figuras xiv

Lista de Tablas xv

Nomenclatura xvii

1. Introducción **1**
1.1. Motivación 1
1.2. Estado del arte 3
1.3. Definición del problema 8
1.4. Objetivos e hipótesis 10
1.5. Organización de la tesis 11

2. Fundamentos **13**
2.1. Cinemática y dinámica de manipuladores 13
2.2. Planificación y optimización de trayectorias 18
2.3. Redes neuronales y aprendizaje profundo 22

3. Metodología **27**
3.1. Entorno de simulación y plataforma física 27
3.2. Visión general del sistema 31
3.3. Planificación de movimiento 34
3.4. Percepción 37
3.5. Red de asimiento 39
3.6. Entrenamiento 41

4. Resultados **45**
4.1. Protocolo experimental 45
4.2. Calibración del lanzamiento 49
4.3. Evaluación en simulación 51
4.4. Resultado principal 52

4.5. Análisis de la política de asimiento 52
4.6. Análisis del desempeño 54
4.7. Comparación con el trabajo de referencia 56
4.8. Limitaciones 59

5. Conclusiones **61**
5.1. Cumplimiento de los objetivos 61
5.2. Aportaciones 62
5.3. Trabajo futuro 62

Bibliografía **63**

A. Generación de escenas y etiquetado automático de asimientos **67**
A.1. Piezas utilizadas 67
A.2. Construcción de las escenas 70
A.3. Criterio de viabilidad del asimiento 70
A.4. Parámetros de generación 71

B. Formulación de los problemas de planificación **73**
B.1. Límites del manipulador 73
B.2. Movimiento articular 73
B.3. Movimiento cartesiano 74
B.4. Lanzamiento 75
B.5. Parámetros numéricos 76

C. Calibración del sistema de percepción **77**
C.1. Calibración de la cámara RGB-D 77
C.2. Corrección de la superficie de la mesa 78
C.3. Calibración de la cámara cenital 78

Índice de figuras

1.1. *Pick and place* frente a lanzamiento 2
1.2. Planteamiento del problema y supuestos 9

2.1. Dos configuraciones para la misma pose 16
2.2. Transcripción directa de un problema de control óptimo 21
2.3. Estructura general de la U-Net 25
2.4. Conexión de salto de la U-Net 25

3.1. Escena de simulación y región de muestreo del objetivo 28
3.2. Articulaciones del manipulador Sawyer 30
3.3. Efector final en su apertura máxima 31
3.4. Arquitectura de comunicación del sistema 32
3.5. Ciclo de operación del sistema 33
3.6. Parámetros de la primitiva de asimiento 34
3.7. Modelo reducido para el lanzamiento 36
3.8. Parámetros de la primitiva de lanzamiento 37
3.9. Construcción del mapa de alturas 38
3.10. Arquitectura de la red de asimiento 39
3.11. Relleno de la observación antes de rotarla 40
3.12. Inferencia de la política de asimiento 41
3.13. Selección del asimiento sobre una escena real 41
3.14. Etiqueta de asimiento en tres orientaciones 42

4.1. Piezas empleadas en la evaluación 46
4.2. Disposición de los objetivos 47
4.3. Montaje experimental 48
4.4. Seguimiento de la trayectoria articular 49
4.5. Perfil de la corrección de velocidad 50
4.6. Mapas de probabilidad de asimiento 53
4.7. Desempeño en cada día de la evaluación 54
4.8. Tasa de asimiento y de lanzamiento exitoso por forma 55
4.9. Lanzamientos exitosos por objetivo de la matriz 56
4.10. Duración de las fases del ciclo de operación 59

A.1. Catálogo de piezas de simulación 68

Índice de tablas

1.1. Comparación de los trabajos de asimiento 5
1.2. Comparación de los trabajos de lanzamiento 7

3.1. Hiperparámetros de entrenamiento 44

4.1. Rapidez horizontal planificada y medida en vuelo 51
4.2. Desempeño de las redes en simulación 51
4.3. Desempeño del sistema en el robot físico 52
4.4. Condiciones experimentales de ambos sistemas 56
4.5. Tamaño de los objetos respecto de la apertura del objetivo 57
4.6. Desempeño comparado con la referencia 58

A.1. Configuración del etiquetado geométrico 71

B.1. Límites articulares del robot Sawyer 73
B.2. Parámetros del planificador 76

Nomenclatura

$a^{(l)}$	Salida de la capa l de una red neuronal
b	Condiciones de frontera del problema de control óptimo
$b^{(l)}$, $W^{(l)}$	Sesgo y pesos de la capa l
$c(\theta, \dot{\theta})$	Términos de Coriolis y centrípetos
D	Distancia horizontal al objetivo
d	Desplazamiento lateral del efector final
F	Dinámica del sistema en el problema de control óptimo
g	Vector de gravedad
$g(\theta)$	Términos de gravedad
h	Restricciones de trayectoria
I	Observación ortográfica RGB-altura de $170 \times 230 \times 4$
J, J_v	Jacobiano geométrico y su bloque lineal
k	Índice de nodo
M	Matriz de masa
N	Número de nodos en los movimientos articular y cartesiano; número de intervalos en el lanzamiento
N_o	Número de orientaciones evaluadas
o	Índice de rotación
p	Posición del efector final
p_g	Posición del asimiento
p_{obj}	Posición del objetivo
Q	Mapas de valoración de las acciones de asimiento
q	Orientación del efector final, en cuaternión unitario
R	Matriz de rotación, $R \in SO(3)$
r, $\hat{r}$	Posición de liberación y su valor nominal
$s(t)$	Función de escalamiento temporal
T	Transformación rígida, $T \in SE(3)$; T_{ij} es la transformación rígida del marco j respecto del marco i
T_B	Temperatura de la distribución de Boltzmann
t_0, t_f	Tiempos inicial y final del movimiento; t_f es su duración
u	Entrada del problema de control óptimo
(u, v)	Píxel de la observación
v, $\hat{v}$	Velocidad de liberación y su valor nominal
x, x_d	Pose del efector final y pose deseada

y_i, $\hat{y}_i$	Etiqueta y predicción
z	Estado del problema de control óptimo
α	Ángulo de liberación
β_0, β_1	Coeficientes de la corrección de velocidad
δ	Corrección de la rapidez de liberación
Δt	Paso de discretización
θ, $\dot{\theta}$, $\ddot{\theta}$	Posición, velocidad y aceleración articulares
θ_i	Coordenada de la articulación j_i, numeradas desde 0
θ_a	Articulaciones activas durante el lanzamiento
θ_k^{ref}, θ_a^{ref}	Referencias articulares por nodo y al inicio del lanzamiento
p_k^{ref}, q_k^{ref}	Referencias cartesianas de posición y orientación por nodo
ε_p	Tolerancia de posición final
ε_o	Tolerancia de orientación final, adimensional
$x_{\text{mín}}$, $z_{\text{mín}}$	Cotas de posición del efector en el plano de lanzamiento
$t_{f_{\text{mín}}}$, $t_{f_{\text{máx}}}$	Cotas de duración del lanzamiento
θ_{ini}, θ_{fin}	Configuraciones inicial y final
$\theta_{\text{mín}}$, $\theta_{\text{máx}}$	Límites de posición articular
$\dot{\theta}_{\text{máx}}$, $\ddot{\theta}_{\text{máx}}$	Límites de velocidad y aceleración articulares
ℓ	Entropía cruzada binaria
μ, σ	Media y desviación estándar de cada canal de la observación
τ, $\tau_{\text{máx}}$	Pares articulares y su límite
φ	Función de activación
$\phi_g = (p_g, \psi)$	Parámetros de la primitiva de asimiento
$\phi_t = (r, v)$	Parámetros de la primitiva de lanzamiento
ψ	Rotación del efector final en el asimiento
ω	Velocidad angular del efector final
$\mathcal{J}_{(\cdot)}$	Funciones de costo
$\mathcal{L}_g$	Pérdida del entrenamiento de la red de asimiento
$\mathcal{L}_t$	Pérdida del refinamiento con el resultado del lanzamiento
$\mathcal{V} = (\omega, v)$	*Twist* del efector final

Abreviaturas

RGB-D	Imagen de color con profundidad (*red, green, blue, depth*)
RL	Aprendizaje por refuerzo (*Reinforcement Learning*)
ROS	*Robot Operating System*
SGD	Descenso de gradiente estocástico (*Stochastic Gradient Descent*)
SLERP	Interpolación esférica lineal (*Spherical Linear Interpolation*)

Capítulo 1

Introducción

La manipulación robótica comprende las acciones mediante las cuales un robot modifica la posición o el movimiento de los objetos de su entorno. Entre ellas se encuentran asir, transportar, empujar, soltar y lanzar (Mason, 2001). Aunque estas acciones implican formas distintas de interacción, todas requieren seleccionar y ejecutar un movimiento que produzca el efecto deseado sobre el objeto.

Zheng et al. (2025) señalan que, en los últimos años, una parte importante de la investigación se ha centrado en métodos de aprendizaje capaces de operar con objetos y tareas cada vez más diversos. El objetivo no es únicamente ejecutar una acción determinada, sino lograr que el sistema mantenga un buen desempeño cuando cambian los objetos, el entorno o incluso la tarea. Sin embargo, esto sigue siendo difícil debido a la diversidad de situaciones que pueden presentarse en la práctica, la incertidumbre del entorno y problemas propios de la percepción, como el ruido y las oclusiones.

El lanzamiento forma parte de este problema general de manipulación, pero presenta una diferencia importante respecto del transporte convencional. El robot no necesita acompañar a la pieza hasta el destino: puede liberarla durante el movimiento y dejar que complete el resto del recorrido en vuelo libre. Esto permite alcanzar posiciones que quedan fuera del espacio cinemático del manipulador y, en algunos casos, reducir el desplazamiento que debe realizar el robot. A cambio, el resultado depende con mayor fuerza del asimiento de la pieza, del movimiento empleado para lanzarla y de las condiciones alcanzadas en el momento de la liberación.

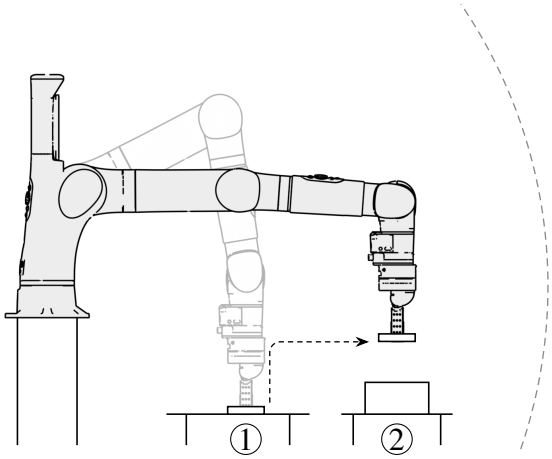
1.1. Motivación

Una de las tareas más comunes de manipulación consiste en trasladar un objeto de una posición inicial a un destino. En un sistema de *pick and place*, el robot primero ase la pieza, la transporta manteniendo el contacto con ella y, finalmente, la deposita en la posición deseada. Este tipo de operación se utiliza habitualmente en procesos de clasificación, de alimentación de piezas y de transferencia de objetos entre distintas zonas de trabajo.

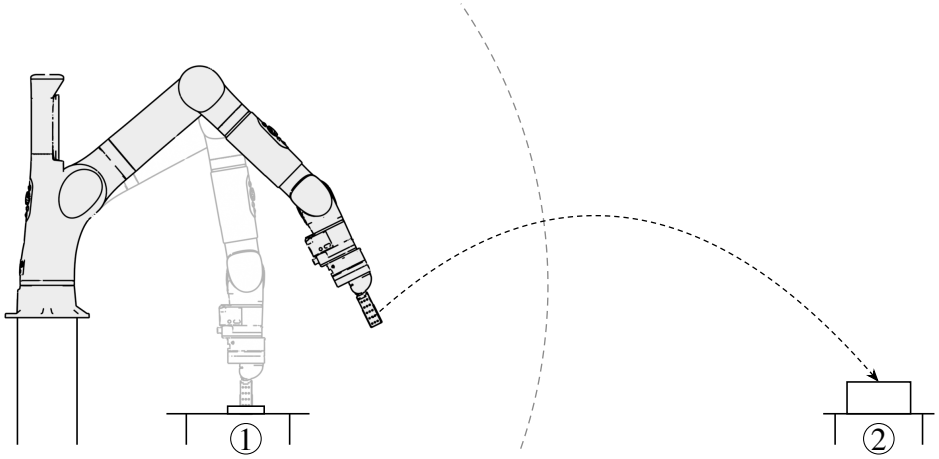
El lanzamiento ofrece una forma distinta de realizar este transporte al liberar la pieza antes de que el manipulador alcance el destino y permitir que la pieza complete una parte del recorrido por sí misma. Esta acción pertenece a la manipulación no prensil, en la que hay movimiento relativo

entre el objeto y el manipulador. Lynch y Mason (1999) señalan que este tipo de manipulación puede ampliar las capacidades del robot al permitir que el objeto alcance destinos que no serían posibles si permaneciera sujeto durante toda la tarea.

Una de las principales ventajas del lanzamiento es que permite ampliar el espacio en el que puede realizarse la tarea. En un *pick and place*, el destino debe ubicarse dentro del espacio de trabajo del manipulador y debe existir una trayectoria que permita transportar la pieza hasta dicho destino. En un lanzamiento, en cambio, el efector final solo necesita alcanzar un estado desde el cual la pieza pueda ser liberada hacia el objetivo. El alcance cinemático del robot no cambia, pero el objeto puede alcanzar posiciones que el efector final no puede alcanzar directamente (Lynch y Mason, 1999), como se muestra en la Figura 1.1.



(a) *Pick and place*



(b) Lanzamiento

Figura 1.1: Transporte de una pieza desde la mesa de recogida ① hasta una caja ②.

Otra ventaja, es la posible reducción de la distancia que debe recorrer el manipulador. En lugar de acompañar la pieza hasta el punto de entrega y regresar desde allí, el robot puede liberarla antes y comenzar su siguiente movimiento mientras la pieza completa el recorrido en

vuelo. Esta propiedad resulta especialmente útil cuando existe una separación considerable entre la zona de recogida y los destinos, y constituye una de las razones por las que se ha propuesto el lanzamiento como alternativa al *pick and place* en tareas de clasificación (Zeng et al., 2020).

Sin embargo; el lanzamiento introduce, una dificultad que no se presenta de la misma forma en un *pick and place*: una vez liberada la pieza, el robot deja de controlar directamente su movimiento. El resultado depende entonces de las condiciones alcanzadas en el instante de la liberación y del asimiento realizado. Por esta razón, un asimiento aceptable para levantar y transportar una pieza no necesariamente es el más conveniente para lanzarla con precisión.

En este trabajo interesa precisamente esta relación entre ambas etapas: seleccionar asimientos que no solo permitan mantener sujeta la pieza, sino que también favorezcan el resultado del lanzamiento subsecuente.

1.2. Estado del arte

Los primeros enfoques para el asimiento y el lanzamiento robóticos se basaron principalmente en modelos geométricos y físicos, con los que se determinaban las acciones del robot utilizando información conocida del objeto y del sistema. Estos métodos continúan siendo relevantes, pero con el desarrollo del aprendizaje automático surgieron alternativas capaces de asumir parte de esas decisiones a partir de los datos.

En el asimiento, esta transición se extendió desde la generación y evaluación de candidatos mediante criterios geométricos hasta métodos capaces de predecir acciones a partir de observaciones visuales. Más adelante, también surgió la idea de que la calidad de un asimiento no depende únicamente de que sea posible asir la pieza, sino también de la tarea que se realizará después.

En el lanzamiento se observó un desarrollo similar. Los modelos analíticos permiten determinar las condiciones necesarias para alcanzar un objetivo, mientras que los métodos basados en el aprendizaje se han utilizado para representar o corregir efectos difíciles de modelar. Algunos trabajos combinan actualmente ambas aproximaciones.

1.2.1. Asimiento

La selección de asimientos a partir de información visual se ha planteado mediante criterios geométricos y mediante modelos aprendidos a partir de datos. Saxena et al. (2008) utilizaron características extraídas de imágenes para identificar regiones de asimiento adecuadas en objetos desconocidos, mientras que Jiang et al. (2011) representaron cada acción mediante un rectángulo orientado en una imagen RGB-D y emplearon el aprendizaje supervisado para evaluar distintas configuraciones. En ambos casos, las características utilizadas para realizar la predicción eran definidas previamente y empleadas después por el modelo de aprendizaje.

También es posible obtener una valoración del asimiento directamente a partir de la geometría observada. Domae et al. (2014) propusieron calcular una medida de calidad en un mapa de profundidad, utilizando regiones del efector final asociadas al contacto y a posibles colisiones. Para cada orientación, se obtiene un mapa en el que es posible seleccionar la posición de mayor valor, sin requerir un modelo tridimensional conocido de la pieza. Aunque la medida se obtiene

mediante criterios geométricos y no mediante aprendizaje, esta formulación ya establece una correspondencia directa entre las posiciones de observación y las posibles acciones de asimiento.

Las redes neuronales profundas también permitieron aprender las características que se utilizaron para evaluar estas acciones. Lenz et al. (2015) emplearon información RGB-D y una arquitectura profunda para evaluar candidatos de asimiento. Debido al número de configuraciones posibles, utilizaron dos redes en cascada, en las que la primera redujo el conjunto de candidatos y la segunda realizó una evaluación más detallada. Redmon y Angelova (2015) utilizaron una red convolucional para predecir directamente rectángulos de asimiento a partir de la imagen, lo que reduce la necesidad de evaluar por separado un gran número de propuestas.

El entrenamiento de estos modelos requiere un número considerable de ejemplos. Pinto y Gupta (2016) obtuvieron las etiquetas a partir de los propios intentos de asimiento del robot y recopilaron 50 000 ejemplos durante aproximadamente 700 horas de operación. Levine et al. (2018) emplearon varios manipuladores para recopilar cientos de miles de intentos y aprender una política de asimiento visual. Estos trabajos muestran que la interacción física puede utilizarse como fuente de supervisión, aunque obtener conjuntos de datos de gran tamaño de esta manera requiere un tiempo de entrenamiento considerable.

Una alternativa consiste en generar los datos mediante modelos y simulación. Mahler et al. (2017) propusieron Dex-Net 2.0, en el que se emplean modelos tridimensionales y métricas analíticas de calidad para generar millones de ejemplos sintéticos. Con estos datos se entrena una red convolucional que estima la robustez de posibles asimientos a partir de imágenes de profundidad, lo que reduce la cantidad de experiencia que debe recopilarse directamente en el robot físico.

Para evitar la evaluación independiente de cada candidato, también se han utilizado redes que generan una salida espacial. Morrison et al. (2018) propusieron GG-CNN, que genera predicciones de calidad y de pose de asimiento asociadas a las posiciones en una imagen de profundidad. La acción puede seleccionarse directamente en este mapa, manteniendo la correspondencia entre la observación y la posición física del asimiento. Zhang et al. (2022) estudian un problema relacionado con la generación de datos y utilizan la simulación para obtener etiquetas densas de asimiento, lo que proporciona supervisión en un conjunto más amplio de posiciones dentro de una misma escena.

La Tabla 1.1 resume los trabajos revisados. De ellos, dos ideas resultan especialmente relevantes: representar la calidad del asimiento mediante un mapa directamente asociado a la observación y aprovechar la simulación para supervisar múltiples acciones en una misma escena. Sin embargo, determinar si una acción permite asir correctamente una pieza no implica necesariamente que ese asimiento sea adecuado para la tarea que debe realizarse después.

Tabla 1.1: Comparación de los trabajos de asimiento. *Acción*: cómo se representa el asimiento; *Etiquetas*: cómo se generan; *Tarea subsecuente*: si la valoración del asimiento considera la acción que sigue. *El asimiento proviene de una red preentrenada; lo que se aprende es el empuje.

Trabajo	**Acción**	**Etiquetas**	**Tarea subsecuente**
Saxena et al. (2008)	Puntos	Renderizado sintético	–
Jiang et al. (2011)	Candidatos	Anotación manual (rectángulos)	–
Domae et al. (2014)	Densa	Criterio geométrico	–
Lenz et al. (2015)	Candidatos	Anotación manual (rectángulos)	–
Redmon y Angelova (2015)	Regresión	Anotación manual (rectángulos)	–
Pinto y Gupta (2016)	Candidatos	Ejecución en el robot	–
Mahler et al. (2017)	Candidatos	Simulación y métrica analítica	–
Levine et al. (2018)	Servo continuo	Ejecución en el robot	–
Morrison et al. (2018)	Densa	Anotación manual (rectángulos)	–
Zeng et al. (2020)	Densa	Ejecución en el robot	✓
Fang et al. (2020)	Candidatos	Simulación	✓
Zhang et al. (2022)	Densa	Simulación	–
Kasaei y Kasaei (2024)	Densa*	Simulación (RL)	–
Este trabajo	Densa	Criterio geométrico y simulación	✓

1.2.2. Lanzamiento

Los primeros trabajos sobre manipulación dinámica no prensil se apoyaron principalmente en modelos del robot, del objeto y de su interacción. Lynch y Mason (1999) estudiaron cómo un manipulador con pocos grados de libertad podría producir movimientos más complejos en un objeto mediante deslizamiento, rodamiento y vuelo libre. Para ello, formularon la planificación como un problema de optimización no lineal en el que el movimiento del robot debía satisfacer las condiciones necesarias para generar la trayectoria deseada del objeto. Sus experimentos incluyeron tareas de lanzamiento y recepción con un manipulador de un grado de libertad.

El lanzamiento puede plantearse como un problema inverso. En lugar de predecir dónde caerá una pieza a partir de una velocidad conocida, se parte de la posición del objetivo y se calculan las condiciones de liberación necesarias para alcanzarlo. Si el vuelo se aproxima mediante un modelo balístico y se fijan la posición y el ángulo de liberación, puede calcularse directamente la velocidad requerida. El problema para el manipulador consiste, entonces, en generar una trayectoria que alcance esa posición a la velocidad calculada.

Sin embargo, ejecutar exactamente la solución obtenida a partir de un modelo resulta difícil. Miyashita et al. (2009, 2011) observaron que los movimientos rápidos, los cambios en el estado de contacto y las limitaciones de los actuadores dificultan obtener un modelo lo suficientemente preciso para resolver directamente el problema inverso del lanzamiento. Su propuesta combina un modelo de lanzamiento con aprendizaje iterativo para corregir el movimiento a partir de los errores observados en ejecuciones previas. Este tipo de trabajos muestra una transición temprana entre una solución puramente analítica y métodos que emplean la experiencia para compensar lo que el modelo no representa correctamente.

Los métodos basados en modelo continúan siendo utilizados. Por ejemplo, Liu y Billard (2024) estudian la incertidumbre asociada al instante de liberación y diseñan movimientos que permanecen válidos ante variaciones en dicho instante, sin requerir un modelo aprendido para cada objeto. Su trabajo muestra que, incluso utilizando un modelo balístico sencillo para el vuelo, pueden obtenerse lanzamientos precisos si el movimiento del robot se diseña considerando la incertidumbre en la liberación.

En conjunto, esta línea de trabajo plantea el lanzamiento principalmente como un problema de determinar un estado de liberación y producirlo mediante el movimiento del manipulador. El aprendizaje aparece inicialmente como una forma de corregir errores del modelo o de la ejecución.

El trabajo más cercano a esta tesis es TossingBot, propuesto por Zeng et al. (2020). El sistema realiza el ciclo completo de asimiento y lanzamiento a partir de observaciones RGB-D y combina el aprendizaje con un modelo físico sencillo. La imagen se transforma en una representación ortográfica del espacio de trabajo, y una red totalmente convolucional produce predicciones asociadas a las posibles acciones de asimiento y lanzamiento. La red se entrena mediante interacción con el entorno, utilizando el resultado de las acciones ejecutadas como señal de supervisión.

Para el lanzamiento, TossingBot utiliza una formulación denominada "física residual". En lugar de aprender directamente la velocidad necesaria desde cero, un modelo balístico proporciona una velocidad nominal de liberación a partir de la posición del objetivo. La red aprende una corrección a partir de esa estimación. Así, el modelo proporciona la estructura básica del problema, mientras que el aprendizaje se utiliza para representar los efectos que el modelo ideal no captura.

Otros trabajos han ampliado el problema inicial a condiciones distintas. Kasaei y Kasaei (2023) utilizan el aprendizaje por refuerzo para generar lanzamientos hacia objetivos fijos y móviles y consideran además la presencia de obstáculos durante el vuelo. El entrenamiento se realiza en simulación antes de transferir la política al robot físico. Este trabajo extiende el lanzamiento a escenarios más completos, aunque no centra el aprendizaje en la selección de asimiento, como ocurre en TossingBot.

En conjunto, estos métodos, resumidos en la Tabla 1.2, muestran que el aprendizaje puede utilizarse en distintas partes del problema: para corregir modelos de lanzamiento, generar directamente los parámetros de la acción o relacionar el asimiento con el resultado subsecuente. TossingBot resulta especialmente relevante porque combina estas ideas con una representación densa de las acciones y mantiene un modelo físico para obtener la solución nominal del lanzamiento.

1.2.3. Asimiento condicionado por la tarea

La mayoría de los métodos de asimiento evalúan una acción principalmente por su capacidad de asir correctamente el objeto. Sin embargo, cuando el asimiento es solo la primera parte de una tarea, este criterio puede resultar insuficiente, ya que no todos los asimientos viables facilitan igual la acción subsecuente.

Fang et al. (2020) plantean esta distinción explícitamente. Los autores señalan que gran parte de los métodos anteriores se centra en asimientos agnósticos a la tarea y proponen TOG-Net, una

Tabla 1.2: Comparación de los trabajos de lanzamiento. *Tratamiento del error*: cómo se compensa lo que la descripción balística del vuelo no captura.

Trabajo	**Tratamiento del error**
Lynch y Mason (1999)	–
Miyashita et al. (2009)	Aprendizaje iterativo en el robot
Zeng et al. (2020)	Corrección residual aprendida
Kasaei y Kasaei (2023)	Política libre de modelo (RL)
Kasaei y Kasaei (2024)	Política libre de modelo (RL)
Liu y Billard (2024)	Movimiento robusto a la liberación
Este trabajo	Corrección global

arquitectura que aprende conjuntamente dónde asir una herramienta y cómo utilizarla después. El entrenamiento se realiza mediante autosupervisión generada en simulación para tareas de barrido y martilleo.

TossingBot (Zeng et al., 2020) también relaciona explícitamente el asimiento con el resultado subsecuente. Los autores estudian políticas en las que la valoración del asimiento depende de si el lanzamiento alcanza correctamente el objetivo, y muestran que aprender únicamente a asir la pieza no produce necesariamente los mismos asimientos que aprender a completar la tarea de lanzamiento. Esta relación entre ambas acciones es una de las ideas principales retomadas en el presente trabajo.

La misma idea puede aplicarse al lanzamiento. Si existen varios asimientos capaces de mantener sujeta una pieza, no necesariamente todos producen el mismo resultado al lanzarla. Esta relación constituye uno de los puntos de partida de este trabajo. La política se entrena primero para identificar asimientos viables y, después, incorpora el resultado del lanzamiento para modificar su valoración, de modo que la selección considere también la tarea que debe realizarse después.

1.2.4. Posicionamiento de este trabajo

Los trabajos revisados, resumidos en la Tabla 1.1 y en la Tabla 1.2, presentan dos ideas especialmente relevantes para este trabajo. Por una parte, métodos como el de Domae et al. (2014) permiten evaluar de manera densa la viabilidad de distintas posiciones y orientaciones de asimiento a partir de la geometría observada y de la forma del efector final. Por otra parte, el asimiento orientado a la tarea y sistemas como TossingBot (Fang et al., 2020; Zeng et al., 2020) muestran que no basta con determinar si es posible asir una pieza, ya que la elección influye en el resultado de la manipulación subsecuente.

En TossingBot, tanto el asimiento como el lanzamiento se aprenden mediante la interacción y la exploración. Esta estrategia resulta adecuada cuando el robot puede probar una amplia variedad de acciones, pero puede resultar poco conveniente cuando el conjunto de asimientos válidos es reducido. En este trabajo, la apertura limitada del efector final deja poca tolerancia entre los dedos y los bordes de las piezas, de modo que pequeñas variaciones en la posición u orientación pueden convertir un asimiento válido en una acción fallida. Comenzar directamente

con una exploración poco informada produciría numerosos intentos que no llegan a la etapa de lanzamiento.

La brecha que se aborda se sitúa entre estas dos líneas. Los criterios geométricos permiten obtener información densa sobre dónde es posible asir una pieza, pero no indican qué asimientos serán más adecuados para una tarea subsecuente de lanzamiento. Por otro lado, el aprendizaje a partir del resultado del lanzamiento permite incorporar esa información, pero requiere ejecutar la acción para conocer su resultado.

Por esta razón, el aprendizaje se divide en dos etapas. Primero, se generan etiquetas densas directamente sobre la representación bidimensional de la escena, según un criterio geométrico basado en la forma de los dedos del efector final. Con ellas se elabora una política inicial que identifica posiciones y orientaciones de asimiento viables. Después, esta política se refina mediante lanzamientos en simulación, utilizando el resultado del lanzamiento, es decir, si la pieza alcanza o no el objetivo, para ajustar la valoración de los asimientos. De esta manera, el aprendizaje asociado al lanzamiento parte de una política que ya conoce las restricciones básicas del asimiento y puede concentrarse en distinguir, entre ellos, aquellos que producen mejores resultados en la tarea subsecuente.

1.3. Definición del problema

1.3.1. Plataforma y supuestos

El problema considerado en este trabajo consiste en asir una pieza rígida y lanzarla hacia un objetivo fijo situado fuera del alcance directo del manipulador. El sistema utiliza un robot Sawyer de siete grados de libertad equipado con un efector final de apertura paralela y recorrido reducido. La entrada corresponde a una representación ortográfica de la zona de trabajo que combina información de color y altura, a partir de la cual se seleccionan una posición y una orientación de asimiento. La Figura 1.2 resume el planteamiento del problema y los supuestos considerados.

Las piezas se encuentran apoyadas sobre una superficie plana, sin apilamientos ni oclusiones entre sí. Los objetivos permanecen fijos y se colocan a distancias alcanzables con velocidades de liberación dentro del rango de operación del robot. No se contemplan obstáculos entre el punto de liberación y el objetivo.

Las condiciones de operación consideradas son las siguientes. Las piezas son rectilíneas, de espesor uniforme de 19 mm, con segmentos de entre 14 y 18 mm de ancho y dimensiones exteriores de entre 45 y 108 mm, de modo que la región que queda entre los dedos se encuentra dentro del intervalo de apertura del efector final, de 12 a 24 mm. Los objetivos se sitúan entre 1.56 y 1.90 m de la base del manipulador, más allá de su alcance de 1.26 m, por lo que solo pueden alcanzarse mediante una fase de vuelo libre. Las velocidades de liberación son las que esas distancias requieren bajo el modelo balístico.

Una vez liberada la pieza, el vuelo se aproxima mediante un modelo balístico y se desprecia la resistencia del aire. No se modelan explícitamente otros efectos asociados a la geometría de la pieza, a su distribución de masa o a la interacción con el efector final durante la liberación. En su lugar, se considera que, dentro del dominio estudiado, su influencia puede incorporarse de

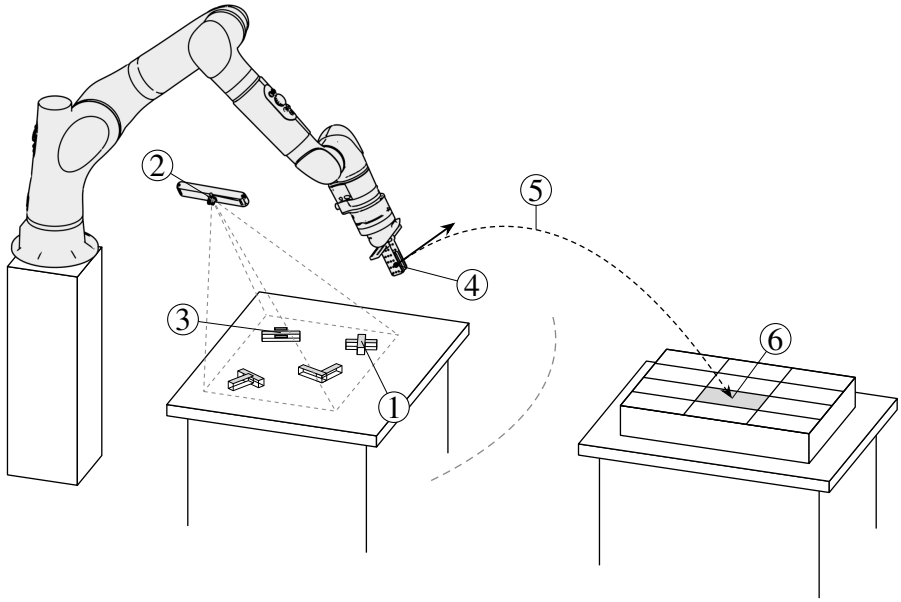


Figura 1.2: Planteamiento del problema y supuestos. ① piezas, ② cámara RGB-D, ③ asimiento, ④ velocidad de liberación, ⑤ vuelo balístico, ⑥ objetivo.

manera suficiente mediante la selección del punto y la orientación de asimiento. La velocidad nominal de liberación se calcula a partir del modelo balístico y las diferencias sistemáticas observadas durante la ejecución física se compensan mediante una corrección global de la velocidad comandada.

El entrenamiento de la política se realiza en simulación y sus parámetros permanecen fijos durante la evaluación en el robot físico. Quedan fuera del alcance de este trabajo los objetivos en movimiento, las piezas deformables, las escenas con objetos apilados, los obstáculos durante el vuelo y el aprendizaje en línea del robot.

1.3.2. Formulación

Dada una observación de la escena y la posición de un objetivo, el sistema debe seleccionar una pieza, determinar una acción de asimiento y ejecutar un lanzamiento que permita depositarla sobre dicho objetivo.

La acción de asimiento se representa mediante una posición en el espacio de trabajo y una orientación del efector final

$$\phi_g = (p_g, \psi). \tag{1.1}$$

Una vez realizado el asimiento, el lanzamiento queda determinado por las condiciones alcanzadas en el instante de la liberación. Bajo el modelo balístico utilizado en este trabajo, la posición de la pieza durante el vuelo se aproxima mediante

$$p(t) = r + v\,t + \frac{1}{2} g\,t^2, \tag{1.2}$$

donde r y v representan la posición y la velocidad de liberación y g es el vector de gravedad. Para un objetivo dado, el problema consiste en obtener condiciones de liberación que lleven la trayectoria de la pieza hasta la región ocupada por dicho objetivo.

La selección del asimiento se realiza entonces dentro del conjunto de posiciones y orientaciones disponibles en la escena, mientras que el resultado de la tarea queda determinado por el lanzamiento subsecuente. La forma en que se valoran estas acciones y se establecen las condiciones de liberación se desarrolla en el Capítulo 3.

1.4. Objetivos e hipótesis

1.4.1. Objetivo general

Desarrollar y evaluar un sistema capaz de asir y lanzar piezas rígidas hacia objetivos fijos situados fuera del alcance directo de un manipulador, en el que la selección del asimiento considere su efecto en el lanzamiento subsecuente y la política aprendida en simulación pueda transferirse al robot físico.

1.4.2. Objetivos específicos

1. Desarrollar un entorno de simulación que reproduzca las condiciones principales de la plataforma física, incluyendo el manipulador, el efector final, la escena de trabajo y la información visual utilizada por el sistema.

2. Desarrollar una representación de la escena y un procedimiento geométrico que permitan generar, de forma densa, etiquetas de viabilidad para distintas posiciones y orientaciones de asimiento.

3. Entrenar una política de asimiento a partir de la supervisión densa generada, capaz de estimar la calidad de las posibles acciones directamente en la representación de la escena.

4. Refinar la política de asimiento utilizando los resultados de lanzamientos realizados en simulación, de modo que la valoración de las acciones considere no solo la viabilidad del asimiento, sino también si el lanzamiento subsecuente alcanza el objetivo.

5. Formular e implementar un planificador de trayectorias para las diferentes etapas de la tarea, que incluya la generación de movimientos de lanzamiento que cumplan las condiciones de liberación obtenidas a partir del modelo balístico y respeten las restricciones del manipulador.

6. Integrar el sistema en el robot físico y caracterizar las diferencias entre las velocidades de liberación planificadas y ejecutadas, incorporando una corrección que permita utilizar la política aprendida sin modificar los parámetros de la red.

7. Evaluar el desempeño del sistema en piezas conocidas y desconocidas durante el entrenamiento, considerando el éxito del asimiento, del lanzamiento y de la tarea completa, y contrastar los resultados con el trabajo de referencia.

1.4.3. Hipótesis

Se plantea que, bajo las condiciones de operación definidas en la Sección 1.3.1, las variaciones que afectan la precisión del lanzamiento pueden manejarse mediante la selección del asimiento y una corrección global de la velocidad de liberación, sin requerir un modelo residual aprendido que modifique la velocidad en función de cada pieza o asimiento.

1.5. Organización de la tesis

El Capítulo 2 presenta los conceptos necesarios para seguir el desarrollo del sistema. Se introducen la representación de la pose, la cinemática y la dinámica del manipulador, los fundamentos de la planificación y optimización de trayectorias, y los elementos de aprendizaje profundo empleados en la política de asimiento.

El Capítulo 3 describe la metodología utilizada. Primero se presentan el entorno de simulación y la plataforma física, seguidos del ciclo de operación del sistema. A continuación se detallan la planificación de ambos movimientos, la representación de la escena, la arquitectura de la red de asimiento y el procedimiento utilizado para generar los datos y entrenar los modelos.

El Capítulo 4 presenta la evaluación experimental. Primero se comparan en simulación las variantes de la red de asimiento y se selecciona la utilizada en el robot físico. Después se describe el protocolo seguido con el robot físico y se analizan el seguimiento durante los lanzamientos, el comportamiento de la política de asimiento y el desempeño del sistema sobre piezas conocidas y desconocidas durante el entrenamiento. Finalmente, los resultados se contrastan con el trabajo de referencia y se discuten las principales limitaciones observadas.

El Capítulo 5 reúne las conclusiones del trabajo, revisa el cumplimiento de los objetivos y plantea posibles líneas de desarrollo para continuar con el sistema.

Capítulo 2

Fundamentos

2.1. Cinemática y dinámica de manipuladores

En esta sección se introducen los conceptos de pose y transformaciones rígidas, cinemática directa y diferencial, cinemática inversa y redundancia, y dinámica inversa. Estas herramientas se utilizan más adelante para formular los problemas de planificación del asimiento y del lanzamiento.

2.1.1. Pose, rotaciones y cuaterniones

Para describir una tarea de manipulación es necesario expresar la posición y la orientación de los objetos, así como las relaciones espaciales entre ellos. Estas cantidades se definen respecto de sistemas de coordenadas, denominados marcos de referencia. Cuando la información proviene de distintos elementos del sistema, como una cámara o un manipulador, puede encontrarse expresada inicialmente en marcos diferentes. Por ello, es necesario conocer las transformaciones que permiten relacionarlos entre sí (Lynch y Park, 2017).

En el sistema desarrollado se utilizan varios de estos marcos. La cámara RGB-D obtiene inicialmente las mediciones respecto de su propio sistema de coordenadas y después estas se transforman al marco de la base del manipulador para construir la representación del espacio de trabajo y localizar los puntos de asimiento. El planificador calcula el movimiento a partir de la pose del efector final respecto de la base del robot. De este modo, la información obtenida durante la percepción puede relacionarse con una posición y una orientación que el manipulador debe alcanzar físicamente.

La pose de un cuerpo rígido respecto de un marco de referencia queda determinada por su posición y su orientación. La posición se representa mediante un vector

$$p = \begin{bmatrix} p_x & p_y & p_z \end{bmatrix}^T \in \mathbb{R}^3, \tag{2.1}$$

que expresa el desplazamiento entre el origen del marco de referencia y el origen del marco asociado al cuerpo. La orientación describe cómo se encuentran rotados entre sí ambos marcos y puede representarse mediante una matriz de rotación $R \in SO(3)$, donde

$$SO(3) = \left\{ R \in \mathbb{R}^{3\times 3} \mid R^T R = I,\ \det(R) = 1 \right\}. \tag{2.2}$$

La posición y la orientación pueden combinarse en una única transformación rígida homogénea

$$T = \begin{bmatrix} R & p \\ 0^T & 1 \end{bmatrix}, \qquad T \in SE(3). \tag{2.3}$$

La matriz R representa la rotación entre los marcos y el vector p la traslación entre sus orígenes. Con ello, un punto x_B expresado en un marco B puede representarse en un marco A mediante

$$x_A = R_{AB}\, x_B + p_{AB}, \tag{2.4}$$

donde R_{AB} y p_{AB} son la rotación y la traslación de B respecto de A. Utilizando coordenadas homogéneas, la misma relación puede escribirse como

$$\begin{bmatrix} x_A \\ 1 \end{bmatrix} = T_{AB} \begin{bmatrix} x_B \\ 1 \end{bmatrix}. \tag{2.5}$$

Las transformaciones también pueden componerse: si se conoce la transformación de un marco B respecto de A y la de un marco C respecto de B, la transformación de C respecto de A se obtiene mediante

$$T_{AC} = T_{AB}\, T_{BC}. \tag{2.6}$$

Esta propiedad permite relacionar mediciones obtenidas en distintos sistemas de coordenadas, como ocurre al transformar los puntos observados por una cámara al marco de la base del manipulador (Lynch y Park, 2017).

Aunque una matriz de rotación describe directamente la orientación, utiliza nueve elementos para representar únicamente tres grados de libertad. Para la planificación, resulta conveniente utilizar una representación más compacta que, además, permita interpolar la orientación de forma continua a lo largo de una trayectoria. Por esta razón, en este trabajo se emplean cuaterniones unitarios.

Un cuaternión unitario

$$q = \begin{bmatrix} q_0 & q_1 & q_2 & q_3 \end{bmatrix}^T, \qquad \|q\| = 1, \tag{2.7}$$

permite representar cualquier rotación tridimensional sin singularidades de representación. La representación requiere cuatro parámetros y no es única, ya que q y $-q$ corresponden a la misma orientación (Lynch y Park, 2017).

Además de utilizarse para representar la orientación del efector, los cuaterniones permiten construir una transición continua entre dos orientaciones. Esto se emplea en la planificación de los movimientos cartesianos, en la que se define una referencia de orientación para cada punto intermedio de la trayectoria.

Dados dos cuaterniones unitarios q_{ini} y q_{fin}, la interpolación esférica lineal, o SLERP (Shoemake, 1985), se define para $s \in [0, 1]$ como

$$q(s) = \frac{\sin((1-s)\Omega)}{\sin\Omega} q_{\text{ini}} + \frac{\sin(s\Omega)}{\sin\Omega} q_{\text{fin}}, \qquad \cos\Omega = \langle q_{\text{ini}}, q_{\text{fin}} \rangle. \tag{2.8}$$

Tomando las representaciones equivalentes de los cuaterniones de modo que se recorra el arco más corto, SLERP proporciona una transición suave entre ambas orientaciones con

una velocidad angular constante. El uso de cuaterniones evita además las singularidades de representación asociadas a parametrizaciones como los ángulos de Euler. En este trabajo se utiliza para construir la referencia de orientación de los movimientos cartesianos descritos en la Sección 3.3.4.

2.1.2. Cinemática directa y diferencial

Una vez definidos los marcos de referencia, es necesario relacionar el movimiento de las articulaciones con la pose y la velocidad del efector final. En un manipulador serial, la configuración queda determinada por el vector de coordenadas articulares

$$\theta = \begin{bmatrix} \theta_0 & \theta_1 & \cdots & \theta_{n-1} \end{bmatrix}^T . \tag{2.9}$$

Cada valor de θ determina una pose del efector final respecto de la base del manipulador. Esta relación constituye la cinemática directa y puede escribirse de forma general como

$$x = f(\theta), \tag{2.10}$$

donde x contiene la posición y la orientación del efector final. Para una cadena serial, esta transformación se obtiene componiendo las transformaciones asociadas a cada articulación y eslabón,

$$T_{0n}(\theta) = T_{01}(\theta_0)\, T_{12}(\theta_1) \cdots T_{n-1,n}(\theta_{n-1}). \tag{2.11}$$

La matriz resultante proporciona directamente la posición y la orientación del efector respecto del marco de la base (Lynch y Park, 2017).

En este trabajo, la cinemática directa se utiliza durante la planificación para evaluar la pose del efector correspondiente a cada configuración propuesta por el optimizador. Esto permite, por ejemplo, imponer una trayectoria cartesiana durante el asimiento o verificar que el efector alcance la posición de liberación requerida durante el lanzamiento.

La cinemática directa relaciona las posiciones articulares y cartesianas, pero durante el lanzamiento también es necesario conocer cómo las velocidades articulares generan el movimiento del efector final. Esta relación se obtiene mediante la cinemática diferencial. Para una configuración θ, la velocidad cartesiana del efector puede expresarse como

$$\mathcal{V} = J(\theta)\, \dot{\theta}, \qquad \mathcal{V} = \begin{bmatrix} \omega \\ v \end{bmatrix}, \tag{2.12}$$

donde $J(\theta)$ es el Jacobiano geométrico del manipulador y el *twist* $\mathcal{V}$ contiene la velocidad angular ω y la velocidad lineal v del efector final.

El Jacobiano describe cómo una variación instantánea de las coordenadas articulares se transforma en un movimiento cartesiano. Su bloque lineal permite obtener la velocidad del efector final,

$$v = J_v(\theta)\, \dot{\theta}, \tag{2.13}$$

que resulta especialmente importante durante el lanzamiento. En ese caso, no basta con que el efector alcance una posición determinada: también debe hacerlo a una velocidad compatible con el estado de liberación necesario para alcanzar el objetivo.

2.1.3. Cinemática inversa y redundancia

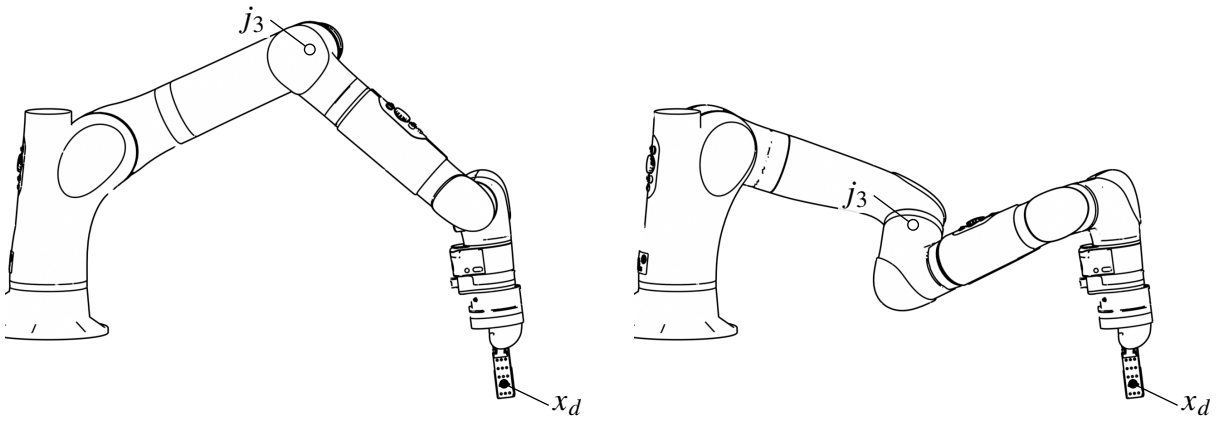
En muchas tareas de manipulación, primero se conoce la pose que debe alcanzar el efector final y es necesario determinar qué configuración articular permite alcanzarla. Por ejemplo, una vez localizada una pieza respecto de la base del robot, el punto y la orientación de asimiento definen una pose objetivo del efector. El problema consiste entonces en encontrar un vector de coordenadas articulares θ que satisfaga

$$x_d = f(\theta), \tag{2.14}$$

donde $f(\theta)$ es la cinemática directa y x_d la pose deseada. Este problema se conoce como cinemática inversa (Lynch y Park, 2017).

A diferencia de la cinemática directa, en la que cada configuración determina una única pose del efector, una misma pose cartesiana puede corresponder a más de una configuración articular. En manipuladores redundantes, como el robot Sawyer de siete grados de libertad, esta multiplicidad permite modificar la postura del brazo sin cambiar la pose del efector final. Aunque distintas configuraciones satisfagan la misma pose objetivo, no necesariamente son igualmente adecuadas para realizar una tarea, ya que algunas pueden aproximar los eslabones a la mesa, a otros objetos o a los límites articulares.

Esta multiplicidad cobra mayor importancia en los manipuladores redundantes. Si la dimensión del espacio articular es mayor que la de la tarea cartesiana, existen grados de libertad que pueden modificarse sin alterar la pose impuesta al efector final. Para una tarea de pose tridimensional, el Sawyer dispone de siete coordenadas articulares frente a los seis grados de libertad de posición y orientación del efector. Lejos de configuraciones singulares, esta redundancia permite alcanzar la misma pose mediante una familia de configuraciones distintas. La Figura 2.1 muestra dos de ellas.



(a) Codo arriba (b) Codo abajo

Figura 2.1: Dos configuraciones del manipulador Sawyer que llevan el efector final a la misma pose. Las dos se obtuvieron resolviendo la cinemática inversa contra la misma pose objetivo y coinciden en posición dentro de 0.01 mm y en orientación dentro de 0.001°; lo único que cambia entre ellas es la altura de la articulación j_3, que desciende 331 mm. Ambos paneles comparten cámara y encuadre.

La redundancia puede aprovecharse para satisfacer objetivos adicionales, como mantener el manipulador alejado de sus límites articulares, evitar configuraciones poco convenientes o conservar la continuidad respecto del movimiento anterior. Esto último es especialmente importante cuando la cinemática inversa se resuelve a lo largo de una trayectoria. Si cada pose se tratara de forma independiente, soluciones cartesianas próximas podrían asociarse a configuraciones articulares pertenecientes a ramas distintas, produciendo cambios bruscos en el movimiento aun cuando la trayectoria del efector sea continua.

Por esta razón, la planificación puede plantear la cinemática inversa como un problema de optimización en el que alcanzar la pose cartesiana constituye una restricción, mientras que la elección entre las configuraciones compatibles se realiza mediante criterios adicionales. Una forma general de expresarlo es

$$\begin{aligned} \min_{\theta} \quad & \mathcal{J}(\theta) \\ \text{s.a.} \quad & x_d = f(\theta), \\ & \theta_{\text{mín}} \leq \theta \leq \theta_{\text{máx}}, \end{aligned} \tag{2.15}$$

donde $\mathcal{J}(\theta)$ favorece las configuraciones más convenientes para la tarea.

En la planificación de trayectorias, este mismo principio puede aplicarse a toda la secuencia de configuraciones. En lugar de seleccionar independientemente una solución de cinemática inversa en cada instante, se puede favorecer la proximidad a una trayectoria articular de referencia,

$$\mathcal{J}_{\text{ref}} = \sum_{k} \left\| \theta_k - \theta_k^{\text{ref}} \right\|^2, \tag{2.16}$$

de modo que el movimiento permanezca en una región continua del espacio articular, mientras cumpla las condiciones cartesianas requeridas. Este enfoque resulta útil en el sistema desarrollado, donde el manipulador debe aproximarse a las piezas y alcanzar estados de liberación específicos sin realizar cambios abruptos entre configuraciones articulares equivalentes.

2.1.4. Dinámica inversa

La cinemática permite determinar la pose y la velocidad del efector final a partir del movimiento de las articulaciones, pero no establece qué esfuerzo deben producir estas para realizar dicho movimiento. Esta consideración cobra mayor importancia en trayectorias rápidas, donde una solución que cumpla con las restricciones de posición, velocidad y aceleración puede requerir pares articulares excesivamente elevados.

La dinámica de un manipulador rígido puede expresarse mediante

$$\tau = M(\theta)\,\ddot{\theta} + c(\theta, \dot{\theta}) + g(\theta), \tag{2.17}$$

donde $M(\theta)$ es la matriz de inercia, $c(\theta, \dot{\theta})$ agrupa los efectos de Coriolis y centrípetos, $g(\theta)$ representa la contribución de la gravedad y τ contiene los pares articulares (Lynch y Park, 2017).

Cuando se conocen la posición, la velocidad y la aceleración articulares, esta relación permite calcular el par necesario para producir el movimiento,

$$\tau = f_\tau(\theta, \dot{\theta}, \ddot{\theta}), \tag{2.18}$$

lo que constituye el problema de la dinámica inversa. En contraste, la dinámica directa determina la aceleración resultante a partir de los pares aplicados y del estado del manipulador.

En la planificación de movimiento, la dinámica inversa permite comprobar si una trayectoria requiere esfuerzos compatibles con la capacidad de actuación del robot. Para una trayectoria discretizada, el par puede evaluarse en cada instante y restringirse mediante

$$|\tau_k| \leq \tau_{\text{máx}}. \tag{2.19}$$

Así, además de satisfacer las condiciones cinemáticas de la tarea, el planificador puede evitar soluciones que requieran pares superiores a los permitidos por los actuadores. Esta restricción resulta especialmente relevante en movimientos rápidos, como el lanzamiento, en los que las aceleraciones necesarias pueden exigir más de los actuadores.

2.2. Planificación y optimización de trayectorias

La planificación de movimiento consiste en determinar cómo debe moverse el manipulador desde un estado inicial hasta cumplir una tarea determinada, respetando al mismo tiempo las restricciones impuestas por el robot y por el entorno. Dependiendo del problema, esto puede resolverse mediante trayectorias predefinidas entre configuraciones conocidas o mediante problemas de optimización en los que la trayectoria completa se resuelve como un solo problema.

En esta sección se presentan las trayectorias punto a punto utilizadas como referencia, la formulación general de control óptimo, la transcripción directa empleada para convertir el problema continuo en un programa no lineal y el procedimiento de solución numérica utilizado en el planificador.

2.2.1. Trayectorias punto a punto

Una de las formas más simples de planificar el movimiento de un manipulador consiste en especificar una configuración inicial y una final, sin imponer una trayectoria particular al efector entre ambas. Este tipo de movimiento resulta útil cuando interesa trasladar el robot entre dos configuraciones conocidas manteniendo continuidad en la posición, la velocidad y la aceleración articulares.

Sea θ_{ini} la configuración inicial y θ_{fin} la configuración final. La trayectoria puede construirse mediante una función escalar de tiempo $s(t)$, con $s(0) = 0$ y $s(t_f) = 1$,

$$\theta(t) = \theta_{\text{ini}} + s(t)\,(\theta_{\text{fin}} - \theta_{\text{ini}})\,. \tag{2.20}$$

Al elegir un polinomio de quinto orden con velocidad y aceleración nulas en ambos extremos para $s(t)$:

$$s(0) = 0, \qquad s(t_f) = 1, \qquad \dot{s}(0) = \dot{s}(t_f) = 0, \qquad \ddot{s}(0) = \ddot{s}(t_f) = 0, \tag{2.21}$$

se obtiene la parametrización

$$s(t) = 10\left(\frac{t}{t_f}\right)^3 - 15\left(\frac{t}{t_f}\right)^4 + 6\left(\frac{t}{t_f}\right)^5. \tag{2.22}$$

Este perfil, comúnmente denominado de mínimo *jerk*, produce una trayectoria suave en la que posición, velocidad y aceleración permanecen continuas (Lynch y Park, 2017). Sus derivadas temporales determinan las velocidades y aceleraciones articulares,

$$\dot{\theta}(t) = \dot{s}(t)\,(\theta_{\text{fin}} - \theta_{\text{ini}})\,, \qquad \ddot{\theta}(t) = \ddot{s}(t)\,(\theta_{\text{fin}} - \theta_{\text{ini}})\,. \tag{2.23}$$

Para esta parametrización, los valores máximos de las funciones de escalamiento son (Lynch y Park, 2017)

$$\dot{s}_{\text{máx}} = \frac{1.875}{t_f}, \qquad |\ddot{s}|_{\text{máx}} = \frac{5.77}{t_f^2}. \tag{2.24}$$

Por lo tanto, para una articulación i, con desplazamiento $\Delta\theta_i = \theta_{i,\text{fin}} - \theta_{i,\text{ini}}$, el tiempo de movimiento debe satisfacer

$$t_f \geq \frac{1.875\,|\Delta\theta_i|}{\dot{\theta}_{i_{\text{máx}}}} \tag{2.25}$$

para respetar su límite de velocidad, y

$$t_f \geq \sqrt{\frac{5.77\,|\Delta\theta_i|}{\ddot{\theta}_{i_{\text{máx}}}}} \tag{2.26}$$

para respetar su límite de aceleración. En un manipulador con varias articulaciones, la duración mínima que satisface estas condiciones se obtiene tomando el mayor valor requerido entre todas ellas.

2.2.2. El problema de control óptimo

Las trayectorias punto a punto permiten definir movimientos suaves entre dos configuraciones conocidas, pero resultan insuficientes cuando el movimiento debe satisfacer condiciones adicionales durante su ejecución o en el estado final. Por ejemplo, en el lanzamiento, no basta con llevar el manipulador de una configuración a otra: el efector final debe alcanzar un estado de liberación determinado mientras se respetan los límites del robot a lo largo de toda la trayectoria. Este tipo de problemas puede formularse como un problema de control óptimo.

En su forma general, se busca determinar cómo cambian en el tiempo un estado $z(t)$ y una entrada de control $u(t)$ que minimicen una función de costo (Kelly, 2017),

$$\mathcal{J} = \Phi\big(z(t_f), t_f\big) + \int_{t_0}^{t_f} L(z(t), u(t), t)\; dt, \tag{2.27}$$

donde Φ representa un costo asociado al estado final y L penaliza propiedades de la trayectoria a lo largo del intervalo.

El estado cambia según las ecuaciones del sistema,

$$\dot{z}(t) = F(z(t), u(t), t)\,, \tag{2.28}$$

y puede estar sujeta a restricciones que deben cumplirse durante el movimiento,

$$h(z(t), u(t), t) \leq 0, \tag{2.29}$$

así como a condiciones impuestas en los extremos de la trayectoria,

$$b\big(z(t_0), z(t_f), t_0, t_f\big) = 0. \tag{2.30}$$

Para la planificación del manipulador puede utilizarse como estado y como entrada

$$z = \begin{bmatrix}\theta \\ \dot{\theta}\end{bmatrix}, \qquad u = \ddot{\theta}, \qquad \dot{z} = \begin{bmatrix}\dot{\theta} \\ \ddot{\theta}\end{bmatrix}. \tag{2.31}$$

Esta formulación permite expresar dentro de un mismo problema tanto las restricciones articulares como las condiciones cartesianas de la tarea. Mediante las relaciones cinemáticas de la Sección 2.1, las condiciones finales pueden imponerse directamente sobre la pose, mediante (2.10), o sobre la velocidad del efector, mediante (2.12), sin necesidad de especificar previamente una configuración articular final única.

2.2.3. Transcripción directa

El problema anterior está definido sobre funciones continuas del tiempo y, por tanto, no puede resolverse directamente como un problema de optimización con un número finito de variables. La transcripción directa aproxima la trayectoria mediante sus valores en un conjunto de nodos y convierte el problema de control óptimo en un programa no lineal (Kelly, 2017), como se ilustra en la Figura 2.2.

El intervalo de movimiento se divide en N segmentos. En cada nodo se introducen como variables de decisión el estado y la entrada,

$$z_k, \qquad u_k, \qquad k = 0, 1, \ldots, N. \tag{2.32}$$

Las ecuaciones diferenciales del sistema se sustituyen entonces por restricciones algebraicas que relacionan nodos consecutivos. En el lanzamiento se utiliza la regla trapezoidal; en los movimientos articulares y cartesianos, la de Euler, en la que el cambio se aproxima con la derivada en el nodo inicial. La regla trapezoidal aproxima el cambio entre dos nodos mediante el promedio de la derivada en ambos extremos,

$$z_{k+1} = z_k + \frac{\Delta t}{2}\left[F(z_k, u_k) + F(z_{k+1}, u_{k+1})\right]. \tag{2.33}$$

Para el estado articular definido anteriormente, esta relación da lugar a

$$\begin{aligned}\theta_{k+1} &= \theta_k + \frac{\Delta t}{2}\left(\dot{\theta}_k + \dot{\theta}_{k+1}\right), \\ \dot{\theta}_{k+1} &= \dot{\theta}_k + \frac{\Delta t}{2}\left(\ddot{\theta}_k + \ddot{\theta}_{k+1}\right).\end{aligned} \tag{2.34}$$

Estas restricciones obligan a que las posiciones, velocidades y aceleraciones de nodos consecutivos sean consistentes con la dinámica del sistema.

Las restricciones de trayectoria se evalúan también sobre los nodos,

$$h(z_k, u_k) \leq 0, \tag{2.35}$$

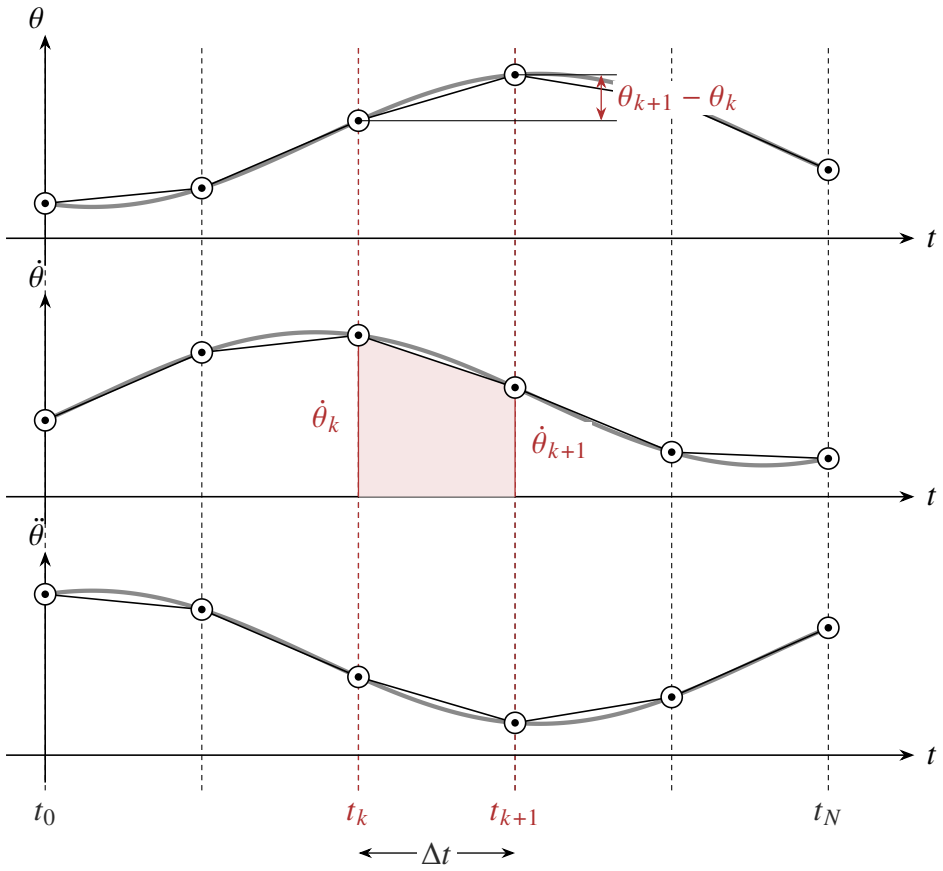


Figura 2.2: Transcripción directa. En gris, la solución continua; en negro, los valores en los nodos, separados Δt, que el problema de optimización manipula. El área sombreada es la aproximación trapezoidal de (2.34) y equivale al incremento de θ entre t_k y t_{k+1} (Kelly, 2017).

mientras que las condiciones iniciales y finales se aplican sobre los extremos de la discretización. La función de costo continua se aproxima de forma correspondiente sobre los nodos, de modo que el problema completo queda convertido en un programa no lineal de la forma

$$\begin{aligned} \min_{z_0,u_0,\ldots,z_N,u_N} \quad & \mathcal{J}(z_0,u_0,\ldots,z_N,u_N) \\ \text{s.a.} \quad & c(z_0,u_0,\ldots,z_N,u_N) = 0, \\ & h(z_k,u_k) \leq 0, \qquad k = 0,\ldots,N; \end{aligned} \tag{2.36}$$

donde la minimización incluye también la duración t_f, cuando esta es variable; y c contiene, las restricciones introducidas por la discretización, entre otras.

La transcripción directa permite tratar conjuntamente la trayectoria completa: las configuraciones articulares, sus derivadas y, cuando corresponde, otras variables como la duración del movimiento se determinan a la vez, ligadas entre sí, mientras se satisfacen las restricciones de la tarea.

2.2.4. Solución numérica

Después de la transcripción, el problema de planificación queda expresado como un programa no lineal con variables continuas y restricciones de igualdad y desigualdad. En general, este tipo de problemas puede ser no convexo, por lo que la solución obtenida depende de la inicialización y corresponde a un óptimo local (Kelly, 2017).

Una buena estimación inicial puede reducir el tiempo de solución y ayudar al optimizador a converger hacia una trayectoria físicamente razonable. Por esta razón, cuando se resuelven varios movimientos relacionados puede reutilizarse una solución previa, o una trayectoria cercana, como punto inicial del siguiente problema.

En este trabajo, el programa no lineal se formula en CasADi (Andersson et al., 2019), que permite representar simbólicamente la función de costo y las restricciones, así como obtener sus derivadas mediante diferenciación automática. El problema resultante se resuelve con IPOPT (Wächter y Biegler, 2006), un método de punto interior diseñado para problemas de optimización no lineal de gran escala con restricciones, que determina en conjunto las variables de decisión que definen la trayectoria.

2.3. Redes neuronales y aprendizaje profundo

Las redes neuronales son modelos paramétricos que permiten aproximar relaciones entre una entrada y una salida a partir de ejemplos. Su funcionamiento está basado en la composición de múltiples transformaciones, de modo que cada capa recibe una representación de la información, la transforma y entrega el resultado a la siguiente. Para una capa l, esta operación puede expresarse como

$$a^{(l)} = \varphi\left(W^{(l)}a^{(l-1)} + b^{(l)}\right), \tag{2.37}$$

donde $a^{(l-1)}$ representa la entrada de la capa, $W^{(l)}$ y $b^{(l)}$ corresponden a sus parámetros y $\varphi(\cdot)$ es una función de activación no lineal.

Al encadenar varias capas, la red construye representaciones sucesivas de la entrada. Las primeras transformaciones operan directamente sobre los datos originales, mientras que las posteriores combinan la información obtenida en etapas anteriores para producir la salida final del modelo.

Los parámetros de la red no se fijan manualmente, sino que se ajustan durante el entrenamiento. Para ello se utiliza un conjunto de ejemplos en los que cada entrada se encuentra asociada con una salida esperada. La diferencia entre la predicción de la red y dicha salida se mide mediante una función de pérdida. A partir de esta medida, los parámetros se modifican iterativamente para reducir el error sobre los datos utilizados durante el entrenamiento.

2.3.1. Redes neuronales convolucionales

Cuando la entrada posee una estructura espacial, como ocurre con una imagen, pueden utilizarse redes neuronales convolucionales (LeCun et al., 1998). A diferencia de una capa completamente conectada, una capa convolucional aplica filtros sobre regiones locales de la entrada y comparte sus parámetros entre diferentes posiciones.

Para una entrada X, la salida asociada con el canal k puede expresarse de forma general como

$$Y_k = \varphi\left(\sum_c K_{k,c} * X_c + b_k\right), \tag{2.38}$$

donde $*$ representa la operación de convolución, c identifica los canales de entrada, $K_{k,c}$ corresponde al filtro aplicado y b_k es el término de sesgo del canal de salida.

La aplicación sucesiva de estas operaciones permite combinar información de regiones progresivamente mayores de la entrada. Las primeras capas pueden representar características locales, mientras que las capas posteriores combinan estas respuestas para obtener representaciones de mayor complejidad. Al mismo tiempo, la estructura espacial de la información se mantiene a lo largo de la red.

Esta organización espacial constituye la base de las arquitecturas de predicción densa descritas en la siguiente sección.

2.3.2. Predicción densa

En una tarea de clasificación convencional, una red produce una única salida asociada con toda la entrada. En otros problemas resulta necesario obtener una predicción para cada posición de la observación. Este tipo de salida se conoce como predicción densa.

Las redes totalmente convolucionales permiten conservar la organización espacial de la información y producir mapas de salida relacionados con las posiciones de la entrada. Para una observación de dimensiones $U \times V$, una salida densa puede representarse como

$$Q \in \mathbb{R}^{U \times V}, \tag{2.39}$$

donde cada elemento Q_{uv} contiene la predicción correspondiente a la posición (u, v).

Cuando la red produce varias cantidades para cada posición, la salida puede extenderse a varios canales,

$$Q \in \mathbb{R}^{C \times U \times V}, \tag{2.40}$$

donde C representa el número de valores predichos en cada posición.

Esta formulación mantiene una correspondencia espacial entre la entrada y la salida, por lo que resulta adecuada para problemas en los que la decisión depende de la localización dentro de la observación.

2.3.3. Aprendizaje supervisado

En aprendizaje supervisado, cada entrada utilizada durante el entrenamiento se encuentra asociada con una etiqueta que representa la salida deseada. A partir de estas etiquetas se define una función de pérdida que mide la diferencia entre la predicción de la red y el valor esperado.

Para una salida binaria puede utilizarse la entropía cruzada binaria

$$\ell = -\left[y \log(\hat{y}) + (1 - y) \log(1 - \hat{y})\right], \tag{2.41}$$

donde y representa la etiqueta y $\hat{y}$ la probabilidad predicha por la red.

La salida previa a la conversión en probabilidad se denomina *logit*. Si z representa este valor, la probabilidad correspondiente se obtiene mediante la función sigmoide

$$\hat{y} = \sigma(z) = \frac{1}{1 + e^{-z}}. \tag{2.42}$$

En la presente tesis, durante el entrenamiento, el gradiente de la función de pérdida respecto de los parámetros de la red se obtiene mediante *backpropagation*. A partir de esta información, un optimizador actualiza los parámetros con el objetivo de reducir la pérdida.

2.3.4. Arquitectura codificador–decodificador

En el sistema desarrollado, la predicción densa requiere obtener una salida con la misma resolución espacial que la entrada. Una forma habitual de construir este tipo de redes es mediante una arquitectura codificador–decodificador (Long et al., 2015). El codificador reduce progresivamente la resolución espacial mediante operaciones de submuestreo, mientras aumenta el número de canales utilizados para representar las características de la entrada. Como resultado, las capas más profundas integran información procedente de regiones cada vez mayores de la imagen.

El decodificador realiza el proceso inverso y recupera progresivamente la resolución necesaria para generar una predicción asociada con cada posición de la entrada. Sin embargo, la reducción espacial realizada por el codificador implica una pérdida de información sobre la localización precisa de las características. Si la reconstrucción utiliza únicamente la representación de menor resolución, la interpolación permite aumentar nuevamente el tamaño de la salida, pero no recuperar por sí sola la información espacial perdida durante el submuestreo.

La arquitectura U-Net propuesta por Ronneberger et al. (2015) incorpora conexiones entre niveles de igual resolución del codificador y el decodificador, como se muestra en la Figura 2.3. En cada nivel, las características provenientes de una representación de menor resolución se combinan con las obtenidas por el codificador antes del submuestreo. Si $e^{(l)}$ representa las características del codificador en el nivel l y $d^{(l)}$ las del decodificador, esta operación puede expresarse como

$$d^{(l)} = g_l \left(\left[\mathcal{U}\left(d^{(l+1)}\right),\ e^{(l)} \right] \right), \tag{2.43}$$

donde $\mathcal{U}$ representa el aumento de resolución, $[\cdot, \cdot]$ la concatenación a lo largo de los canales y g_l las operaciones convolucionales realizadas en ese nivel.

Estas conexiones, conocidas como conexiones de salto, permiten que el decodificador combine la información obtenida en las capas profundas con características que conservan una mayor resolución espacial. De este modo, la red puede incorporar información de contexto sin depender únicamente de la representación obtenida después de varias etapas de submuestreo. La Figura 2.4 ilustra (2.43) para un nivel l; la arquitectura concreta utilizada en este trabajo se muestra en la siguiente sección.

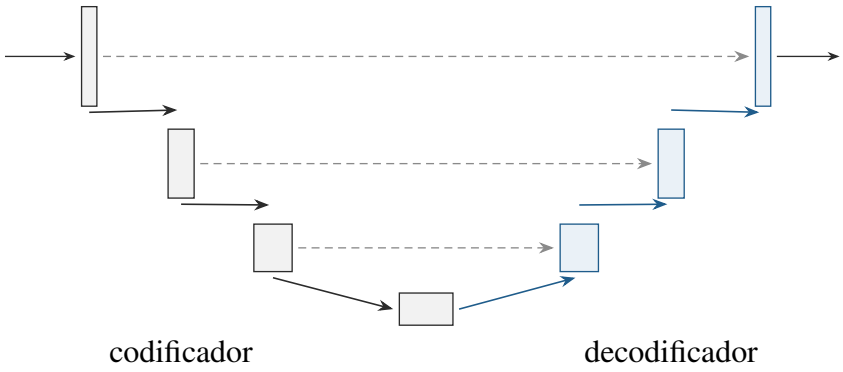


Figura 2.3: Estructura general de la U-Net. El codificador reduce la resolución espacial y aumenta el número de canales; el decodificador la recupera. Las líneas discontinuas son las conexiones de salto entre niveles de igual resolución.

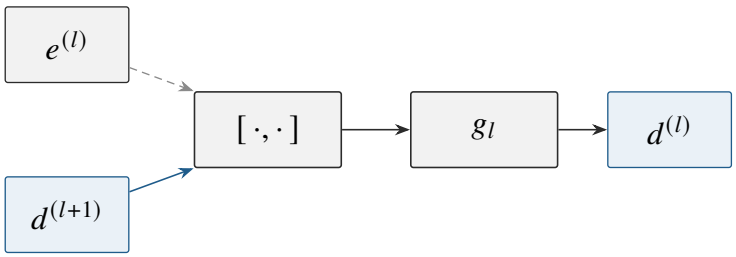


Figura 2.4: Conexión de salto en el nivel l de la U-Net, según (2.43).

Capítulo 3

Metodología

El sistema desarrollado en este trabajo toma como referencia TossingBot (Zeng et al., 2020). De TossingBot se conservan la representación del entorno y de las acciones. Sin embargo, las características de la plataforma utilizada hicieron necesarias varias modificaciones. La apertura reducida del efector final, los errores de seguimiento del Sawyer y el tiempo requerido para recopilar intentos en el robot físico llevaron a modificar el espacio de acciones, la planificación del movimiento y la estrategia de entrenamiento.

La metodología comienza con los dos entornos utilizados durante el desarrollo, el simulador y la plataforma física, y con la relación que se mantuvo entre ambos. Después se describe el ciclo completo de asimiento y lanzamiento junto con las dos primitivas de movimiento que lo componen. Las siguientes secciones presentan la planificación del movimiento, la representación de la escena que recibe la red y el método de selección del asimiento. El capítulo termina con el entrenamiento de los modelos; su evaluación en simulación y los resultados en el robot físico se presentan en el Capítulo 4.

3.1. Entorno de simulación y plataforma física

El entrenamiento de los modelos empleados en este trabajo requiere varios miles de escenas distintas. Obtenerlas directamente en el robot físico resulta poco práctico, ya que cada intento implica ejecutar la tarea completa, recuperar la pieza y restablecer la escena antes de continuar. Por esta razón, los datos utilizados para el entrenamiento se generan en simulación, en la que estas operaciones pueden automatizarse y las etiquetas se obtienen directamente del estado del entorno.

La plataforma física se utiliza después para evaluar el método bajo condiciones que no se reproducen con exactitud en el simulador, entre ellas los errores de seguimiento, la elasticidad de las articulaciones y las variaciones introducidas por el contacto entre el efector final y las piezas.

Este reparto de funciones entre el simulador y el robot requiere mantener las mismas primitivas de asimiento y lanzamiento en ambos entornos. Para ello se conservaron la disposición y las dimensiones del área de trabajo, el procedimiento con el que se construye el mapa de alturas que recibe la red (Sección 3.4) y la parametrización del asimiento y del lanzamiento (Sección 3.2.3).

No se buscó reproducir con exactitud toda la dinámica del Sawyer, sino mantener la compatibilidad necesaria para ejecutar en el robot las decisiones aprendidas en simulación. Las siguientes subsecciones describen ambos entornos y las diferencias que persisten entre ellos.

3.1.1. Entorno de simulación

Para la fase de entrenamiento del modelo se utilizó MuJoCo (Todorov et al., 2012), un motor de física de código abierto especializado en la simulación precisa de cuerpos articulados y de dinámicas de contacto complejas. La elección de este simulador se basó principalmente en los requisitos de la tarea de asimiento. A diferencia de los modelos basados en contactos rígidos, MuJoCo implementa una formulación de optimización convexa que modela contactos suaves y estables; esta característica reduce las inestabilidades numéricas durante la interacción del efector final del robot con las piezas. Asimismo, el carácter determinista del motor de física permite la ejecución reproducible de las trayectorias de manipulación, lo que facilita la recopilación de datos y el entrenamiento del modelo.

La escena contiene una mesa de recogida, situada 23 cm por debajo de la base del manipulador, sobre la cual se disponen las piezas. El objetivo de lanzamiento es una plataforma móvil ubicada fuera del alcance del manipulador; durante el refinamiento, su posición se muestrea uniformemente dentro de la región mostrada en la Figura 3.1.

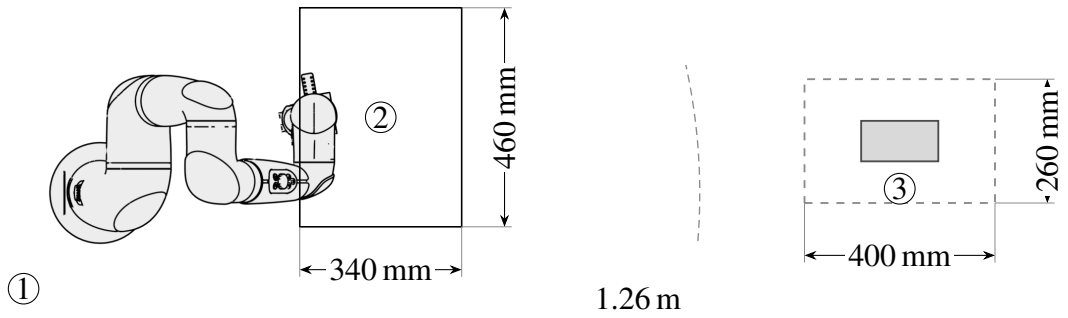


Figura 3.1: Escena de simulación, vista en planta. ① base del manipulador; ② mesa de recogida, dentro del alcance del manipulador (arco discontinuo, 1.26 m); ③ región dentro de la cual se muestrea la posición del objetivo de lanzamiento en cada episodio de refinamiento (rectángulo discontinuo) y una posición de ejemplo (rectángulo sombreado).

Además, las escena incluye, un modelo del efector final y una cámara RGB-D simulada, cuyos parámetros intrínsecos se ajustaron a los de la cámara real descrita en la Sección 3.1.2.

Para generar las escenas de entrenamiento se utilizaron 60 piezas rectilíneas, formadas por segmentos de sección transversal rectangular unidos por ángulos rectos. Sus dimensiones variaron tanto en la sección transversal como en la longitud de los segmentos. El catálogo completo se presenta en el Apéndice A.

Sobre este entorno se construyeron las observaciones de percepción, las etiquetas de asimiento y los episodios de lanzamiento que se utilizaron para entrenar el modelo, como se describe más adelante.

3.1.2. Plataforma física

La plataforma física utilizada para evaluar el modelo entrenado mediante simulación es el robot manipulador Sawyer (Rethink Robotics, 2018). Se trata de un robot serial de siete grados de libertad y un alcance máximo de 1.26 m. Ambas características se tuvieron en cuenta en el diseño de la tarea. Por una parte, la matriz de objetivos se colocó fuera del alcance cinemático del manipulador, de modo que las piezas tuvieran que alcanzarla mediante una fase de vuelo libre. Por otra parte, los siete grados de libertad hacen que el manipulador sea redundante para la tarea, por lo que fue necesario definir qué articulaciones participarían directamente en el lanzamiento.

El movimiento de lanzamiento se realiza sobre un plano vertical orientado hacia el objetivo. Antes de iniciar el movimiento, el robot se alinea con dicho plano, lo que permite emplear un mecanismo planar equivalente de tres grados de libertad. La selección de las articulaciones y la construcción de este modelo se detallan en la Sección 3.3, siguiendo la convención de numeración de la Figura 3.2.

El modelo utilizado en la simulación considera articulaciones rígidas. Esta es una simplificación respecto del Sawyer físico, cuyas articulaciones emplean actuadores elásticos en serie (Pratt y Williamson, 1995). En estos actuadores, un resorte de torsión separa el motor del eslabón, por lo que ambos pueden adoptar posiciones distintas cuando el robot se mueve bajo carga. La diferencia se vuelve más evidente durante movimientos rápidos, como el lanzamiento. Este comportamiento no se incluyó en el simulador porque no se contó con un modelo identificado de las articulaciones del robot.

El robot cuenta con un efector final Rethink Robotics ClickSmart Pneumatic Small Gripper, con una carrera total de 12 mm; se configuró con una apertura mínima de 12 mm y máxima de 24 mm, como se muestra en la Figura 3.3.

Además, se utilizaron dos cámaras para la parte de percepción del sistema. La cámara encargada de proveer la imagen de entrada al sistema es una Asus Xtion Pro RGB-D, con una resolución de 640×480 píxeles, cuya nube de puntos alimenta el mapa de alturas, que representa las piezas sobre la mesa de asimiento. De forma independiente, se utiliza una cámara cenital de 1280×960 píxeles para localizar la matriz de objetivos y registrar el resultado de los lanzamientos. La calibración de ambas cámaras se explica con más detalle en el Apéndice C.

El montaje se completa con dos mesas dispuestas a la misma altura. En la primera se colocan las piezas que el sistema debe recoger y lanzar, y en la segunda se coloca la matriz de objetivos, situada fuera del alcance del manipulador; sus dimensiones se detallan en la Sección 4.1.2.

3.1.3. Correspondencia entre robot y simulación

Existen diferencias y similitudes entre el modelo utilizado en la simulación y el robot físico. Por un lado, se trató de mantener el efector final lo más parecido posible a su configuración en la simulación; se utilizaron las mismas dimensiones, la misma carrera y una modelo geométrico

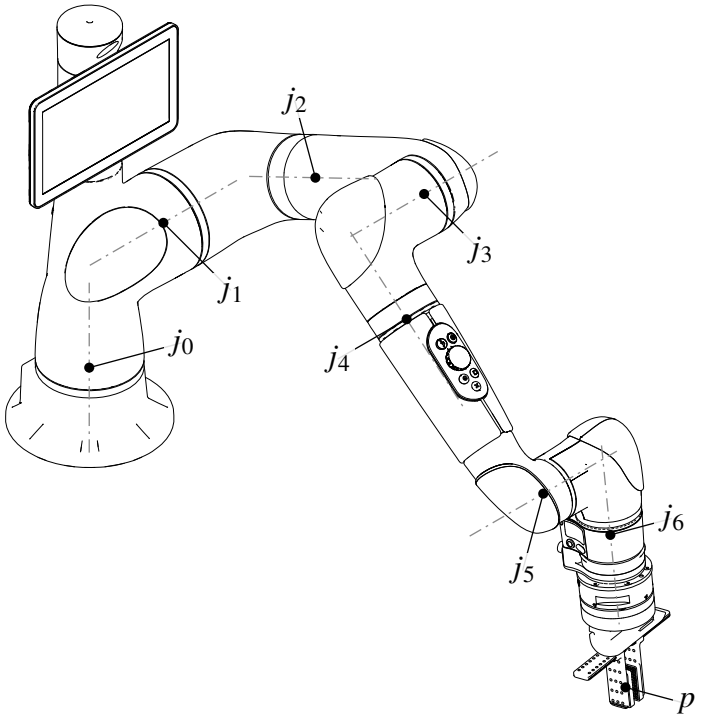


Figura 3.2: Convención de numeración de las articulaciones del manipulador Sawyer y eje de rotación de cada una. El dibujo se generó a partir del mismo modelo geométrico que emplean el simulador y el planificador.

de malla lo más preciso posible para el contacto. En cuanto a las trayectorias, tanto el robot físico como el simulado utilizan el mismo planificador; la diferencia radica en el control. En el simulador el control es ideal: se impone exactamente la trayectoria calculada en cada iteración. En el robot físico, es responsabilidad del controlador interno seguir la trayectoria deseada lo más de cerca posible. En resumen, en el simulador el robot sigue las trayectorias de manera perfecta, mientras que en el robot físico no es posible debido a las características mencionadas anteriormente (Pratt y Williamson, 1995). En cuanto a las piezas, en la simulación todas tuvieron densidad uniforme y acabados regulares; en las piezas físicas, el proceso de fabricación introduce distribuciones de masa no uniformes al estar unidas por clavos metálicos, además de presentar un acabado más irregular debido a que los cortes no fueron perfectamente limpios. En cuanto a la actuación del efector final, en el simulador no hay retrasos, mientras que en el robot físico sí hay retrasos variables.

3.1.4. Arquitectura de control, comunicación y adquisición de datos

La aplicación de control se ejecuta en una computadora externa, con procesador Intel Core Ultra 9 185H, 16 GB de memoria y una tarjeta gráfica NVIDIA GeForce RTX 4070 de 8 GB,

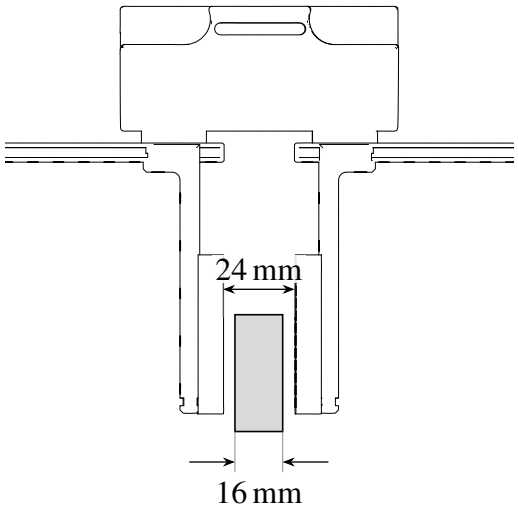


Figura 3.3: Efector final en su apertura máxima, con la sección transversal de una pieza de 16 mm entre los dedos del efector final. La apertura mínima, 12 mm, es menor que la sección transversal de la pieza, de modo que el cierre ocurra sobre ella.

e integra la percepción, la inferencia de las redes neuronales y la planificación del movimiento. La comunicación con el Sawyer se realiza mediante un servidor alojado en un contenedor Docker que ejecuta una versión de *Robot Operating System* (ROS) compatible con el robot. La aplicación envía los comandos y recibe el estado del manipulador mediante ZeroMQ; dentro del contenedor, el servidor publica y consulta la información correspondiente a través de ROS.

3.2. Visión general del sistema

Esta sección describe la organización general del sistema y la secuencia seguida en cada intento. Primero se presenta la arquitectura de comunicación entre la aplicación principal y el robot. Después se describe el ciclo que transforma la observación de la mesa en una acción de asimiento y, si esta tiene éxito, en una trayectoria de lanzamiento. Los detalles de la percepción, la planificación y el entrenamiento se presentan en las secciones posteriores.

3.2.1. Arquitectura y flujo de datos

La forma original de utilizar el manipulador Sawyer es mediante InteraSDK. Rethink Robotics dejó de operar en 2018 y, por lo tanto, ya no existe soporte oficial para su software. La plataforma depende de versiones obsoletas de Ubuntu y ROS1, cuya integración en el mismo entorno utilizado para la percepción y el aprendizaje limitaría el uso de hardware y software modernos, como las tarjetas gráficas más recientes, las versiones actuales de PyTorch y otras bibliotecas. Por esta razón, se separó la lógica del proceso principal de la comunicación con el robot. La versión de ROS compatible con el Sawyer se ejecuta en un contenedor de Docker.

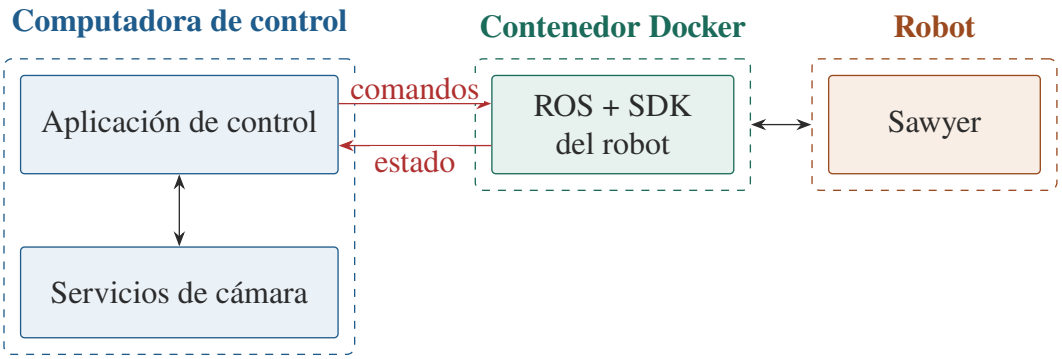


Figura 3.4: Arquitectura de comunicación entre la aplicación principal y el contenedor de control. La aplicación reúne la percepción, la inferencia y la planificación; el contenedor aísla la pila de ROS, de modo que la aplicación solo intercambia mensajes con él y no depende de ROS.

La aplicación de control lee los datos publicados por los servicios de ambas cámaras. La cámara RGB-D publica la nube de puntos utilizada como entrada del sistema de percepción, según se describe en la Sección 3.4, mientras que la cámara cenital proporciona el video utilizado para localizar los objetivos y evaluar los resultados de los lanzamientos.

La comunicación entre la aplicación principal y el contenedor se realiza mediante ZeroMQ, como se muestra en la Figura 3.4. La computadora de control calcula las trayectorias que el robot debe seguir y envía los comandos, mientras que el contenedor se encarga de publicarlos en ROS y de leer el estado del robot para enviarlo de vuelta a la aplicación de control. Dentro del contenedor, un servidor ZeroMQ actúa como intermediario entre la aplicación principal y ROS.

Las trayectorias de movimiento generadas contienen referencias de posición, velocidad y aceleración articular, calculadas para ejecutarse a una frecuencia de 100 Hz. El controlador envía estas referencias al robot, punto por punto, y también coordina la apertura del efector final en el instante definido para liberar la pieza.

Todos los datos enviados y recibidos por el robot se registran para analizar el comportamiento del sistema físico y los errores de seguimiento durante la fase de lanzamiento.

3.2.2. Ciclo de operación

A continuación se presenta el flujo de trabajo de cada ciclo del sistema, resumido en la Figura 3.5. El ciclo comienza con la captura de la nube de puntos de la cámara RGB-D, que representa la superficie de la mesa y de las piezas. La nube se transforma en un sistema de referencia cuyo eje z es paralelo al vector de gravedad y, a partir de ella, se construye la observación que se utiliza como entrada de la red. La red produce una medida de confianza para cada posición y orientación posible del efector, de las cuales se selecciona la de mayor valor. La pose de asimiento resultante se utiliza para calcular la trayectoria de aproximación que sigue el robot antes de cerrar el efector final sobre la pieza.

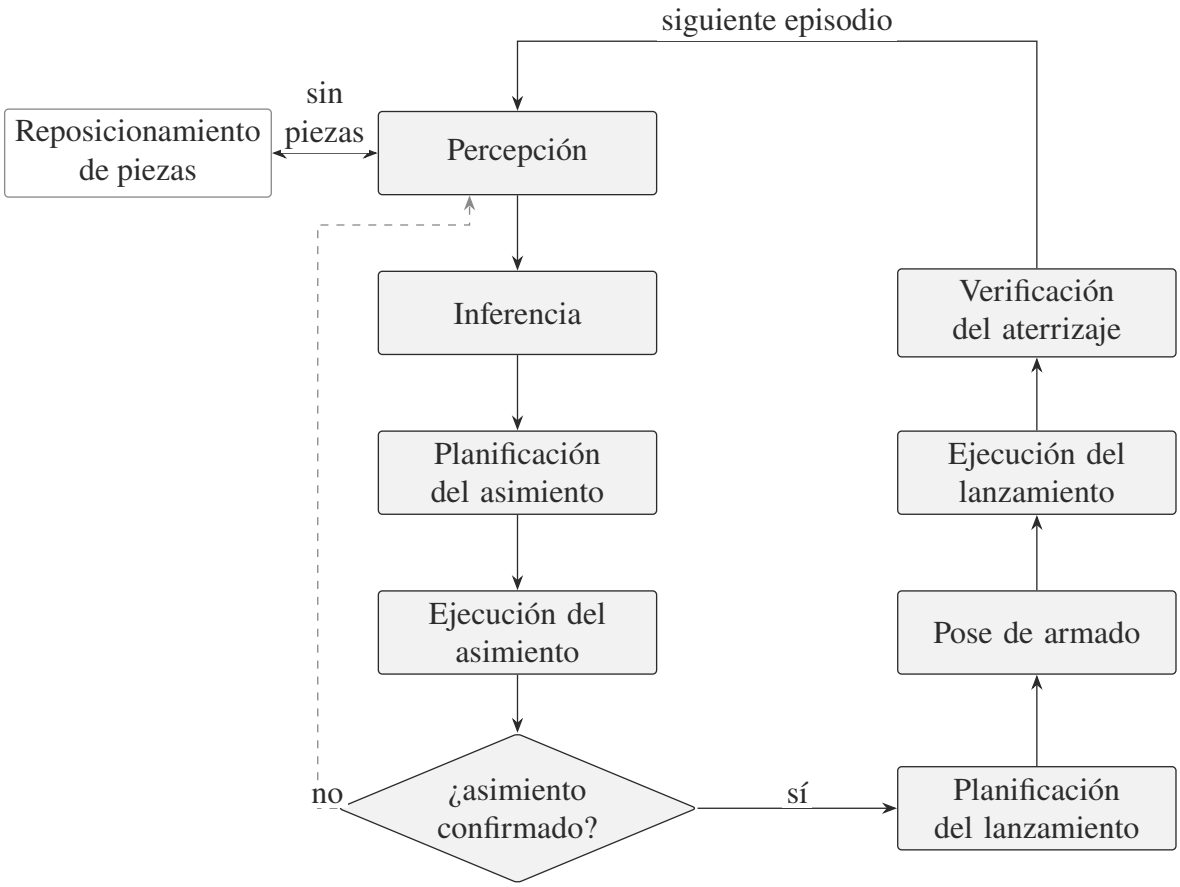


Figura 3.5: Ciclo de operación del sistema. La columna izquierda corresponde al asimiento y la derecha al lanzamiento; las flechas discontinuas son las ramas que no avanzan al lanzamiento.

Después, se comprueba el resultado del asimiento. Esto depende de la plataforma: en el simulador solo se confirma la posición de la pieza; en el robot físico se comprueba la diferencia en el total de píxeles que no son de fondo entre dos tomas del mapa de alturas. En caso de que el asimiento sea exitoso, se procede al lanzamiento; de lo contrario, se repite el ciclo de percepción e inferencia.

La fase de lanzamiento forma parte del objetivo asignado al episodio. A partir de él se determina la velocidad de liberación requerida y la orientación de la base del manipulador; se resuelve la trayectoria y se ejecuta el lanzamiento. Por último, la cámara cenital registra dónde cayó la pieza, lo que concluye el episodio y permite proceder al siguiente.

3.2.3. Primitivas

El ciclo descrito se apoya en dos primitivas de movimiento, cada una con su conjunto de parámetros y su criterio de éxito.

La primitiva queda determinada por los parámetros $\phi_g = (p_g, \psi)$ que entrega la red: la posición del asimiento y la rotación del efector final. El manipulador se sitúa sobre la pieza, cierra el efector final y la eleva para continuar con la tarea, como se muestra en la Figura 3.6.

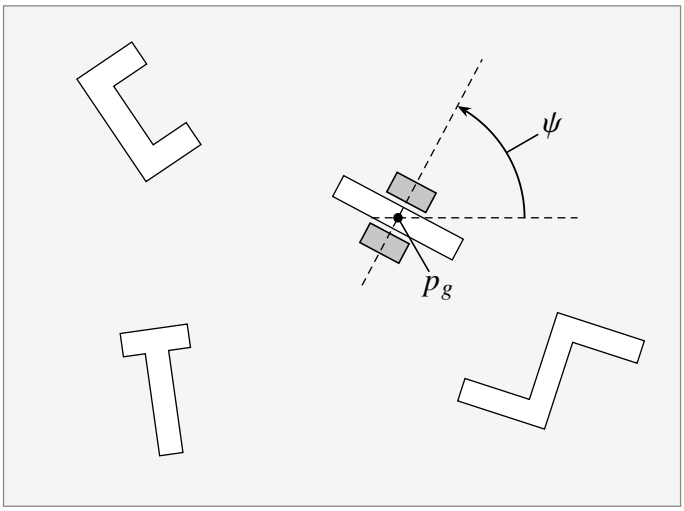


Figura 3.6: Parámetros de la primitiva de asimiento sobre el plano del mapa de alturas: p_g es la posición del asimiento y ψ la rotación del efector alrededor del eje vertical. Los dedos del efector final se representan por las huellas de colisión de sus superficies de contacto, de 30×15 mm, separadas por la apertura de 24 mm.

La primitiva de lanzamiento queda determinada por el objetivo p_{obj} asignado al episodio. De él se derivan la orientación de la base y los parámetros $\phi_t = (r, v)$, la posición de liberación y la velocidad que la pieza debe llevar en ese instante; con esos datos se resuelve la trayectoria de lanzamiento, el brazo se lleva primero a la configuración inicial calculada y, desde ahí, se ejecuta el movimiento con la apertura del efector final sincronizada con la liberación. Su formulación se detalla en la Sección 3.3.5.

Las dos primitivas se ejecutan de forma independiente: primero se realiza el asimiento y, si este tiene éxito, se planifica y se ejecuta el lanzamiento. Su relación se incorpora durante el entrenamiento, en el que la política aprende a preferir los puntos de asimiento con los que la pieza alcanza el objetivo, como se describe en la Sección 3.6.

3.3. Planificación de movimiento

El software del Sawyer incluye herramientas de cinemática inversa para tareas de manipulación convencionales, entre ellas SNS-IK (Flacco et al., 2015). En este trabajo también era necesario controlar el recorrido del robot y, durante el lanzamiento, la velocidad del efector final al liberar la pieza. Por ello, se desarrolló un planificador basado en optimización.

3.3.1. Modelo cinemático y dinámico

Se partió del modelo del Sawyer de MuJoCo Menagerie (Zakka et al., 2022). El efector final y los adaptadores se añadieron para representar el montaje físico.

El modelo se carga con Pinocchio (Carpentier et al., 2019) y, mediante su extensión para CasADi, los cálculos cinemáticos y dinámicos pueden incorporarse como expresiones simbólicas al problema de optimización.

3.3.2. Formulación general

Los tres problemas comparten las siguientes restricciones articulares:

$$\theta_{\text{mín}} \leq \theta_k \leq \theta_{\text{máx}}, \qquad |\dot{\theta}_k| \leq \dot{\theta}_{\text{máx}}, \qquad |\ddot{\theta}_k| \leq \ddot{\theta}_{\text{máx}}. \tag{3.1}$$

Los problemas se formulan en CasADi y se resuelven con IPOPT, como se describe en la Sección 2.2.4. El costo y las condiciones de frontera varían según el movimiento. Aquí se muestran los elementos que distinguen cada movimiento; las formulaciones completas de los costos, las condiciones de frontera y las restricciones se reúnen en el Apéndice B.

3.3.3. Movimiento articular

El movimiento articular lleva al robot desde θ_{ini} hasta θ_{fin} sin fijar el recorrido del efector final.

Se parte del perfil de mínimo *jerk* de la Sección 2.2.1. La optimización discreta sigue ese perfil e impone las restricciones de (3.1), además de las condiciones iniciales y finales.

3.3.4. Movimiento cartesiano y primitiva de asimiento

El movimiento cartesiano se usa cuando importa el recorrido del efector final. La posición sigue una línea recta y la orientación se interpola mediante SLERP, como se describe en la Sección 2.1.1. El costo también incluye una referencia articular θ_k^{ref}, obtenida mediante una interpolación de mínimo *jerk* entre la configuración inicial y una solución de cinemática inversa.

La duración se fija mediante una heurística que considera la distancia cartesiana por recorrer y los límites de velocidad del perfil de movimiento, con una duración mínima de 0.5 s. La trayectoria sigue las referencias cartesianas y articulares y penaliza los movimientos bruscos. Se integra con Euler y debe cumplir las restricciones articulares comunes. La pose final debe satisfacer

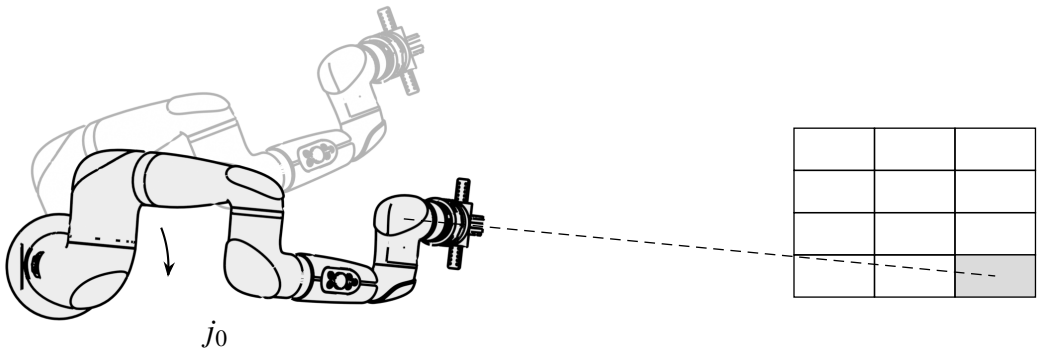
$$\|p(\theta_{N-1}) - p_d\|^2 \leq \varepsilon_p^2, \qquad 1 - \langle q(\theta_{N-1}), q_d \rangle^2 \leq \varepsilon_o. \tag{3.2}$$

La primitiva de asimiento de la Sección 3.2.3 combina ambos movimientos: la aproximación y la elevación son articulares, y el descenso sobre la pieza es cartesiano.

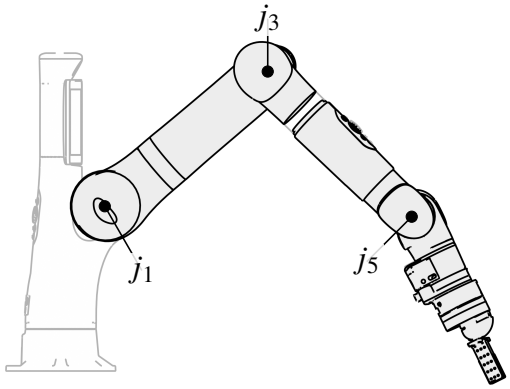
3.3.5. Optimización de la trayectoria de lanzamiento

Antes de planificar el lanzamiento, j_0 se orienta hacia el objetivo y las articulaciones restantes que no intervienen se bloquean, como se muestra en la Figura 3.7. Solo quedan activas

$$\theta_a = \begin{bmatrix} \theta_1 & \theta_3 & \theta_5 \end{bmatrix}^T. \tag{3.3}$$



(a) Vista superior



(b) Vista normal al plano

Figura 3.7: Modelo reducido para el lanzamiento. En (a), j_0 alinea el brazo con el plano vertical de la celda objetivo, sombreada; (b) es la vista normal a ese plano. En trazo completo se muestran los eslabones que mueven j_1, j_3 y j_5; los demás quedan bloqueados. El problema se reduce así a un mecanismo planar de tres grados de libertad.

El efector final está desplazado respecto al plano del brazo. Por eso, la orientación de j_0 incluye la corrección

$$\theta_0 = \operatorname{atan2}(p_{\text{obj},y}, p_{\text{obj},x}) - \arcsin\left(\frac{d}{D}\right), \tag{3.4}$$

donde D es la distancia horizontal al objetivo y $d = 160.3\,\text{mm}$ es el desplazamiento lateral del efector final obtenido del modelo cinemático.

Al fijar θ_0 queda definido el plano vertical de lanzamiento. En ese plano, r y v son la posición y la velocidad de liberación. Antes de resolver la trayectoria se calcula el estado deseado $\hat{r}$, $\hat{v}$. Para una rapidez $\|\hat{v}\|$ y un ángulo α,

$$\hat{v} = \|\hat{v}\| \begin{bmatrix} \cos\alpha \\ \sin\alpha \end{bmatrix}. \tag{3.5}$$

El costo prioriza que la posición de liberación se acerque a la deseada,

$$\mathcal{J}_{\text{lan}} = w_p \, \|r - \hat{r}\|^2 + w_{t_f} t_f + \mathcal{J}_{\text{reg}}. \tag{3.6}$$

Además de (3.1), se limitan el par y la cercanía del efector final a la mesa durante el barrido,

$$|\tau_a| \leq \tau_{a_{\text{máx}}}, \qquad p_{x,k} \geq x_{\text{mín}}, \qquad p_{z,k} \geq z_{\text{mín}}. \tag{3.7}$$

$\mathcal{J}_{\text{reg}}$ agrupa las penalizaciones de aceleración, *jerk* definido en la Sección 2.2.1 y de desviación respecto de la configuración inicial. La integración es trapezoidal, como se describe en la Sección 2.2.3. La dirección y la magnitud de la velocidad de liberación se imponen mediante restricciones, mientras que la posición de liberación se incorpora mediante el costo. A diferencia de los movimientos anteriores, t_f también es una variable de decisión. La Figura 3.8 muestra la configuración inicial y la de liberación de una solución.

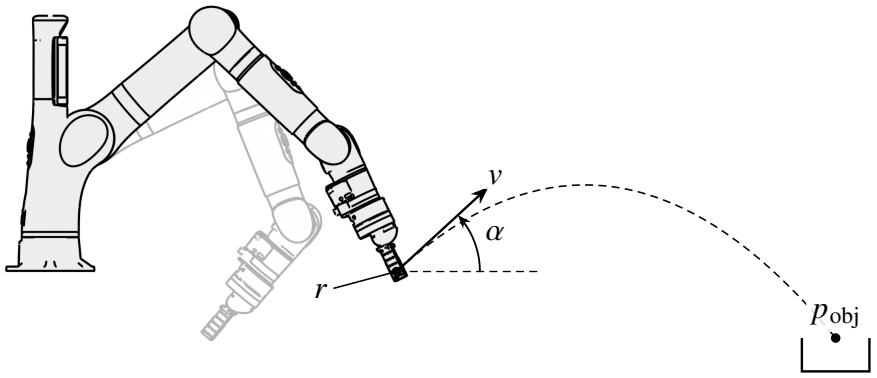


Figura 3.8: Parámetros de la primitiva de lanzamiento sobre el plano vertical: en gris la configuración desde la que arranca el movimiento y en trazo completo la de liberación, con la posición r, la velocidad v, su ángulo α sobre la horizontal y el objetivo p_{obj}. El vuelo se muestra según el modelo balístico hacia esa celda.

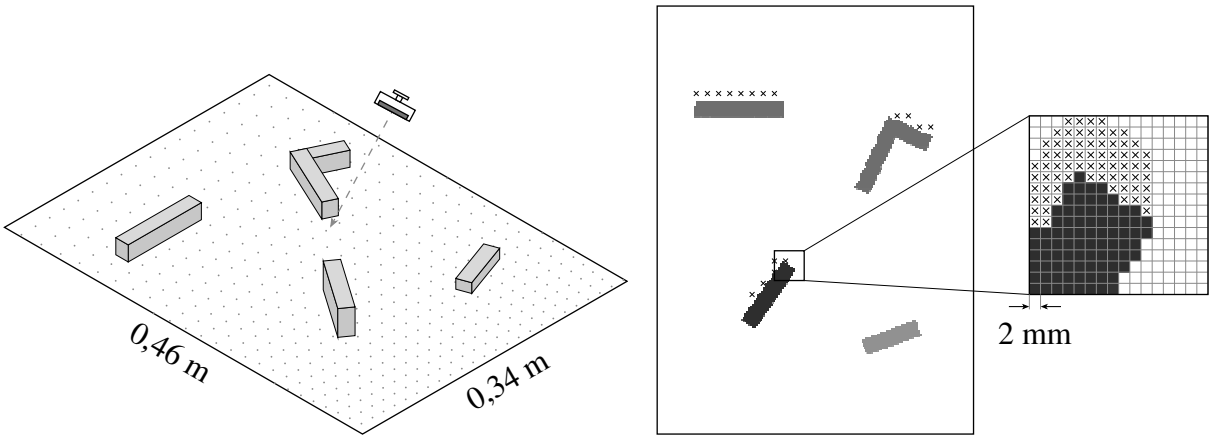
3.4. Percepción

La percepción consiste en convertir la nube de puntos captada por la cámara RGB-D en la representación empleada por la red neuronal. La nube se expresa primero en el marco de referencia del manipulador y, después, se proyecta sobre la mesa de recogida para construir un mapa ortográfico de alturas.

3.4.1. Mapa ortográfico de alturas

La nube de puntos se proyecta a una vista ortográfica desde arriba. Con ello, cada píxel representa una región de tamaño constante sobre la mesa, independientemente de su posición respecto a la cámara. Esto permite relacionar directamente las posiciones de la imagen con las posiciones físicas en el espacio de trabajo.

El procedimiento comienza por eliminar los puntos que se encuentran fuera de la región de recogida, de 0.34×0.46 m. Los puntos restantes se distribuyen en una matriz con una resolución de 2 mm por píxel, lo que da como resultado una imagen de 170×230 píxeles. Cuando varios puntos caen en una misma celda, se conserva el de mayor altura, como ilustra la Figura 3.9.



(a) Escena (b) Mapa de alturas

Figura 3.9: Construcción del mapa de alturas. Las celdas marcadas con × son las que la cámara no alcanza a ver detrás de cada pieza: su altura queda en cero, igual que la de la mesa.

Cada celda almacena la altura del punto seleccionado y sus valores RGB, por lo que la observación final tiene dimensiones

$$I \in \mathbb{R}^{170\times230\times4}, \tag{3.8}$$

con tres canales de color y un canal de altura.

La geometría de la escena se representa principalmente mediante el canal de altura. Los canales RGB se conservaron en la representación de entrada utilizada por la arquitectura de la red, aunque en esta tarea las piezas se distinguen principalmente por su forma.

3.4.2. Normalización de la observación

Antes de introducir la observación a la red, cada canal se estandariza de forma independiente,

$$I' = \frac{I - \mu}{\sigma}, \tag{3.9}$$

donde I es el valor original y μ y σ son la media y la desviación estándar del canal.

Estos parámetros se estimaron a partir de 500 observaciones generadas durante el entrenamiento mediante aleatorización de dominio y se mantuvieron fijos durante la evaluación.

3.5. Red de asimiento

La política de asimiento utiliza una red totalmente convolucional que recibe la observación I y genera un mapa de valoración asociado a las posiciones de la escena. Esta formulación conserva la idea de predicción densa utilizada en TossingBot (Zeng et al., 2020), pero en este trabajo la función de asimiento se implementa mediante una única red de tipo U-Net. La velocidad de lanzamiento no es estimada por la red, sino que se obtiene a partir del modelo balístico descrito en la Sección 3.3.5.

Para considerar las distintas orientaciones del efector final, la observación se evalúa en cada una de las rotaciones definidas para la política, como se describe en la Sección 3.5.2.

3.5.1. Arquitectura

La red sigue una arquitectura codificador–decodificador de tipo U-Net, descrita en la Sección 2.3.4. La entrada está formada por cuatro canales correspondientes a RGB y altura, mientras que la salida es un mapa de un canal con la misma resolución espacial.

El codificador contiene tres etapas de submuestreo mediante *max pooling* de 2×2. En cada nivel se aplican dos convoluciones de 3×3, seguidas de *group normalization* y activación *rectified linear unit* (ReLU). El decodificador recupera progresivamente la resolución mediante interpolación bilineal y concatena las características provenientes del nivel correspondiente del codificador, según (2.43). La Figura 3.10 muestra la arquitectura completa y el número de canales utilizado en cada nivel.

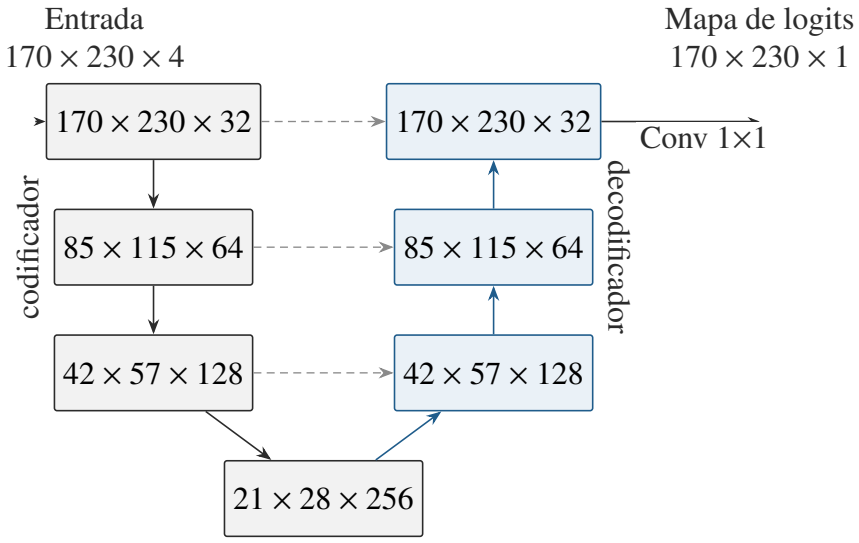


Figura 3.10: Arquitectura de la red de asimiento, con la misma convención de la Figura 2.4. Cada bloque indica la resolución espacial y el número de canales en ese nivel.

Una convolución final de 1×1 produce el mapa de valoración $Q \in \mathbb{R}^{U \times V}$ de (2.39), cuyos elementos son *logits* y no probabilidades (2.42). Para cada orientación considerada se obtiene

un mapa y la acción final se selecciona a partir del mayor valor entre todas las posiciones y orientaciones, como se describe en la Sección 3.5.2. La red contiene 1 948 577 parámetros.

La arquitectura de tipo U-Net se eligió para conservar mayor detalle espacial en la predicción de los asimientos. La red utilizada en el trabajo de referencia reduce la resolución por un factor de 4 y la recupera mediante interpolación bilineal, mientras que en este trabajo las regiones de asimiento pueden ocupar pocos píxeles debido a la reducida tolerancia entre los dedos y los bordes de las piezas. Las conexiones de salto proporcionan al decodificador características obtenidas antes del submuestreo, como se describió en la Sección 2.3.4. La comparación entre ambas arquitecturas se presenta en la Sección 4.3.

3.5.2. Muestreo de orientaciones

La red evalúa una orientación fija del efector final respecto de la observación. Para considerar el giro completo, la imagen se rota en 32 orientaciones separadas 11.25°. Aunque el efector final es simétrico ante una rotación de 180°, ambas orientaciones se mantienen como acciones distintas, ya que producen sentidos opuestos de la pieza, con respecto de la dirección del lanzamiento.

Cada orientación se procesa con la misma U-Net y produce un mapa de *logits*, es decir $C = 1$ en (2.40). Los 32 mapas se agrupan en

$$Q \in \mathbb{R}^{32\times U\times V}, \tag{3.10}$$

y la acción se selecciona mediante

$$(u^*, v^*, o^*) = \underset{u,v,o}{\operatorname{argmax}}\, Q_{ouv}. \tag{3.11}$$

El píxel seleccionado se convierte a una posición de asimiento mediante la correspondencia entre la imagen ortográfica y el espacio de trabajo definida en la Sección 3.4.1, mientras que el índice o^* determina la orientación del efector final,

$$\psi = 11.25^\circ\, o^*. \tag{3.12}$$

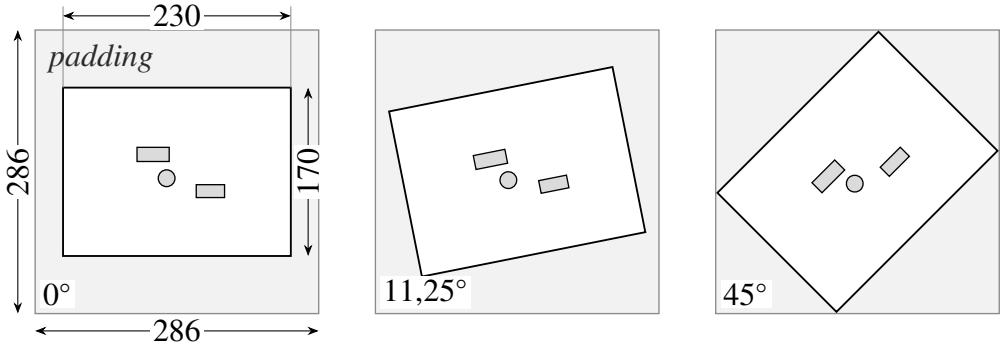


Figura 3.11: Relleno de la observación antes de rotarla. En blanco la observación y en gris el lienzo. A la izquierda sin girar, al centro en el paso de 11.25° de la política y a la derecha en 45°.

Antes de realizar las rotaciones, se añade *padding* a la observación para evitar recortes del espacio de trabajo. El área añadida permite realizar las rotaciones sin perder información, como se muestra en la Figura 3.11. Las imágenes se rotan mediante interpolación por vecino más cercano y, después de la inferencia, solo se consideran las posiciones correspondientes a la región original.

La Figura 3.12 resume el procedimiento de inferencia y la Figura 3.13 muestra un ejemplo sobre una escena real.

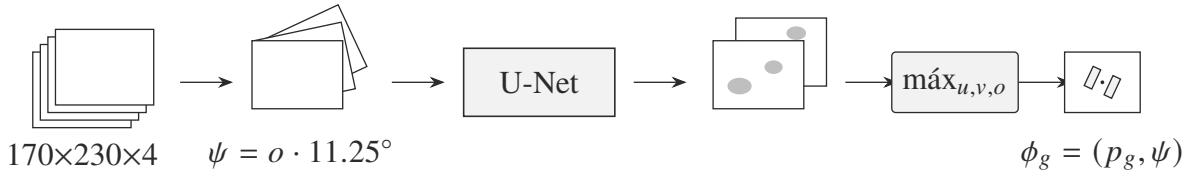


Figura 3.12: Inferencia de la política de asimiento: de la observación rotada al mapa de *logits* de cada rotación, y del máximo sobre todos ellos a los parámetros ϕ_g de la primitiva.

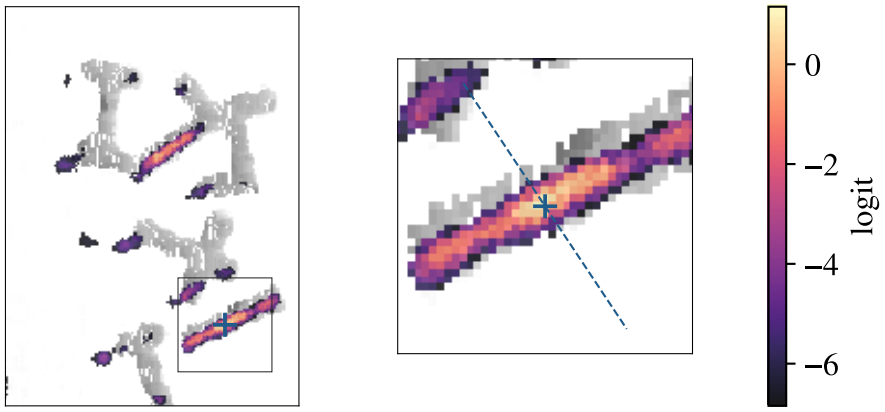


Figura 3.13: Selección de un asimiento sobre una escena real: el mapa de *logits* de la rotación elegida sobre la escena, con el punto seleccionado marcado y un detalle de 8×8 cm a su alrededor, donde la línea indica la dirección en que se cierran los dedos del efector final.

3.6. Entrenamiento

El entrenamiento se realiza en dos etapas. En la primera, la red aprende a identificar asimientos viables a partir de etiquetas densas obtenidas mediante un criterio geométrico. En la segunda, la red se refina en función de los resultados de lanzamientos simulados, siguiendo el esquema de autosupervisión de TossingBot. TossingBot entrena la red únicamente mediante prueba y error (Zeng et al., 2020, §V). La primera etapa es, por tanto, una desviación respecto del trabajo de referencia, motivada por la reducida tolerancia de asimiento discutida en la Sección 1.2.4.

Ambas etapas se ejecutaron en una computadora con procesador AMD Ryzen 7 9700X, 64 GB de memoria y una tarjeta gráfica NVIDIA GeForce RTX 4060 de 8 GB. La primera

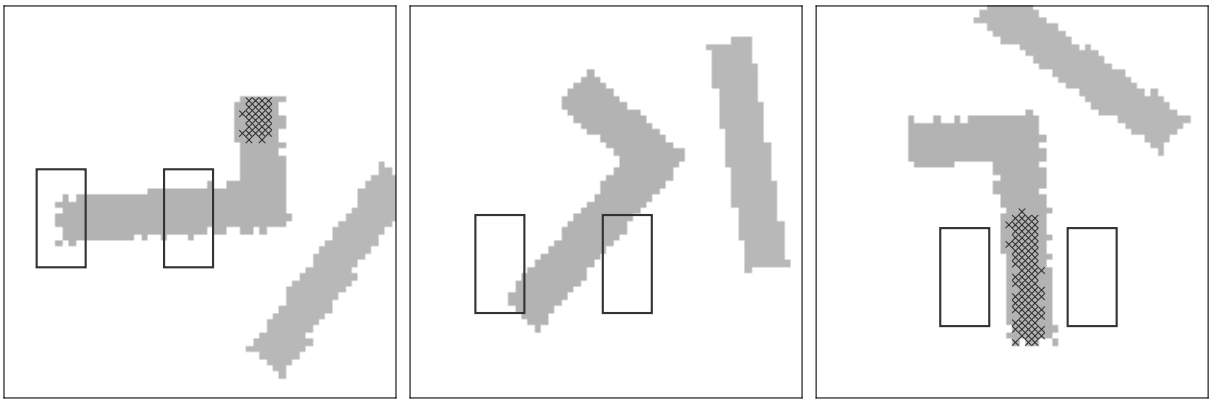
etapa requirió alrededor de una hora y media, y la segunda alrededor de dos horas para 3 000 episodios.

3.6.1. Entrenamiento inicial con etiquetas geométricas

Para cada escena se evalúan todas las posiciones del mapa de alturas y las 32 orientaciones del efector final. Cada acción recibe una etiqueta binaria,

$$y_i \in \{0, 1\}, \tag{3.13}$$

donde $y_i = 1$ corresponde a un asimiento viable. Un asimiento se considera viable cuando se cumplen dos condiciones. Primero, la sección transversal de la pieza entre los dedos debe estar dentro de la carrera del efector. Segundo, el volumen barrido por los dedos durante el descenso, ampliado 1 mm en cada dirección, no debe intersecar ninguna pieza de la escena. La ampliación deja una tolerancia para los errores de posicionamiento. Así se obtiene supervisión de toda la región evaluada y no únicamente de la acción que la política habría seleccionado. La Figura 3.14 muestra el resultado sobre una pieza en tres orientaciones.



(a) 45° (b) 90° (c) 135°

Figura 3.14: Etiqueta de asimiento sobre una pieza ⌊, en un recorte de 12×12 cm. La observación se gira a cada orientación del efector, como la evalúa la política (Figura 3.11), de modo que los dedos, cuya huella son los rectángulos, cierran siempre en horizontal. Las celdas con etiqueta positiva llevan ×.

El conjunto contiene 1 000 escenas generadas mediante aleatorización de dominio, con entre una y diez piezas tomadas de un catálogo de 60 formas. De ellas, 850 se utilizan para entrenamiento y 150 para validación. Al evaluar todas las posiciones y orientaciones de cada escena se obtienen cerca de 1.25×10^9 etiquetas.

La mayor parte de las posiciones del mapa no corresponde a un asimiento viable. Para evitar que esta diferencia domine el entrenamiento, la pérdida calcula por separado las medias de las etiquetas positivas y negativas. Para cada acción se utiliza la entropía cruzada binaria definida en (2.41), y la pérdida queda dada por

$$\mathcal{L}_g = \frac{1}{2}\left(\frac{1}{N^+}\sum_{i\,:\,y_i=1}\ell_i + \frac{1}{N^-}\sum_{i\,:\,y_i=0}\ell_i\right), \tag{3.14}$$

donde N^+ y N^- son el número de etiquetas positivas y negativas de la muestra, respectivamente. Cuando una de las dos clases no está presente, la pérdida se calcula únicamente sobre la clase disponible.

La red se entrena a partir de parámetros iniciales aleatorios mediante *stochastic gradient descent* (SGD) (Robbins y Monro, 1951), sin preentrenamiento sobre imágenes. Los valores de esta etapa y de la siguiente se presentan en la Tabla 3.1.

3.6.2. Refinamiento con el resultado del lanzamiento

La segunda etapa parte de los parámetros del entrenamiento inicial y continúa el aprendizaje mediante la interacción en simulación. En cada episodio se observa la escena, se selecciona una acción de asimiento y se ejecuta. Si la pieza queda asida, se lanza hacia un objetivo cuya posición se muestrea uniformemente dentro de la región descrita en la Sección 3.1.1 (Figura 3.1). De este modo, el refinamiento se realiza a diferentes distancias y desplazamientos laterales de lanzamiento.

Siguiendo la idea utilizada en el trabajo de referencia TossingBot (Zeng et al., 2020, §V), la supervisión del asimiento se obtiene a partir del resultado de la tarea subsecuente. La etiqueta es positiva cuando la pieza alcanza el objetivo asignado y negativa en cualquier otro caso, incluido un asimiento fallido. A diferencia de la primera etapa, únicamente se dispone de una etiqueta para la acción ejecutada, por lo que el gradiente se propaga solo a través de la posición y la orientación correspondientes a dicha acción.

La pérdida de cada episodio se calcula como

$$\mathcal{L}_t = w_i\,\ell_i, \qquad w_i = \begin{cases} 0.5, & \text{si la pieza fue asida pero no alcanzó el objetivo,} \\ 1, & \text{en otro caso,} \end{cases} \tag{3.15}$$

donde ℓ_i corresponde a la entropía cruzada definida en (2.41).

Esta ponderación se introduce porque el refinamiento parte de una red que ya ha aprendido a identificar asimientos viables. Un lanzamiento fallido tras asir correctamente la pieza no implica necesariamente que el asimiento sea completamente inadecuado, ya que el error también puede deberse a la ejecución del lanzamiento. Penalizar estos casos con el mismo peso que un asimiento fallido puede degradar la capacidad de asir adquirida en la primera etapa. Esto reduciría además la frecuencia con la que la política consigue asir una pieza y, por tanto, la cantidad de episodios que proporcionan información sobre el resultado del lanzamiento.

Cada transición se almacena en una memoria de repetición priorizada y, después de cada episodio, se actualizan los parámetros utilizando un lote extraído de ella. El refinamiento utiliza SGD con una tasa de aprendizaje menor que la empleada durante el entrenamiento inicial, ya que el objetivo es modificar una política previamente entrenada y no aprenderla desde una inicialización aleatoria.

La exploración se limita a las acciones que el criterio geométrico de la primera etapa considera viables. A lo largo de los 3 000 episodios, la probabilidad de realizar una acción exploratoria disminuye linealmente de 0.1 a 0.02. Cuando se explora, la acción se selecciona mediante una distribución de Boltzmann (Sutton y Barto, 2018)

$$P(a_i) = \frac{\exp(z_i/T_B)}{\sum_{j\in\mathcal{A}_v}\exp(z_j/T_B)}, \tag{3.16}$$

donde z_i es el *logit* asociado a la acción, $\mathcal{A}_v$ es el conjunto de acciones geométricamente viables y T_B es la temperatura. Esta disminuye de 0.5 a 0.15 en el mismo intervalo. Cuando no se realiza una acción exploratoria, se selecciona la acción con mayor *logit*.

Esta estrategia evita dedicar la exploración a posiciones que el criterio geométrico ya identifica como inviables, lo cual es especialmente importante debido a la reducida tolerancia disponible para asir las piezas con el efector final utilizado.

Las escenas empleadas en esta etapa utilizan el subconjunto de 39 piezas descrito en el Apéndice A. El refinamiento se ejecutó durante 3 000 episodios y se guardaron los parámetros cada 50 episodios. El modelo utilizado en la plataforma corresponde a los parámetros del episodio 2 500 de la U-Net con 32 orientaciones, la variante con mejor desempeño en simulación (Tabla 4.2).

Tabla 3.1: Hiperparámetros de las dos etapas de entrenamiento.

	Entrenamiento inicial	**Refinamiento**
Inicialización	aleatoria	entrenamiento inicial
Supervisión	densa, geométrica	acción ejecutada, lanzamiento
Datos	850 / 150 escenas	3 000 episodios
Épocas	10	—
Optimizador	SGD	SGD
Momento	0.9	0.9
Tasa de aprendizaje	10^{-4}	10^{-5}
Decaimiento de parámetros	10^{-4}	2×10^{-5}
Lote	4	16

Capítulo 4

Resultados

Este capítulo reporta la evaluación del sistema desarrollado, primero en simulación, para seleccionar la red de asimiento, y después en el robot físico. Además del desempeño global en la tarea de asir y lanzar, se analiza por separado el comportamiento de la política de asimiento, el seguimiento de las trayectorias de lanzamiento y la variación del desempeño entre piezas y objetivos. Finalmente, se comparan los resultados con el trabajo de referencia y se discuten las principales limitaciones del sistema.

En total, se realizaron 826 intentos, de los cuales 800 concluyeron con un lanzamiento. Al considerar la tarea completa, la tasa de éxito para la tarea completa fue de 85.12 % para las piezas conocidas durante el entrenamiento y de 73.56 % para las desconocidas.

4.1. Protocolo experimental

La evaluación física se diseñó para medir por separado el éxito del asimiento, del lanzamiento y de la tarea completa. Para ello se utilizaron ocho piezas, una matriz de 12 objetivos y un mismo protocolo para las ocho piezas. A continuación se describen las piezas, la disposición de los objetivos, la secuencia seguida en los experimentos y el criterio utilizado para determinar el éxito de cada intento.

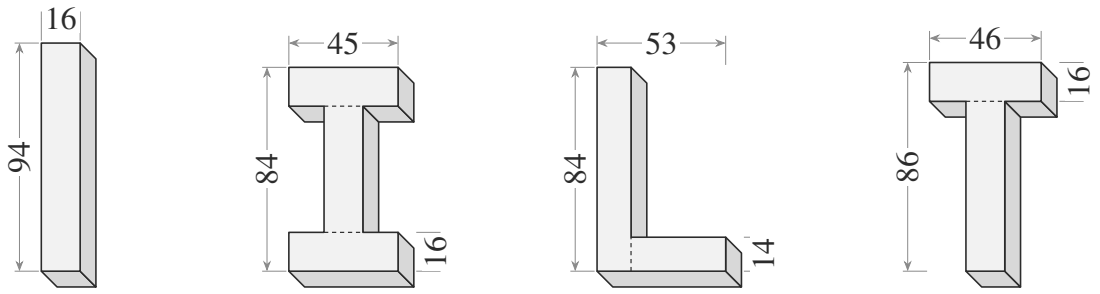
4.1.1. Piezas de evaluación

El conjunto de evaluación está compuesto por ocho piezas de sección transversal rectangular, cada una con una forma geométrica distinta.

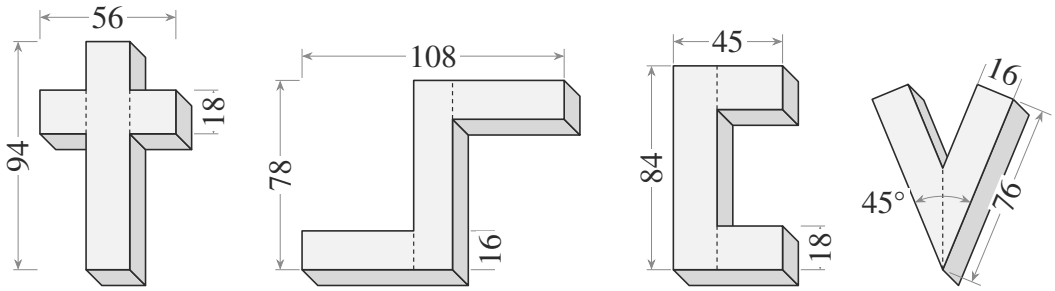
Se fabricó un solo ejemplar de cada forma. Debido a las irregularidades propias del proceso de fabricación, las tasas de éxito obtenidas para cada pieza pueden verse influidas no solo por su forma, sino también por las características particulares del ejemplar utilizado.

Cuatro de las piezas corresponden a formas conocidas, vistas durante el entrenamiento: la 𝕀, la 𝕀, la 𝕃 y la 𝕋. El catálogo de entrenamiento incluye sus dimensiones, además de variantes más largas o más anchas (Apéndice A). Las otras cuatro, la 𝕥, la ⅃⌐, la 𝔼 y la 𝕍, corresponden a formas desconocidas para el sistema.

Los segmentos utilizados para ensamblar las piezas tienen una sección transversal de entre 14 y 18 mm. Dada la apertura máxima del efector final, existe una tolerancia de aproximadamente



(a) Piezas conocidas



(b) Piezas desconocidas

Figura 4.1: Piezas empleadas en la evaluación. En (a), las conocidas, vistas durante el entrenamiento: 𝕀, 𝕀, 𝕃 y 𝕋; en (b), las desconocidas: 𝕥, ⌐, 𝔼 y 𝕍. Las cotas están en milímetros: las exteriores y la sección transversal de cada pieza. Todas tienen 19 mm de espesor. La línea punteada indica la junta atornillada entre dos segmentos, no un traslape.

3 a 5 mm por lado. Con una resolución de 2 mm por píxel en el mapa de altura, esta tolerancia equivale a 1.5–2.5 píxeles para la selección del punto de asimiento.

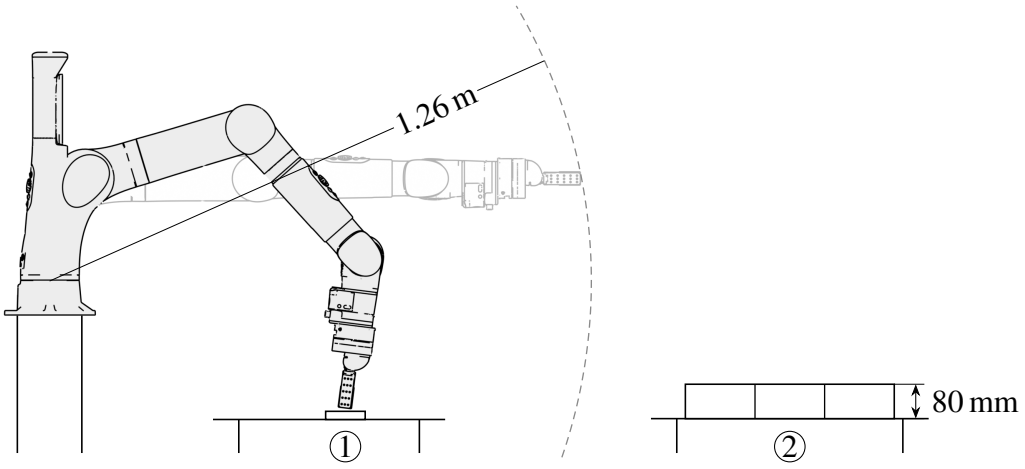
4.1.2. Matriz de objetivos

Se utilizaron 12 objetivos dispuestos en una caja dentro de una matriz de tres filas y cuatro columnas. Cada objetivo mide 7.5 × 15 cm y tiene una profundidad de 8 cm. Las tres filas se encuentran a 1.56, 1.72 y 1.90 m de la base del manipulador, respectivamente. La Figura 4.2a sitúa la caja respecto del manipulador y la Figura 4.2b detalla la distribución de los objetivos.

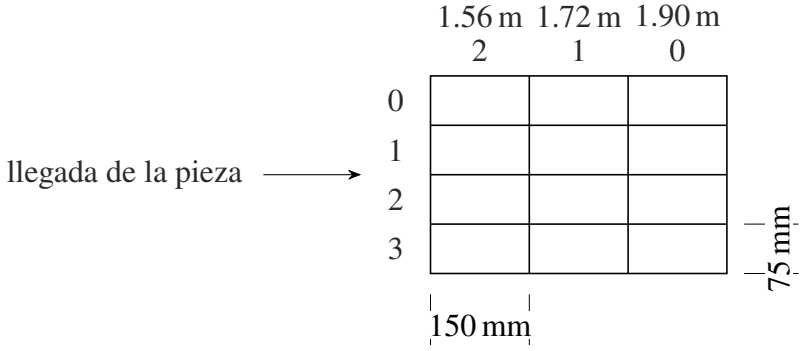
La pose de la matriz con respecto al marco de referencia del robot se obtuvo mediante un proceso de calibración con un patrón ChArUco (Garrido-Jurado et al., 2014), observado simultáneamente por la cámara de profundidad y la cámara cenital. La Figura 4.3 muestra el montaje completo.

4.1.3. Ejecución y criterio de éxito

El modelo utilizado en la evaluación física corresponde a la U-Net descrita en la Sección 3.5, refinada con el resultado del lanzamiento según la Sección 3.6.2. Los parámetros del modelo no



(a) Vista lateral



(b) Planta de la matriz

Figura 4.2: Disposición de los objetivos respecto de la base del manipulador. En gris, el brazo en extensión completa; el arco marca el alcance, 1.26 m: ① mesa de recogida, ② matriz de objetivos. En la planta, la distancia a la base va debajo de cada fila.

se actualizaron durante la ejecución de la tarea. El objetivo fue realizar 100 lanzamientos por pieza, sin considerar cuántos intentos se requerirían debido a errores en la fase de asimiento.

Durante las diferentes sesiones de evaluación se colocaban juntas las ocho piezas, conocidas y desconocidas, y se dejaba que el sistema las agotara antes de reponerlas. En cada intento, el objetivo se tomaba de un recorrido exhaustivo de los 12 disponibles, ordenado al azar en cada vuelta, sin repetir ningún objetivo antes de completar cada vuelta por los 12 disponibles. El sistema intentaba asir la pieza en la que tuviera mayor confianza de éxito. Si el asimiento tenía éxito, procedía a lanzarla al objetivo seleccionado. Una vez agotadas las ocho piezas, se reponían manualmente y se iniciaba un nuevo ciclo.

Un lanzamiento se consideró exitoso si la pieza entró en el objetivo asignado. También se contabilizó como éxito si rebotó previamente en alguna de las paredes antes de entrar, o si entró en el objetivo y salió de él debido a un rebote. Por el contrario, si primero entró en un objetivo



Figura 4.3: Montaje experimental. De izquierda a derecha: el manipulador sobre su base, la mesa de recogida con las piezas y la matriz de objetivos. La cámara cenital se encuentra suspendida sobre la mesa de la matriz de objetivos.

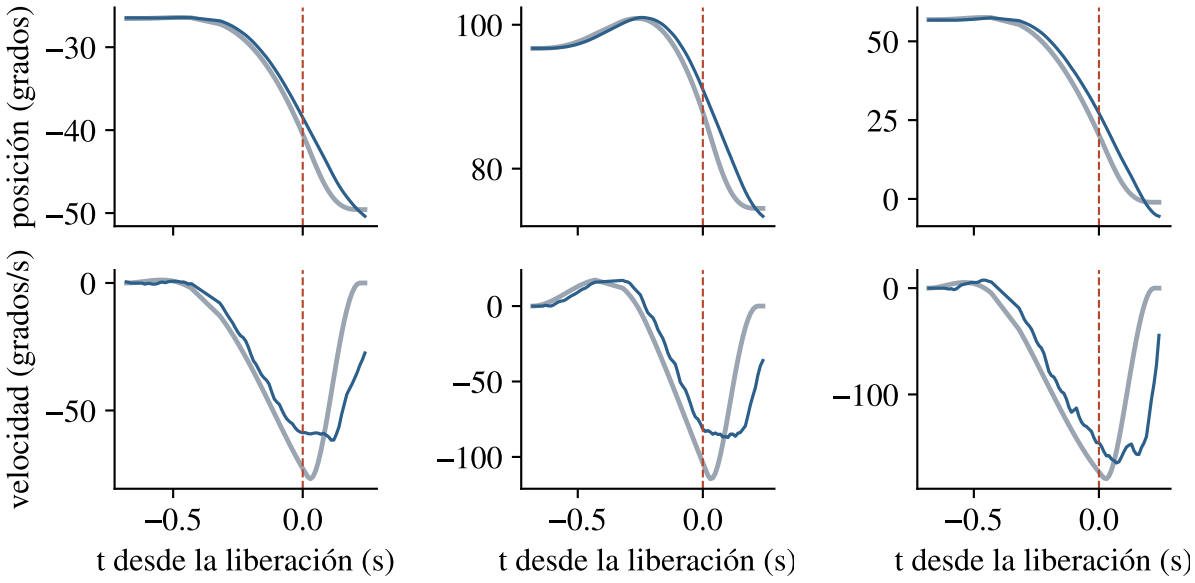
distinto y después terminó en el objetivo asignado como consecuencia de un rebote, se consideró fallido.

4.2. Calibración del lanzamiento

Se observó que el robot presenta errores de seguimiento en las trayectorias articulares definidas por el planificador. Como consecuencia, el efector final no alcanza exactamente la posición ni la velocidad deseadas en el instante de liberación de la pieza. Para compensar este comportamiento se utilizó una corrección global de la velocidad de lanzamiento, cuyo procedimiento se describe a continuación.

4.2.1. Error de seguimiento y corrección de velocidad

Como se explica en la Sección 3.3, el planificador de trayectorias proporciona la posición, velocidad y aceleración deseadas para cada articulación en cada instante de tiempo, a una frecuencia de 100 Hz, la misma que se utiliza para enviar los comandos al robot. Al ejecutar estas referencias, se espera que el manipulador siga la trayectoria planificada lo más de fielmente posible. Sin embargo, como se observa en la Figura 4.4, las trayectorias ejecutadas no coinciden con las originalmente planificadas.



(a) j_1 (b) j_3 (c) j_5

Figura 4.4: Seguimiento de la trayectoria articular durante un lanzamiento a la fila alejada, en las tres articulaciones con velocidad planificada distinta de cero. La línea gris gruesa es la trayectoria planificada y la azul la ejecutada; la fila superior muestra la posición y la inferior la velocidad. La línea vertical marca el instante de liberación.

Estas diferencias producen errores en la posición y la velocidad del efector final en el instante de liberación. Sin compensación, la pieza sale con una velocidad inferior a la que requiere el modelo balístico y cae antes del objetivo. Experimentalmente se observó que este déficit aumenta con la velocidad solicitada: es pequeño para la fila cercana y se vuelve más evidente para la más distante.

Para compensar este comportamiento, la rapidez que se comanda al planificador no es la que entrega el modelo balístico, sino una corregida

$$\|v\| = \|\hat{v}\| + \delta, \qquad \delta = \beta_0 + \beta_1 \|\hat{v}\|, \tag{4.1}$$

donde $\|\hat{v}\|$ es la rapidez nominal de liberación que entrega el modelo balístico y δ es la corrección, lineal en $\|\hat{v}\|$. Sus parámetros se determinaron experimentalmente: para cada una de las tres filas de objetivos se fijó la corrección necesaria para acertar, 0.10, 0.25 y 0.35 m/s para las filas cercana, intermedia y lejana, respectivamente, y la recta se ajustó por mínimos cuadrados a esos tres puntos de operación. Los valores resultantes son $\beta_0 = -1.1346$ m/s y $\beta_1 = 0.4722$, de manera que la corrección aplicada aumenta a medida que aumenta la velocidad nominal solicitada, como muestra la Figura 4.5.

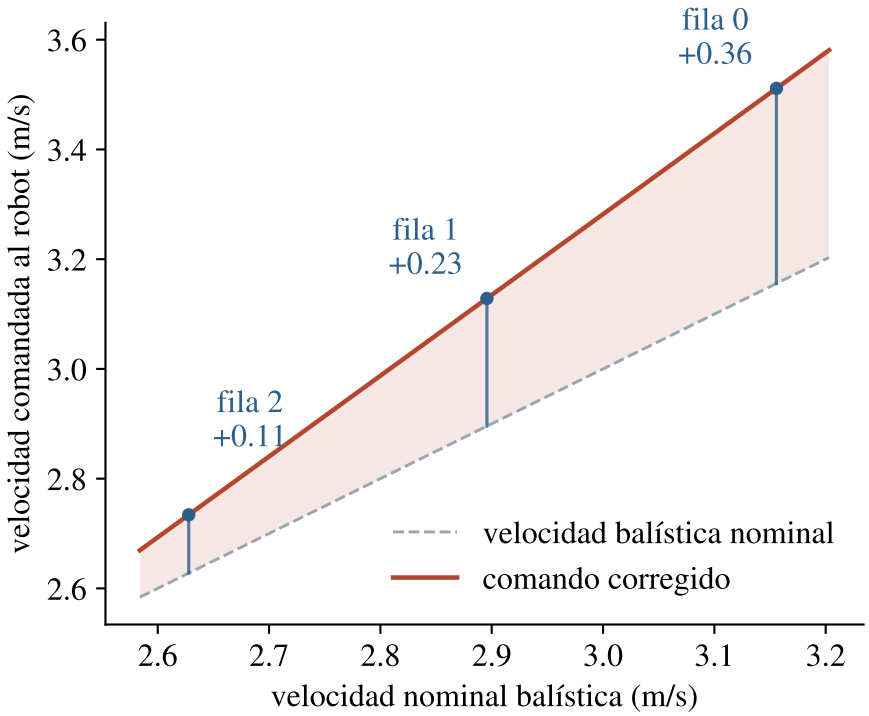


Figura 4.5: Perfil de la corrección de velocidad. La banda sombreada representa la magnitud de la corrección aplicada; los marcadores señalan los tres puntos de operación.

Para verificar la corrección se comparó la rapidez horizontal planificada en el instante de liberación con la rapidez horizontal de la pieza medida durante el vuelo mediante la cámara cenital. La Tabla 4.1 resume los resultados por fila de objetivos. Con la corrección aplicada, las medianas de las velocidades medidas se mantienen próximas a las planificadas en las tres filas de objetivos, lo que indica que la compensación permite aproximar la velocidad de liberación a la requerida para el lanzamiento.

Tabla 4.1: Rapidez horizontal planificada en el instante de liberación y rapidez horizontal medida en vuelo con la cámara cenital, por fila de objetivos.

Fila	**Planificada (m/s)**	**Medida, mediana (m/s)**
Cercana	1.88	1.90
Intermedia	2.14	2.26
Alejada	2.43	2.48

4.3. Evaluación en simulación

Antes de la evaluación física, se compararon en simulación la red base y tres políticas refinadas con el resultado del lanzamiento (Sección 3.6.2). Las políticas refinadas corresponden a la U-Net descrita en la Sección 3.5.1 evaluada con 32 y con 16 orientaciones, y a una red totalmente convolucional con bloques residuales basada en la arquitectura de asimiento de TossingBot (Zeng et al., 2020), evaluada con 32 orientaciones. Esta última se utiliza como arquitectura de referencia y no incluye conexiones de salto entre las etapas de reducción y recuperación de resolución. Todas las variantes se refinaron con el mismo procedimiento y durante el mismo número de episodios, y para cada una se evaluaron los parámetros del episodio 2 500.

Cada modelo se evaluó sobre las mismas 200 escenas, generadas con una semilla fija. En cada escena se colocaron las ocho piezas de evaluación (Sección 4.1.1) y el sistema intentó asirlas y lanzarlas una a una hasta vaciar la mesa, hacia objetivos de la matriz de 12 objetivos (Sección 4.1.2). Durante la evaluación la acción se selecciona siempre con el mayor *logit*, sin exploración. La Tabla 4.2 resume los resultados.

Tabla 4.2: Desempeño en simulación de la red base y de las variantes refinadas sobre las mismas 200 escenas. El lanzamiento se mide sobre los asimientos exitosos y la tarea completa sobre todos los intentos. El número indica las orientaciones evaluadas. En negritas el modelo utilizado en la evaluación física.

	Piezas conocidas			**Piezas desconocidas**		
Modelo	Asimiento	Lanzamiento	Tarea	Asimiento	Lanzamiento	Tarea
Red base, U-Net 32	97.9 %	74.2 %	72.6 %	94.9 %	64.2 %	60.9 %
U-Net refinada 16	91.4 %	86.7 %	79.3 %	92.2 %	85.6 %	78.9 %
Referencia refinada 32	94.1 %	94.5 %	88.9 %	92.5 %	92.4 %	85.5 %
U-Net refinada 32	**99.1 %**	**97.2 %**	**96.4 %**	**97.1 %**	**94.6 %**	**91.9 %**

El refinamiento mejora el desempeño de la tarea completa en las tres variantes respecto de la red base, que, aun con una tasa de asimiento del 96.4 %, completa la tarea solo en el 66.6 % de los intentos, en conjunto, considerando piezas conocidas y desconocidas. La U-Net con 32 orientaciones obtuvo el mejor desempeño en todas las métricas, con 98.1 % de éxito en el asimiento y 94.1 % en la tarea completa. El éxito fue de 96.4 % en las piezas conocidas y de 91.9 % en las desconocidas. La red de referencia con 32 orientaciones alcanzó 87.2 % de éxito en la tarea completa, mientras que reducir el número de orientaciones de la U-Net a 16 disminuyó esta tasa a 79.1 % y produjo también una caída en el desempeño de asimiento. Por

pieza, las de menor éxito para el modelo seleccionado fueron la ⌐¬ y la ⊏, con 85.3 % y 90.2 %, respectivamente, mientras que el resto obtuvo al menos 93 %. A partir de estos resultados, se seleccionó la U-Net con 32 orientaciones para la evaluación física.

4.4. Resultado principal

A continuación se presentan los resultados de los intentos necesarios para completar 100 lanzamientos por pieza. La Tabla 4.3 resume las tasas de éxito en el asimiento, en el lanzamiento y en la tarea completa para los conjuntos de piezas conocidas y desconocidas.

Tabla 4.3: Desempeño del sistema en el robot físico para las piezas conocidas y desconocidas durante el entrenamiento. El lanzamiento se mide sobre los asimientos exitosos y la tarea completa sobre todos los intentos.

	Piezas conocidas			**Piezas desconocidas**		
	Asimiento	Lanzamiento	Tarea	Asimiento	Lanzamiento	Tarea
Éxitos / intentos	400 / 410	349 / 400	349 / 410	400 / 416	306 / 400	306 / 416
Tasa	97.56 %	87.25 %	85.12 %	96.15 %	76.50 %	73.56 %

La tasa de asimiento alcanzó el 97.56 % en las piezas conocidas durante el entrenamiento. Este resultado es relevante considerando la estrecha tolerancia disponible para posicionar el efector final sobre las piezas, tal como se describe en la Sección 4.1.1. En las piezas desconocidas, la tasa disminuyó al 96.15 %.

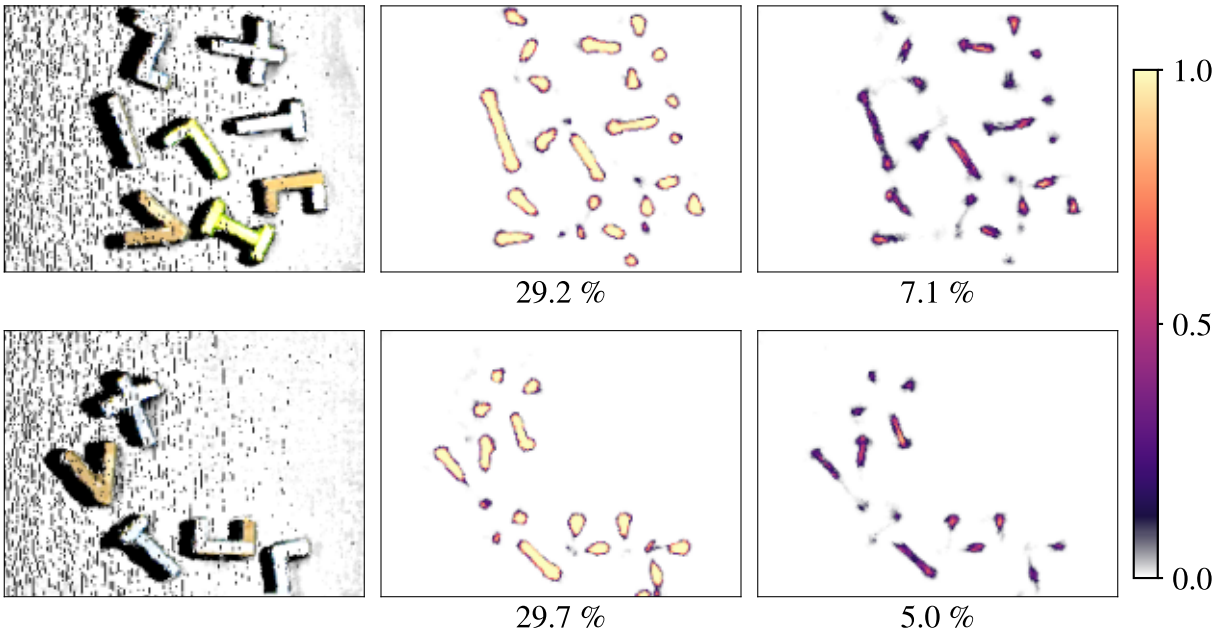
Considerando únicamente los intentos en los que el asimiento fue exitoso y se realizó un lanzamiento, la tasa de lanzamientos exitosos fue del 87.25 % para las piezas conocidas y del 76.50 % para las desconocidas.

El éxito de la tarea completa requiere que ambas etapas se realicen correctamente: primero, el asimiento y, después, el lanzamiento al objetivo asignado. Al considerar la secuencia completa, el sistema alcanzó una tasa de éxito del 85.12 % en las piezas conocidas y del 73.56 % en las desconocidas.

4.5. Análisis de la política de asimiento

4.5.1. Concentración de la política de asimiento

Para analizar el efecto del refinamiento sobre el comportamiento de la política de asimiento, se compararon la red base y la red refinada en las mismas escenas. Para este análisis, los *logits* se transformaron en probabilidades mediante la función sigmoide. Ambas generan mapas de probabilidad claramente distintos que reflejan el criterio con el que fue entrenada cada red. La red base muestra una alta confianza en gran parte de la superficie de las piezas, mientras que la red refinada se concentra únicamente en ciertas zonas, lo que reduce el número total de puntos candidatos de asimiento.



(a) Escena (b) Red base (c) Red refinada

Figura 4.6: Mapas de probabilidad de asimiento sobre dos escenas registradas durante la evaluación; el color está normalizado por mapa. La cifra bajo cada mapa es la fracción de píxeles de la pieza que supera la mitad del máximo alcanzado dentro de ella.

La Figura 4.6 muestra este comportamiento en dos escenas observadas durante la evaluación. Para cada píxel, el mapa representa el valor máximo de probabilidad entre las 32 orientaciones discretas del efector final.

El grado de concentración se cuantificó en 256 escenas. Para cada una se utilizó la máscara de la pieza seleccionada durante el episodio, común a ambas redes, y se midió la fracción de píxeles cuya probabilidad superaba la mitad del valor máximo alcanzado dentro de dicha máscara. En promedio, la red base superó este umbral en el 39.35 % de los píxeles, mientras que la red refinada lo hizo en el 6.92 %. La red refinada resultó más concentrada que la base en las 256 escenas.

La comparación utiliza un umbral relativo porque ambas redes tienen rangos de confianza distintos. La red base prácticamente satura en 1.0 sobre las piezas, mientras que el máximo de la red refinada dentro de la pieza tiene una mediana de 0.71.

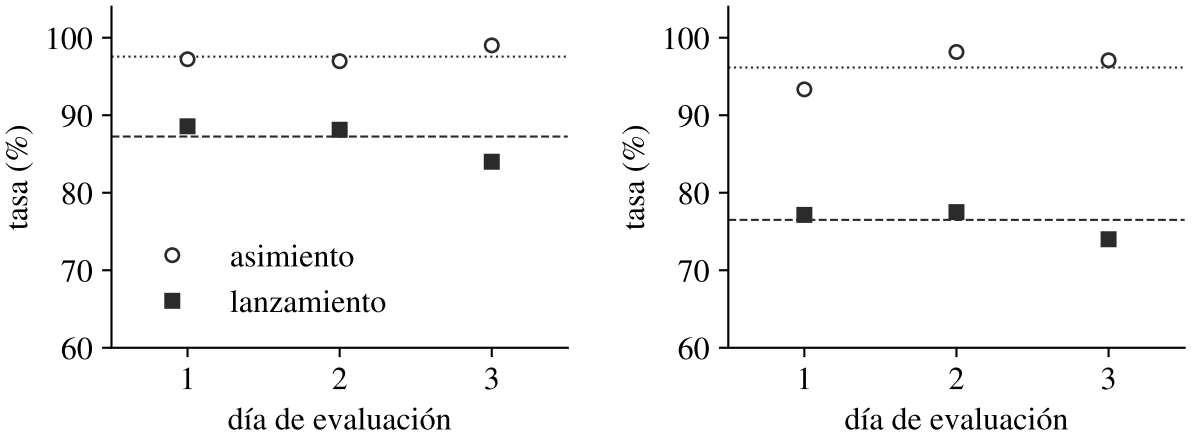
Esta diferencia es consistente con los datos y la función de costo utilizados para entrenar el modelo. La red base fue entrenada únicamente para identificar asimientos viables, por lo que no dispone de información sobre el efecto que una determinada selección tendrá en el lanzamiento. El refinamiento con el resultado del lanzamiento incorpora esta información y orienta la política hacia un conjunto más reducido de candidatos.

4.6. Análisis del desempeño

Los resultados expuestos en la Sección 4.4 describen el comportamiento general del sistema, pero no muestran cómo se distribuye el desempeño a lo largo de la evaluación ni cómo varía entre las distintas piezas y objetivos. Esta sección analiza estos resultados con mayor detalle, considerando los 826 intentos y 800 lanzamientos.

4.6.1. Estabilidad temporal

La evaluación se realizó a lo largo de tres días, con las ocho piezas colocadas conjuntamente sobre la mesa. La Figura 4.7 muestra la tasa de asimiento y la de lanzamiento exitoso de cada día, separadas en piezas conocidas y desconocidas.



(a) Piezas conocidas

(b) Piezas desconocidas

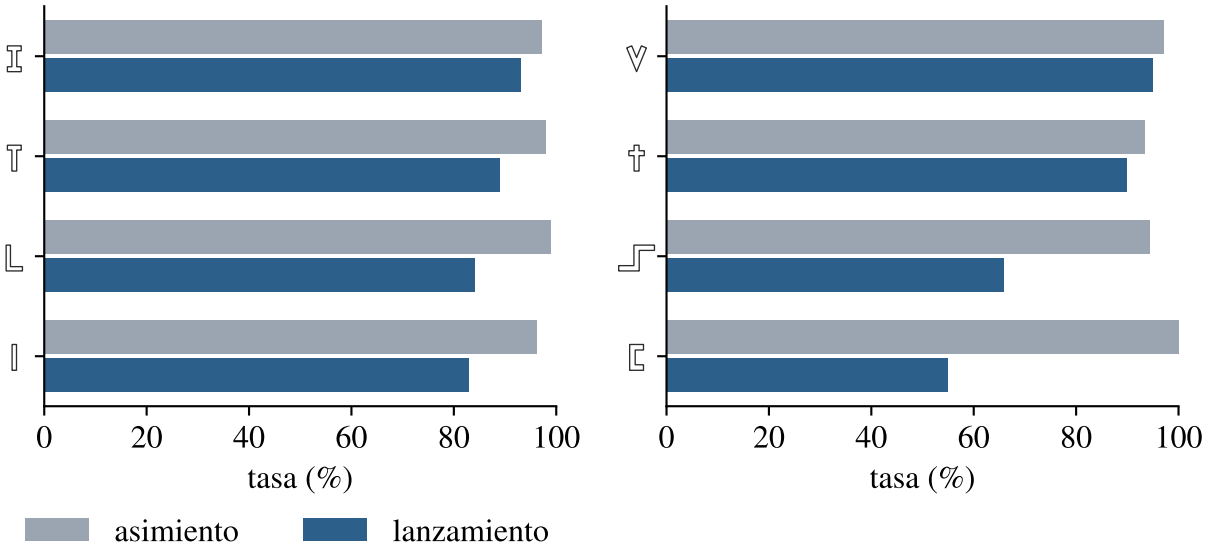
Figura 4.7: Desempeño en cada día de la evaluación. Cada marca es la tasa de ese día y la línea discontinua la tasa global de cada serie.

La tasa de asimiento se mantuvo entre 97.0 % y 99.0 % en las piezas conocidas y entre 93.3 % y 98.2 % en las desconocidas. La tasa de lanzamiento varió entre 84.0 % y 88.6 % y entre 74.0 % y 77.5 %, respectivamente. En los tres días, los valores se mantuvieron próximos a las tasas globales reportadas en la Sección 4.4, de 87.25 % para las piezas conocidas y 76.50 % para las desconocidas, sin observarse una tendencia de mejora o deterioro durante la evaluación.

4.6.2. Desempeño por forma

El desempeño también varía según la forma. En las piezas conocidas durante el entrenamiento, la tasa de asimiento se mantuvo entre 96.2 % y 99.0 %, por lo que las diferencias observadas se concentran principalmente en el lanzamiento. La 𝕀 alcanzó la mayor tasa de lanzamientos exitosos, con 93.0 %, seguida por la 𝕋 con 89.0 % y la 𝕃 con 84.0 %, mientras que la 𝕚 presentó el menor desempeño del conjunto, con 83.0 %. En las piezas desconocidas la dispersión es mayor. La 𝕍 acertó en el 95.0 % de sus lanzamientos y la 𝕥 en el 90.0 %, aunque esta última

registró la menor tasa de asimiento de la evaluación, 93.5 %. En cambio, la 𝔼 se asió en todos sus intentos y la ⅁ en el 94.3 %, pero su tasa de lanzamientos exitosos se redujo a 55.0 % y 66.0 %, respectivamente. La Figura 4.8 reúne estas tasas.



(a) Piezas conocidas

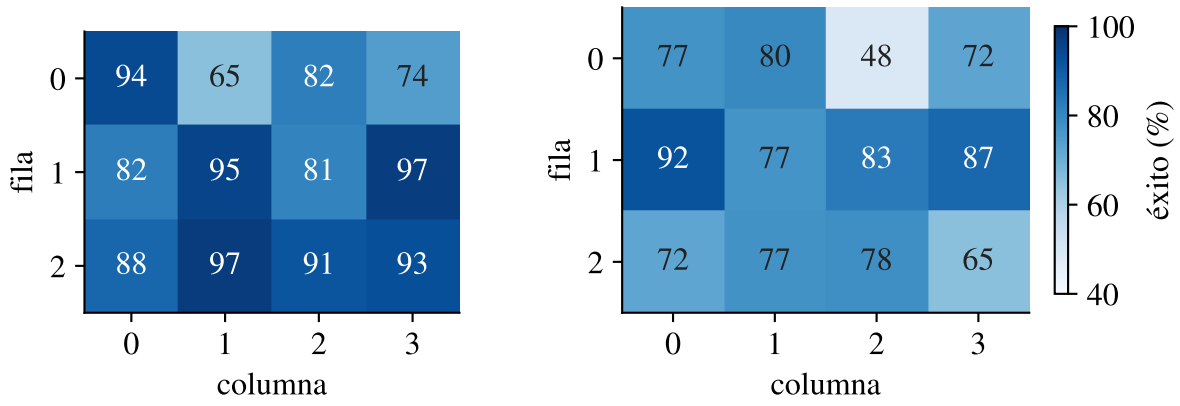
(b) Piezas desconocidas

Figura 4.8: Tasa de asimiento y de lanzamiento exitoso por forma.

4.6.3. Desempeño según el objetivo

El desempeño también varía según el objetivo seleccionado. En las piezas conocidas, al agrupar los objetivos por fila, la fila más cercana y la intermedia alcanzan tasas de lanzamiento exitoso de 92.4 % y 89.1 %, respectivamente, mientras que la fila más alejada presenta el menor desempeño, con 79.5 %. La Figura 4.9 muestra, además, diferencias entre objetivos de la misma fila; en ambos conjuntos la columna 2 concentra la tasa más baja.

En las piezas desconocidas, las tasas agrupadas por fila son 70.2 % en la fila más alejada, 85.4 % en la intermedia y 73.8 % en la más cercana. Los valores individuales son más dispersos que en las piezas conocidas.



(a) Piezas conocidas

(b) Piezas desconocidas

Figura 4.9: Lanzamientos exitosos por objetivo de la matriz. La fila 0 es la más alejada del manipulador y la fila 2 la más cercana; el tono sigue la misma escala en los dos paneles.

4.7. Comparación con el trabajo de referencia

Para poner en contexto los resultados obtenidos, se realiza una comparación con TossingBot (Zeng et al., 2020), que constituye el principal referente del sistema desarrollado. Sin embargo, debe considerarse que ambos sistemas utilizan plataformas distintas, cada una con restricciones propias que condicionaron la elección de los objetos, los objetivos y las condiciones experimentales. Por esta razón, los resultados no deben interpretarse como una comparación directa, sino como una referencia del desempeño obtenido en una tarea similar de asimiento y lanzamiento.

4.7.1. Diferencias de condiciones experimentales

La comparación debe interpretarse considerando que ambos sistemas operan en condiciones experimentales distintas. La Tabla 4.4 resume algunas de las diferencias más importantes entre ambas plataformas y la descripción de los objetos a lanzar se presenta en la Tabla 4.5.

Tabla 4.4: Condiciones experimentales de ambos sistemas.

Característica	**Este trabajo**	**TossingBot**
Manipulador	Sawyer	UR5
Tipo de actuación	Elástica	Rígida
Tipo de efector final	Neumático	Eléctrico
Apertura del efector final	12–24 mm	0–110 mm
Apertura de los objetivos	7.5×15 cm	25×15 cm
Profundidad de los objetivos	8 cm	20 cm

El tamaño de los objetos respecto de la apertura del objetivo también difiere entre ambos sistemas. La Tabla 4.5 expresa cada objeto como una fracción de la apertura a la que debe entrar.

Tabla 4.5: Tamaño de cada objeto en función de la apertura del objetivo. La envolvente es el rectángulo mínimo que contiene al objeto visto desde arriba; las fracciones comparan su lado largo, su lado corto y su área contra los de la apertura. Las dimensiones de los objetos reales de Zeng et al. (2020) no están publicadas, por lo que se emplean los cuatro objetos descritos para la simulación, suponiendo que los objetos desconocidos son de tamaño comparable.

Objeto	**Envolvente (mm)**	**Lado largo**	**Lado corto**	**Área**
Este trabajo, apertura de 150×75 mm				
	94×16	63 %	21 %	13 %
	89×45	59 %	60 %	36 %
	84×53	56 %	71 %	40 %
	86×46	57 %	61 %	35 %
	94×56	63 %	75 %	47 %
	108×78	72 %	104 %	75 %
	84×45	56 %	60 %	34 %
	76×58	51 %	78 %	39 %
Media		*60 %*	*66 %*	*40 %*
TossingBot en simulación, apertura de 250×150 mm				
Esfera, 40 mm de diámetro	40×40	16 %	27 %	4 %
Cubo de 40 mm de lado	40×40	16 %	27 %	4 %
Cilindro, 160×30 mm	160×30	64 %	20 %	13 %
Martillo, 160 mm de largo	160×100	64 %	67 %	43 %
Media		*40 %*	*35 %*	*16 %*

Una de las principales diferencias radica en el efector final. El utilizado en este trabajo tiene una carrera de solo 12 mm, por lo que la tolerancia disponible para realizar cada asimiento es reducida. En contraste, TossingBot utiliza un efector final con una apertura considerablemente mayor, lo que le permite trabajar con una mayor variedad de tamaños y formas.

También existen diferencias importantes en los objetivos. En este trabajo se utilizaron aperturas de 7.5×15 cm, mientras que las empleadas en TossingBot son considerablemente mayores. Aunque se buscó mantener una proporción adecuada entre las dimensiones de los objetos y las de los objetivos, algunos de ellos ocupan una fracción considerable de la apertura disponible, por lo que queda una tolerancia menor para que el objeto quede dentro del objetivo.

Estas diferencias, junto con las características propias de cada manipulador y del conjunto de objetos utilizado, deben considerarse al interpretar los porcentajes que se presentan a continuación.

4.7.2. Métrica y desempeño

La Tabla 4.6 compara el desempeño en asimiento y lanzamiento de ambos sistemas, tanto para objetos conocidos como para desconocidos, así como el éxito en la tarea completa.

En la etapa de asimiento, el sistema desarrollado obtuvo una tasa de éxito superior a la reportada por TossingBot, tanto para los objetos conocidos como para los desconocidos. Esta diferencia podría estar relacionada con el uso de etiquetas densas durante el entrenamiento de

Tabla 4.6: Desempeño de asimiento, de lanzamiento y de la tarea completa sobre el robot físico. Las tasas por etapa de la referencia son las publicadas en Zeng et al. (2020); las de la tarea completa se obtienen al componer ambas. Las tres variantes de la referencia son la que corrige el lanzamiento con física residual, la que usa únicamente el modelo balístico y la que estima la velocidad por regresión directa. En negritas el mejor valor de cada columna.

	Objetos conocidos			**Objetos desconocidos**		
Método	Asimiento	Lanzamiento	Tarea	Asimiento	Lanzamiento	Tarea
TossingBot, regresión	83.40 %	54.20 %	45.20 %	75.60 %	52.00 %	39.31 %
TossingBot, física	85.70 %	61.30 %	52.53 %	76.40 %	58.50 %	44.69 %
TossingBot, residual	86.90 %	84.70 %	73.60 %	73.20 %	**82.30 %**	60.24 %
Este trabajo	**97.56 %**	**87.25 %**	**85.12 %**	**96.15 %**	76.50 %	**73.56 %**

la política de asimiento, aunque no se realizó un experimento específico para aislar el efecto de dicha estrategia. En cuanto al lanzamiento, el desempeño obtenido fue superior al reportado por TossingBot en los objetos conocidos, 87.25 % frente a 84.70 %, e inferior en los desconocidos, 76.50 % frente a 82.30 %.

Finalmente, al considerar el éxito de la tarea completa, es decir, que el sistema consiga tanto asir correctamente el objeto como lanzarlo al objetivo correspondiente, se obtuvo una mayor tasa de éxito en ambos conjuntos.

Sin embargo, estas diferencias no deben interpretarse como una comparación directa entre los métodos, ya que, como se detalló en la Sección 4.7.1, existen diferencias importantes entre las plataformas utilizadas y las condiciones experimentales, que condicionaron tanto los objetos empleados como las dimensiones de los objetivos.

4.7.3. Velocidad de operación

Otra métrica relevante para la comparación es la velocidad de operación del sistema. En TossingBot (Zeng et al., 2020) se reportan 608 intentos por hora, lo que equivale a un ciclo de aproximadamente 5.92 s. Con una tasa de éxito en la tarea completa del 73.6 % para los objetos conocidos, esto equivale a aproximadamente 447 lanzamientos exitosos por hora.

En el sistema desarrollado, la duración mediana del ciclo completo es de 17.12 s. De este tiempo, 9.73 s corresponden a la ejecución del asimiento y su verificación.

La Figura 4.10 muestra la duración mediana de cada fase por separado; su suma, 16.88 s, no coincide exactamente con la mediana del ciclo completo porque las fases no alcanzan su valor mediano en el mismo episodio. La etapa de asimiento requiere que el robot opere a una velocidad relativamente baja durante el acercamiento a la pieza. Debido a la reducida tolerancia disponible para posicionar el efector final, este movimiento debe realizarse evitando colisiones con la propia pieza, las piezas cercanas y la superficie de trabajo.

A partir de la duración mediana del ciclo, el sistema podría realizar aproximadamente 210 intentos por hora si mantuviera este ritmo de forma continua y se le proporcionaran piezas de manera constante. Al considerar las tasas de éxito de la tarea completa, esto correspondería a aproximadamente 179 piezas lanzadas exitosamente por hora para las piezas conocidas y 155 para las desconocidas.

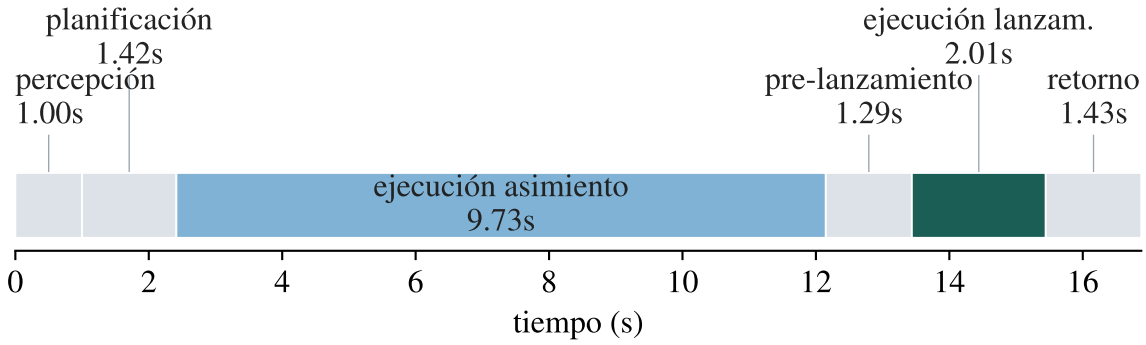


Figura 4.10: Duración mediana de las fases del ciclo de operación. La suma de las medianas es de 16.88 s.

4.8. Limitaciones

Los resultados presentados deben interpretarse considerando las condiciones del montaje experimental y del conjunto de evaluación.

Los conjuntos utilizados se componen de formas rectilíneas. Aunque las piezas desconocidas permiten evaluar la capacidad de generalización del sistema, todas están compuestas por segmentos rectos que, localmente, presentan características similares entre sí y, además, se encuentran dentro de un rango de dimensiones relativamente restringido. Por esta razón, las formas evaluadas no representan la variedad de objetos que pueden encontrarse en un entorno no estructurado.

Además, se utilizó solamente un ejemplar físico de cada forma. Debido a las irregularidades introducidas durante la fabricación, el porcentaje de éxito de cada pieza puede verse afectado, positiva o negativamente, por las características particulares de ese ejemplar, como pequeñas variaciones en la sección transversal, la rectitud de los segmentos o la tolerancia disponible para realizar el asimiento.

Las distancias de los objetivos también se vieron condicionadas por la velocidad máxima que el manipulador puede alcanzar. Por tanto, los resultados obtenidos caracterizan el sistema únicamente dentro del rango de operación estudiado. A medida que aumenta la distancia entre los objetivos y el manipulador, también aumenta la velocidad requerida para alcanzarlos, lo que puede incrementar la influencia de los errores de seguimiento y de la dinámica no modelada.

Finalmente, las dimensiones de las piezas evaluadas limitan la distancia máxima entre el punto de asimiento y el centro de masa. En piezas de mayor longitud o con regiones de asimiento más alejadas de este, los efectos asociados a la dinámica de la pieza podrían cobrar mayor importancia. Por ello, los resultados obtenidos no permiten determinar si la corrección global empleada en este trabajo seguiría siendo suficiente para otro tipo de piezas o si sería necesario incorporar una corrección residual dependiente del asimiento.

Capítulo 5

Conclusiones

5.1. Cumplimiento de los objetivos

El trabajo permitió integrar una estrategia de aprendizaje basada en simulación con la percepción, planificación y ejecución de asimientos y lanzamientos en el robot Sawyer. La política entrenada se transfirió a la plataforma física sin modificar los parámetros de la red y permitió realizar la tarea hacia objetivos fuera del alcance directo del manipulador.

Durante la evaluación física, la política mostró una alta efectividad de asimiento tanto con las piezas conocidas durante el entrenamiento como con las desconocidas. El desempeño del lanzamiento fue inferior al del asimiento, como era de esperarse, ya que depende con mayor sensibilidad de las condiciones alcanzadas en la liberación y de efectos que no se reproducen completamente en simulación, como los errores de seguimiento, el contacto con el efector final y las irregularidades de las piezas. Aun así, permitió completar la tarea en una proporción considerable de los ensayos.

La tasa de asimiento fue del 97.56 % para las piezas conocidas y del 96.15 % para las desconocidas. Considerando únicamente los asimientos exitosos, el lanzamiento alcanzó el objetivo en el 87.25 % y el 76.50 % de los casos, respectivamente, con lo que la tarea completa se logró en el 85.12 % y el 73.56 % de los intentos. En simulación, el refinamiento con el resultado del lanzamiento elevó el éxito de la tarea completa del 66.6 % de la red base al 94.1 %.

Los resultados experimentales permiten evaluar la transferencia de la política aprendida en simulación al robot físico y su comportamiento ante piezas no utilizadas durante el entrenamiento. Sin embargo, los experimentos realizados no permiten cuantificar de manera aislada cuánto contribuyó el entrenamiento inicial con etiquetas densas ni determinar si este redujo el número de episodios necesarios durante el refinamiento.

Dentro del dominio evaluado, estos resultados respaldan la hipótesis planteada, ya que fue posible ejecutar la tarea utilizando la selección aprendida del asimiento y una corrección global de la velocidad, sin incorporar un modelo residual dependiente de cada pieza o asimiento.

5.2. Aportaciones

Las principales aportaciones del trabajo se encuentran en la generación de supervisión para el asimiento, el refinamiento de la política a partir del resultado del lanzamiento y la transferencia de la política aprendida en simulación a la plataforma física.

Se desarrolló un procedimiento de etiquetado automático basado en criterios geométricos y en las dimensiones del efector final. Este procedimiento permite generar supervisión densa para múltiples posiciones y orientaciones de asimiento dentro de una misma escena sin ejecutar individualmente cada acción. Su aplicación resulta especialmente útil en el sistema considerado, donde la apertura reducida del efector final deja una tolerancia limitada para posicionar correctamente los dedos.

A partir de esta supervisión se desarrolló una estrategia de entrenamiento en dos etapas. Primero se obtiene una política capaz de identificar asimientos geométricamente viables y, después, se refina mediante lanzamientos en simulación. Con ello, el resultado de la tarea subsecuente se incorpora a la valoración de los asimientos sin iniciar el aprendizaje mediante una exploración completamente aleatoria.

Finalmente, se integraron la percepción, la selección del asimiento, el cálculo de las condiciones de lanzamiento y la planificación del movimiento en un sistema completo para el robot Sawyer. Tanto el entrenamiento inicial como el refinamiento se realizaron en simulación, y la política resultante se transfirió directamente a la plataforma física para su evaluación. La ejecución del lanzamiento requirió una corrección global de la velocidad comandada, obtenida experimentalmente para compensar las diferencias sistemáticas entre el movimiento planificado y el ejecutado.

5.3. Trabajo futuro

Una primera extensión consiste en ampliar las posibilidades de asimiento para trabajar con piezas apiladas. Esto podría comenzar por considerar distintas alturas de asimiento y luego extenderse a aproximaciones inclinadas o laterales. Para ello sería necesario ampliar la representación de las acciones y adaptar la percepción y la planificación para tratar las oclusiones y evitar colisiones con otras piezas.

Otra línea de trabajo consiste en ampliar la primitiva de lanzamiento. El uso de más articulaciones y una selección más flexible de la posición, la dirección y el ángulo de liberación permitirían explorar movimientos que la primitiva actual no contempla. A partir de esta formulación podrían incorporarse obstáculos, considerando tanto las colisiones del manipulador durante el movimiento como la trayectoria de la pieza durante el vuelo. El beneficio de esta mayor libertad tendría que evaluarse frente al costo de planificación y las capacidades de ejecución del robot.

Finalmente, la tarea podría extenderse a objetivos móviles. En este caso sería necesario estimar la posición del objetivo en el instante de llegada de la pieza y coordinar la liberación con el tiempo de vuelo. Esta extensión requeriría estudiar el efecto de los errores de percepción, de la predicción del movimiento del objetivo y de la ejecución del lanzamiento.

Bibliografía

Andersson, J. A. E., Gillis, J., Horn, G., Rawlings, J. B., y Diehl, M. (2019). CasADi: A software framework for nonlinear optimization and optimal control. *Mathematical Programming Computation*, 11(1):1–36.

Carpentier, J., Saurel, G., Buondonno, G., Mirabel, J., Lamiraux, F., Stasse, O., y Mansard, N. (2019). The Pinocchio C++ library: A fast and flexible implementation of rigid body dynamics algorithms and their analytical derivatives. En *Proceedings of the IEEE/SICE International Symposium on System Integration (SII)*, páginas 614–619.

Domae, Y., Okuda, H., Taguchi, Y., Sumi, K., y Hirai, T. (2014). Fast graspability evaluation on single depth maps for bin picking with general grippers. En *Proceedings of the IEEE International Conference on Robotics and Automation (ICRA)*, páginas 1997–2004.

Fang, K., Zhu, Y., Garg, A., Kurenkov, A., Mehta, V., Fei-Fei, L., y Savarese, S. (2020). Learning task-oriented grasping for tool manipulation from simulated self-supervision. *The International Journal of Robotics Research*, 39(2-3):202–216.

Flacco, F., De Luca, A., y Khatib, O. (2015). Control of redundant robots under hard joint constraints: Saturation in the null space. *IEEE Transactions on Robotics*, 31(3):637–654.

Garrido-Jurado, S., Muñoz-Salinas, R., Madrid-Cuevas, F. J., y Marín-Jiménez, M. J. (2014). Automatic generation and detection of highly reliable fiducial markers under occlusion. *Pattern Recognition*, 47(6):2280–2292.

Jiang, Y., Moseson, S., y Saxena, A. (2011). Efficient grasping from RGBD images: Learning using a new rectangle representation. En *Proceedings of the IEEE International Conference on Robotics and Automation (ICRA)*, páginas 3304–3311.

Kasaei, H. y Kasaei, M. (2023). Throwing objects into a moving basket while avoiding obstacles. En *Proceedings of the IEEE International Conference on Robotics and Automation (ICRA)*, páginas 3051–3057.

Kasaei, H. y Kasaei, M. (2024). Harnessing the synergy between pushing, grasping, and throwing to enhance object manipulation in cluttered scenarios. En *Proceedings of the IEEE International Conference on Robotics and Automation (ICRA)*, páginas 13855–13861.

Kelly, M. (2017). An introduction to trajectory optimization: How to do your own direct collocation. *SIAM Review*, 59(4):849–904.

LeCun, Y., Bottou, L., Bengio, Y., y Haffner, P. (1998). Gradient-based learning applied to document recognition. *Proceedings of the IEEE*, 86(11):2278–2324.

Lenz, I., Lee, H., y Saxena, A. (2015). Deep learning for detecting robotic grasps. *The International Journal of Robotics Research*, 34(4-5):705–724.

Levine, S., Pastor, P., Krizhevsky, A., Ibarz, J., y Quillen, D. (2018). Learning hand-eye coordination for robotic grasping with deep learning and large-scale data collection. *The International Journal of Robotics Research*, 37(4-5):421–436.

Liu, Y. y Billard, A. (2024). Tube acceleration: Robust dexterous throwing against release uncertainty. *IEEE Transactions on Robotics*, 40:2831–2849.

Long, J., Shelhamer, E., y Darrell, T. (2015). Fully convolutional networks for semantic segmentation. En *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, páginas 3431–3440.

Lynch, K. M. y Mason, M. T. (1999). Dynamic nonprehensile manipulation: Controllability, planning, and experiments. *The International Journal of Robotics Research*, 18(1):64–92.

Lynch, K. M. y Park, F. C. (2017). *Modern Robotics: Mechanics, Planning, and Control*. Cambridge University Press.

Mahler, J., Liang, J., Niyaz, S., Laskey, M., Doan, R., Liu, X., Aparicio, J., y Goldberg, K. (2017). Dex-Net 2.0: Deep learning to plan robust grasps with synthetic point clouds and analytic grasp metrics. En *Robotics: Science and Systems XIII*.

Mason, M. T. (2001). *Mechanics of Robotic Manipulation*. MIT Press, Cambridge, MA.

Miyashita, H., Yamawaki, T., y Yashima, M. (2009). Control for throwing manipulation by one joint robot. En *Proceedings of the IEEE International Conference on Robotics and Automation (ICRA)*, páginas 1273–1278.

Miyashita, H., Yamawaki, T., y Yashima, M. (2011). Parts assembly and sorting by throwing manipulation: Planning and control. *Journal of System Design and Dynamics*, 5(1):139–154.

Morrison, D., Leitner, J., y Corke, P. (2018). Closing the loop for robotic grasping: A real-time, generative grasp synthesis approach. En *Robotics: Science and Systems XIV*.

Pinto, L. y Gupta, A. (2016). Supersizing self-supervision: Learning to grasp from 50k tries and 700 robot hours. En *Proceedings of the IEEE International Conference on Robotics and Automation (ICRA)*, páginas 3406–3413.

Pratt, G. A. y Williamson, M. M. (1995). Series elastic actuators. En *Proceedings of the IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, volumen 1, páginas 399–406.

Redmon, J. y Angelova, A. (2015). Real-time grasp detection using convolutional neural networks. En *Proceedings of the IEEE International Conference on Robotics and Automation (ICRA)*, páginas 1316–1322.

Rethink Robotics (2018). Sawyer collaborative robot: Product specifications. Ficha técnica del fabricante.

Robbins, H. y Monro, S. (1951). A stochastic approximation method. *The Annals of Mathematical Statistics*, 22(3):400–407.

Ronneberger, O., Fischer, P., y Brox, T. (2015). U-Net: Convolutional networks for biomedical image segmentation. En *Medical Image Computing and Computer-Assisted Intervention (MICCAI)*, volumen 9351 de *Lecture Notes in Computer Science*, páginas 234–241. Springer.

Saxena, A., Driemeyer, J., y Ng, A. Y. (2008). Robotic grasping of novel objects using vision. *The International Journal of Robotics Research*, 27(2):157–173.

Shoemake, K. (1985). Animating rotation with quaternion curves. En *Proceedings of the 12th Annual Conference on Computer Graphics and Interactive Techniques*, páginas 245–254.

Sutton, R. S. y Barto, A. G. (2018). *Reinforcement Learning: An Introduction*. MIT Press, Cambridge, MA, 2 edition.

Todorov, E., Erez, T., y Tassa, Y. (2012). MuJoCo: A physics engine for model-based control. En *Proceedings of the IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, páginas 5026–5033.

Wächter, A. y Biegler, L. T. (2006). On the implementation of an interior-point filter line-search algorithm for large-scale nonlinear programming. *Mathematical Programming*, 106(1):25–57.

Zakka, K., Tassa, Y., y MuJoCo Menagerie Contributors (2022). MuJoCo Menagerie: A collection of high-quality simulation models for MuJoCo. https://github.com/google-deepmind/mujoco_menagerie.

Zeng, A., Song, S., Lee, J., Rodriguez, A., y Funkhouser, T. (2020). TossingBot: Learning to throw arbitrary objects with residual physics. *IEEE Transactions on Robotics*, 36(4):1307–1319.

Zhang, L., Bai, K., Chen, Z., Shi, Y., y Zhang, J. (2022). Towards precise model-free robotic grasping with sim-to-real transfer learning. En *Proceedings of the IEEE International Conference on Robotics and Biomimetics (ROBIO)*, páginas 1–8.

Zheng, Y., Yao, L., Su, Y., Zhang, Y., Wang, Y., Zhao, S., Zhang, Y., y Chau, L.-P. (2025). A survey of embodied learning for object-centric robotic manipulation. *Machine Intelligence Research*, 22(4):588–626.

Apéndice A

Generación de escenas y etiquetado automático de asimientos

Este apéndice describe el procedimiento utilizado para construir las escenas y generar las etiquetas de asimiento empleadas en la primera etapa de entrenamiento. Para cada escena se obtiene una observación RGB-D y se evalúan automáticamente las posibles acciones de asimiento a partir de la geometría de las piezas y de las dimensiones del efector final. Este procedimiento permite obtener supervisión sobre múltiples posiciones y orientaciones sin ejecutar físicamente cada asimiento.

A.1. Piezas utilizadas

El catálogo utilizado para el entrenamiento inicial contiene 60 piezas rígidas con diferentes formas y dimensiones. Todas tienen un espesor de 19 mm y una sección transversal compatible, en distintos grados, con la apertura reducida del efector final.

El catálogo incluye además las dimensiones exactas de cuatro de las piezas utilizadas en los experimentos físicos: una barra y las piezas en L, T e I. De esta manera, el conjunto contiene tanto variaciones generadas para el entrenamiento como algunos casos que tienen una contraparte directa en la plataforma física.

A.1.1. Piezas utilizadas durante el refinamiento

Para la etapa de refinamiento se utilizó un conjunto reducido de piezas. Se excluyeron configuraciones cuya geometría producía de manera repetida asimientos poco informativos para esta etapa, como se distingue por color en la Figura A.1.

Los cuadrados dejan una holgura mínima respecto de la apertura del efector final, por lo que pequeños errores en la ejecución provocaban secuencias de asimientos fallidos. Las piezas con secciones transversales de 18, 19 y 20 mm presentaban un comportamiento similar y quedaban fuera del rango en el que el refinamiento mostró un desempeño estable. Las piezas en Y se excluyeron debido a su baja tasa de éxito de lanzamiento condicionado al asimiento, cercana al 31 %.

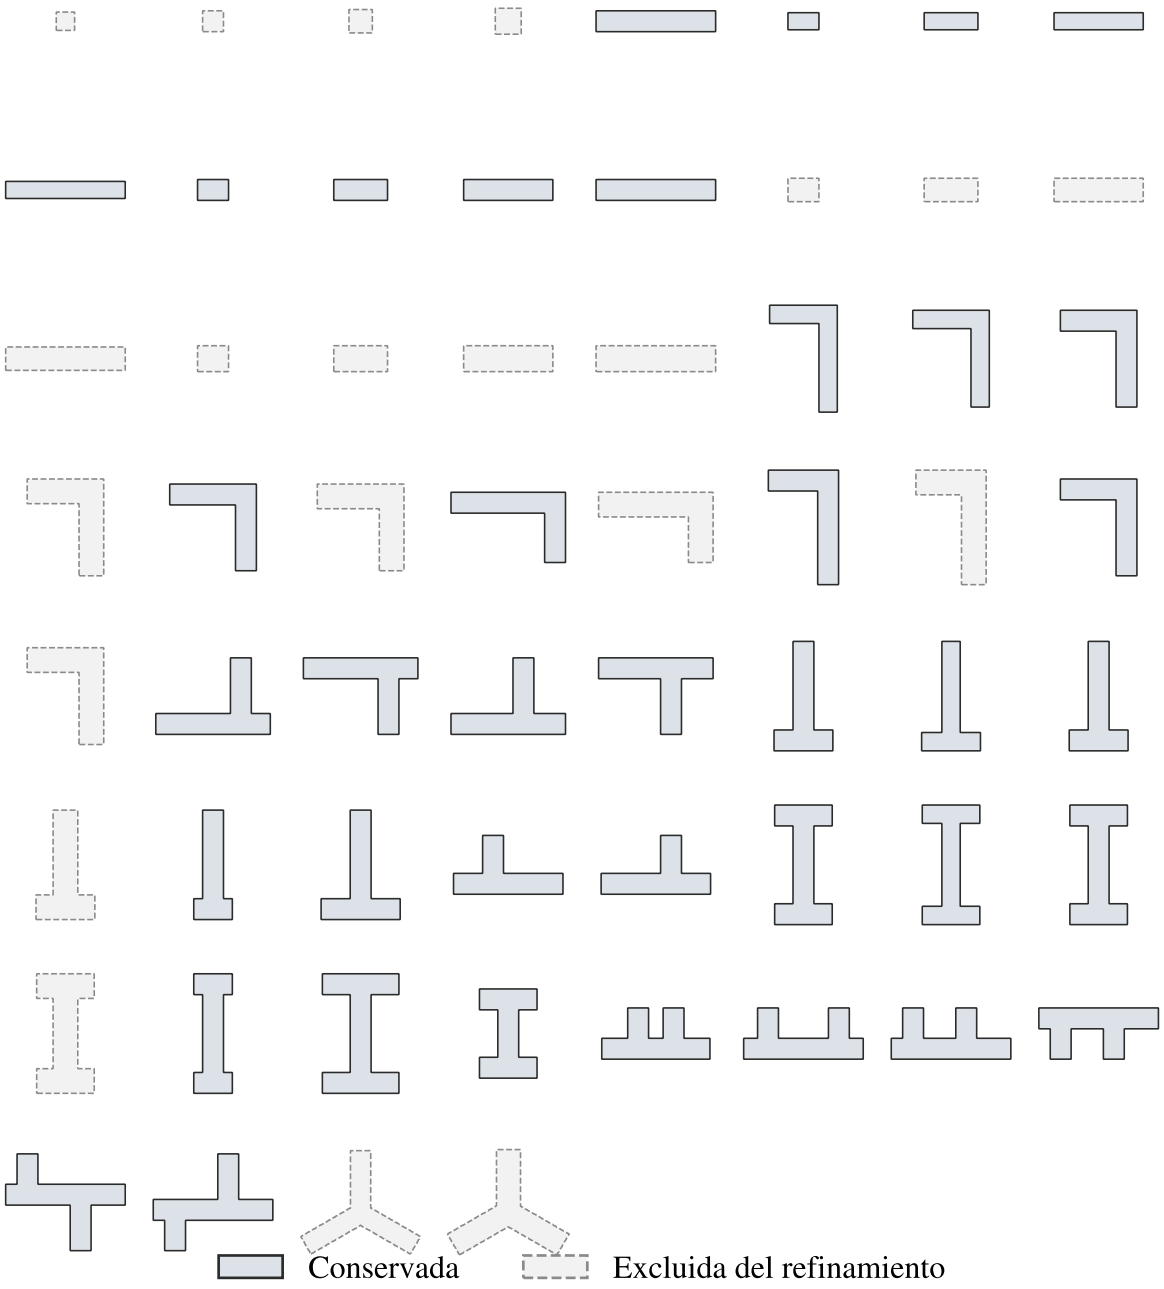


Figura A.1: Formas de las 60 piezas del catálogo de entrenamiento inicial sobre el plano de la mesa, a la misma escala. El color y el trazo de cada silueta indican si la pieza se conservó o se excluyó para la etapa de refinamiento.

El conjunto utilizado finalmente para el refinamiento contiene 39 piezas.

A.2. Construcción de las escenas

Cada escena contiene entre una y diez piezas distribuidas sobre la mesa con posiciones, orientaciones y separaciones variables. Como resultado, las piezas pueden permanecer separadas o quedar en contacto unas con otras. Una vez estabilizada la escena, la misma disposición se utiliza para generar la observación RGB-D y las etiquetas correspondientes.

La retícula utilizada para el etiquetado coincide con la resolución espacial del mapa de alturas, de modo que cada celda representa una posición de 2 mm en el espacio de trabajo. Para cada celda se identifica directamente, a partir de la geometría de la escena, si existe una pieza en esa posición y cuál es la altura local de su superficie. Las celdas vacías reciben una etiqueta negativa. En las celdas ocupadas, la altura del asimiento se fija a la mitad de la altura local de la pieza respecto de la mesa.

Para cada posición se consideran 32 orientaciones separadas 11.25°. Debido a la simetría del efector final, dos orientaciones separadas 180° son equivalentes al evaluar únicamente la viabilidad geométrica del asimiento. Por esta razón, el criterio se calcula para 16 orientaciones y cada resultado se copia a la orientación opuesta para completar las 32 acciones.

Esta simetría se utiliza únicamente durante la generación de las etiquetas de asimiento. Durante el lanzamiento, las orientaciones separadas 180° se mantienen como acciones diferentes, ya que la orientación de la pieza respecto de la dirección del movimiento puede modificar el resultado del lanzamiento.

A.3. Criterio de viabilidad del asimiento

Cada candidato se evalúa a partir de la posición y orientación del efector final y de la geometría de las piezas presentes en la escena. Primero se comprueba que las dimensiones de la pieza sean compatibles con la apertura del efector. Después se verifica que los dedos puedan descender hasta la altura de asimiento sin colisionar con la propia pieza ni con las cercanas.

Cada dedo se representa mediante una huella de colisión rectangular de 30×15 mm sobre el plano horizontal. Estas dimensiones corresponden a la geometría del efector final utilizada para construir su modelo. Durante la comprobación se considera el volumen recorrido por ambas huellas desde la posición inicial de aproximación hasta la altura del asimiento.

La separación entre los dedos en el modelo reproduce la del efector físico, con una apertura entre 12 y 24 mm. Para introducir una pequeña tolerancia frente a errores de posicionamiento, cada huella de colisión se amplía 1 mm por lado en el plano horizontal.

Una acción recibe una etiqueta positiva cuando la posición corresponde a una pieza compatible con la apertura del efector y ninguno de los dedos presenta una colisión durante el descenso. En cualquier otro caso se asigna una etiqueta negativa.

El criterio únicamente comprueba la viabilidad geométrica de la acción. No se simulan el cierre del efector ni la elevación de la pieza, por lo que una etiqueta positiva no representa un asimiento ejecutado con éxito. Tampoco se evalúa en esta etapa la trayectoria completa del manipulador, que se verifica después mediante el planificador.

El procedimiento puede resumirse de la siguiente manera.

1. Se genera la disposición de las piezas y se obtiene la observación RGB-D.

2. Para cada celda se identifica la pieza presente y la altura correspondiente.

3. Las posiciones que no contienen una pieza se etiquetan como negativas.

4. Para cada posición ocupada se evalúan las 16 orientaciones distintas respecto de la simetría del efector final.

5. Para cada candidato se comprueba la compatibilidad con la apertura y la ausencia de colisiones durante el descenso de los dedos.

6. El resultado se copia a la orientación opuesta para completar las 32 orientaciones almacenadas.

La Figura 3.14 muestra ejemplos de los mapas obtenidos. Las regiones próximas a los bordes, uniones entre segmentos u otras piezas pueden quedar descartadas cuando el descenso de alguno de los dedos produce una colisión. Por tanto, una etiqueta negativa indica que la acción fue rechazada por el criterio de viabilidad y no que la posición carezca de supervisión.

A.4. Parámetros de generación

La Tabla A.1 resume los valores utilizados para generar las escenas y las etiquetas del entrenamiento inicial.

Tabla A.1: Configuración del etiquetado geométrico utilizado en el entrenamiento inicial.

Parámetro	Valor
Escenas	1 000
Piezas por escena	1–10
Piezas disponibles	60
Espesor de las piezas	19 mm
Resolución espacial	2 mm
Orientaciones almacenadas	32
Orientaciones evaluadas	16
Separación angular	11.25°
Huella de cada dedo	30×15 mm
Apertura utilizada en el modelo	12–24 mm
Margen horizontal de colisión	1 mm por lado
Penetración admitida	0 mm
Ejecución del cierre y elevación	no

Para reproducir los conjuntos generados se conservan la semilla utilizada para construir las escenas, la selección de piezas y las variaciones aplicadas durante la generación de las observaciones.

Apéndice B

Formulación de los problemas de planificación

Este apéndice presenta las formulaciones discretas de los problemas de optimización utilizados para generar los movimientos articulares, cartesianos y de lanzamiento descritos en la Sección 3.3. Las restricciones articulares se toman del modelo del Sawyer y los límites de velocidad y aceleración se ajustan según el tipo de movimiento.

B.1. Límites del manipulador

Los tres problemas comparten los límites de posición articular del modelo del Sawyer. Los límites de velocidad y aceleración dependen del tipo de movimiento, mientras que los límites de par se muestran en la Tabla B.1. Las restricciones articulares son

$$\theta_{\text{mín}} \leq \theta_k \leq \theta_{\text{máx}}, \qquad |\dot{\theta}_k| \leq \dot{\theta}_{\text{máx}}, \qquad |\ddot{\theta}_k| \leq \ddot{\theta}_{\text{máx}}. \tag{B.1}$$

Tabla B.1: Límites de posición y de par del robot Sawyer.

Articulación	j_0	j_1	j_2	j_3	j_4	j_5	j_6
$\theta_{\text{mín}}$ [rad]	−3.050	−3.810	−3.043	−3.044	−2.976	−2.976	−4.712
$\theta_{\text{máx}}$ [rad]	3.050	2.274	3.043	3.044	2.976	2.976	4.712
$\tau_{\text{máx}}$ [N·m]	80	80	40	40	9	9	9

Los límites de velocidad y aceleración se establecen de acuerdo con la fase del movimiento. En el caso del lanzamiento, donde estos valores afectan directamente las condiciones de liberación alcanzables, los límites utilizados se indican explícitamente en la Sección B.4.

B.2. Movimiento articular

Se emplean N nodos y un paso $\Delta t = t_f/(N-1)$. La duración t_f se calcula antes de resolver el problema, a partir del perfil presentado en la Sección 2.2.1, que también define las referencias

θ_k^{ref}, $\dot{\theta}_k^{\text{ref}}$ y $\ddot{\theta}_k^{\text{ref}}$. El costo es

$$\begin{aligned}\mathcal{J}_{\text{art}} = \sum_{k=0}^{N-1} \big(&10\|\theta_k - \theta_k^{\text{ref}}\|^2 + \|\dot{\theta}_k - \dot{\theta}_k^{\text{ref}}\|^2 \\ &+ 0.5\|\ddot{\theta}_k - \ddot{\theta}_k^{\text{ref}}\|^2 + \|\ddot{\theta}_k\|^2\big).\end{aligned} \tag{B.2}$$

El problema se resuelve sobre las posiciones, velocidades y aceleraciones articulares:

$$\begin{aligned}\min_{\{\theta_k,\dot{\theta}_k,\ddot{\theta}_k\}} \quad & \mathcal{J}_{\text{art}} \\ \text{s.a.} \quad & \theta_{\text{mín}} \le \theta_k \le \theta_{\text{máx}}, \\ & |\dot{\theta}_k| \le \dot{\theta}_{\text{máx}}, \qquad |\ddot{\theta}_k| \le \ddot{\theta}_{\text{máx}}, \\ & \theta_{k+1} = \theta_k + \Delta t\, \dot{\theta}_k, \\ & \dot{\theta}_{k+1} = \dot{\theta}_k + \Delta t\, \ddot{\theta}_k, \\ & \theta_0 = \theta_{\text{ini}}, \qquad \dot{\theta}_0 = 0, \\ & \theta_{N-1} = \theta_{\text{fin}}, \qquad \dot{\theta}_{N-1} = 0.\end{aligned} \tag{B.3}$$

B.3. Movimiento cartesiano

La duración t_f también se calcula antes de resolver el problema, a partir de la distancia entre la posición inicial p_0 y la deseada p_d del efector final y del menor de los límites de velocidad articular del perfil de movimiento,

$$t_f = \text{máx}\left(\frac{\|p_d - p_0\|}{0.15\ \text{mín}_i\, \dot{\theta}_{i_{\text{máx}}}},\ 0.5\,\text{s}\right), \tag{B.4}$$

donde el factor 0.15 convierte el límite articular en una rapidez lineal nominal y el segundo argumento impone la duración mínima.

Las referencias cartesianas se construyen mediante interpolación lineal de la posición y SLERP de la orientación. El costo es

$$\begin{aligned}\mathcal{J}_{\text{cart}} = \sum_{k=0}^{N-1} \big(&5000\|p(\theta_k) - p_k^{\text{ref}}\|^2 \\ &+ 5000[1 - \langle q(\theta_k), q_k^{\text{ref}}\rangle^2] \\ &+ 5\|\theta_k - \theta_k^{\text{ref}}\|^2 + \|\dot{\theta}_k\|^2 + \|\ddot{\theta}_k\|^2\big).\end{aligned} \tag{B.5}$$

Se utilizan las mismas restricciones articulares y ecuaciones de integración de Euler del problema anterior. La condición terminal se impone sobre la pose del efector final,

$$\|p(\theta_{N-1}) - p_d\|^2 \le \varepsilon_p^2, \qquad 1 - \langle q(\theta_{N-1}), q_d\rangle^2 \le \varepsilon_o, \tag{B.6}$$

con $\varepsilon_p = 0.5\,\text{mm}$ y $\varepsilon_o = 0.01$. La primera tolerancia corresponde al error de posición, mientras que la segunda es adimensional y limita el error de orientación mediante la cantidad $1 - \langle q, q_d\rangle^2$, que vale cero cuando ambas orientaciones coinciden.

B.4. Lanzamiento

El lanzamiento utiliza las tres articulaciones activas presentadas en la Sección 3.3.5. En este problema, N denota el número de intervalos; $N+1$ nodos y $\Delta t = t_f/N$, con t_f variable. Las posiciones y velocidades cartesianas se expresan en el marco del plano de lanzamiento, una vez fijada la dirección de la base.

Sea $\hat{v}$ la velocidad solicitada al planificador y $\hat{r}$ la posición de liberación de referencia. El costo completo es

$$\begin{aligned}\mathcal{J}_{\text{lan}} = {} & \frac{\|r-\hat{r}\|^2}{3} + 0.05 t_f \\ & + \frac{10^{-4}}{3(N+1)} \sum_{k=0}^{N} \|\ddot{\theta}_{a,k}\|^2 \\ & + \frac{10^{-3}}{3N} \sum_{k=0}^{N-1} \left\| \frac{\ddot{\theta}_{a,k+1} - \ddot{\theta}_{a,k}}{\Delta t} \right\|^2 + \frac{0.5}{3} \|\theta_{a,0} - \theta_a^{\text{ref}}\|^2,\end{aligned} \tag{B.7}$$

donde θ_a^{ref} es la configuración inicial de referencia del barrido y el factor 3 corresponde al número de articulaciones activas o de componentes de posición, según el término.

$$\begin{aligned}\min_{t_f, \{\theta_{a,k}, \dot{\theta}_{a,k}, \ddot{\theta}_{a,k}\}} \quad & \mathcal{J}_{\text{lan}} \\ \text{s.a.} \quad & t_{f_{\text{mín}}} \le t_f \le t_{f_{\text{máx}}}, \\ & \theta_{a_{\text{mín}}} \le \theta_{a,k} \le \theta_{a_{\text{máx}}}, \\ & |\dot{\theta}_{a,k}| \le \dot{\theta}_{a_{\text{máx}}}, \qquad |\ddot{\theta}_{a,k}| \le \ddot{\theta}_{a_{\text{máx}}}, \\ & \theta_{a,k+1} = \theta_{a,k} + \frac{\Delta t}{2}(\dot{\theta}_{a,k} + \dot{\theta}_{a,k+1}), \\ & \dot{\theta}_{a,k+1} = \dot{\theta}_{a,k} + \frac{\Delta t}{2}(\ddot{\theta}_{a,k} + \ddot{\theta}_{a,k+1}), \\ & \dot{\theta}_{a,0} = 0, \\ & |\tau_a(\theta_{a,k}, \dot{\theta}_{a,k}, \ddot{\theta}_{a,k})| \le \tau_{a_{\text{máx}}}, \\ & p_{x,k} \ge x_{\text{mín}}, \qquad p_{z,k} \ge z_{\text{mín}}, \\ & v_x \ge 0.05\,\text{m/s}, \qquad v_z \ge 0.05\,\text{m/s}, \\ & v_z = \tan(\alpha)\, v_x, \\ & \sqrt{v_x^2 + v_z^2 + 10^{-9}\,\text{m}^2/\text{s}^2} = \|\hat{v}\|.\end{aligned} \tag{B.8}$$

Las restricciones fijan la dirección y la magnitud de la velocidad de liberación, mientras que la posición deseada se incorpora mediante el costo. También se imponen límites articulares, dinámicos y de posición cartesiana durante todo el movimiento: $x_{\text{mín}} = 0.35\,\text{m}$ y $z_{\text{mín}} = -0.15\,\text{m}$ acotan la posición cartesiana del efector durante el barrido.

Las articulaciones activas j_1, j_3 y j_5 están sujetas a

$$\begin{aligned} \dot{\theta}_{a_{\text{máx}}} &= (1.328,\ 1.957,\ 3.485)\ \text{rad/s}, \\ \ddot{\theta}_{a_{\text{máx}}} &= (8.0,\ 10.0,\ 12.0)\ \text{rad/s}^2, \\ \tau_{a_{\text{máx}}} &= (80.0,\ 40.0,\ 9.0)\ \text{N·m}. \end{aligned} \tag{B.9}$$

B.5. Parámetros numéricos

Tabla B.2: Parámetros de la configuración de referencia del planificador.

Problema	Parámetro	Valor
Articular y cartesiano	Nodos	30
Cartesiano	ε_p	0.5 mm
Cartesiano	ε_o	0.01 (adimensional)
Lanzamiento	Intervalos	120
Lanzamiento	$t_{f_{\text{mín}}}$	0.2 s
Lanzamiento	$t_{f_{\text{máx}}}$	1.2 s

Apéndice C

Calibración del sistema de percepción

El sistema utiliza dos cámaras externas que deben expresarse respecto del marco de la base del robot. Para obtener estas transformaciones se emplea un tablero ChArUco (Garrido-Jurado et al., 2014) como referencia común. Primero se determina la posición del tablero respecto de la base utilizando la cámara integrada en el Sawyer. A partir de esta referencia se calibra la cámara RGB-D y, después, la cámara cenital utilizada para observar la matriz de objetivos.

C.1. Calibración de la cámara RGB-D

Se coloca un tablero ChArUco fijo sobre la mesa y se observa desde distintas configuraciones con la cámara de la muñeca del Sawyer. La transformación de esta cámara respecto de la base se conoce a partir del estado del robot, mientras que la pose del tablero respecto de la cámara se obtiene a partir de la detección del ChArUco.

Con la convención de transformaciones de la Sección 2.1.1, para cada observación puede calcularse la pose del tablero respecto de la base mediante

$$T_{\text{base,tablero}} = T_{\text{base,mueca}}\, T_{\text{mueca,tablero}}. \tag{C.1}$$

Como el tablero permanece fijo durante todas las observaciones, las distintas estimaciones corresponden a una misma transformación. Estas se combinan para obtener una única pose del tablero respecto de la base.

Una vez conocida esta referencia, la cámara RGB-D observa el mismo tablero. La detección de sus esquinas en la imagen de color, junto con la información de profundidad, permite obtener la pose del tablero respecto de la cámara. La transformación de la cámara RGB-D respecto de la base se calcula entonces como

$$T_{\text{base,Xtion}} = T_{\text{base,tablero}}\, T^{-1}_{\text{Xtion,tablero}}. \tag{C.2}$$

Esta transformación permite expresar directamente en el marco de la base los puntos tridimensionales obtenidos por la cámara.

C.2. Corrección de la superficie de la mesa

Una vez transformada la nube de puntos al marco de la base, se estima el plano correspondiente a la superficie de la mesa. Esta corrección compensa pequeñas inclinaciones del montaje que, de otro modo, aparecerían como variaciones de altura en el mapa utilizado por la red.

La altura de cada punto se expresa respecto del plano estimado y no respecto de un valor constante de z. Así, una mesa ligeramente inclinada continúa produciendo una superficie aproximadamente plana en el mapa de alturas.

La posición y dimensiones de la zona de recogida se definen también respecto del marco de la base, lo que establece la correspondencia entre las celdas del mapa y las posiciones utilizadas para ejecutar los asimientos.

C.3. Calibración de la cámara cenital

La cámara cenital se calibra utilizando nuevamente el tablero ChArUco como referencia común. Una vez conocida la transformación de la cámara RGB-D respecto de la base, el tablero se observa simultáneamente con la cámara RGB-D y con la cámara cenital.

La pose del tablero respecto de la base puede obtenerse a partir de la cámara RGB-D

$$T_{\text{base,tablero}} = T_{\text{base,Xtion}}\, T_{\text{Xtion,tablero}}. \tag{C.3}$$

A partir de la pose del mismo tablero respecto de la cámara cenital, su transformación respecto de la base queda dada por

$$T_{\text{base,cenital}} = T_{\text{base,tablero}}\, T^{-1}_{\text{cenital,tablero}}. \tag{C.4}$$

De esta manera, ambas cámaras quedan expresadas respecto del mismo sistema de coordenadas del robot. La cámara cenital se utiliza después para localizar la matriz de objetivos y expresar su posición en el marco de la base. A partir de la posición y dimensiones conocidas de la matriz se determinan los centros correspondientes a cada objetivo.

Las transformaciones obtenidas se conservan mientras no cambien la posición de las cámaras, su configuración de captura o el montaje del sistema.